

CONSORT 2010 – Auswertung und Umsetzung

Systematische Komprimierung der Explanation-and-Elaboration-Arbeit, Abgleich mit der Bachelorarbeit und die bislang fehlende Fallzahlbegründung

Bachelorarbeit U15-Plyometrie · DSHS Köln · Stand 09.09.2026 · Arbeitsdokument, keine Manuskriptfassung

Quelle: Moher, D., Hopewell, S., Schulz, K. F., Montori, V., Gøtzsche, P. C., Devereaux, P. J., Elbourne, D., Egger, M., & Altman, D. G. (2010). CONSORT 2010 explanation and elaboration: Updated guidelines for reporting parallel group randomised trials. *BMJ*, 340, c869. <https://doi.org/10.1136/bmj.c869>

Zitierhinweis: Die vorliegende Datei ist die BMJ-Online-first-Fassung („BMJ | online FIRST“, 23.03.2010) mit eigener PDF-Paginierung „Page x of 28“. Diese Seitenzahlen sind keine Zeitschriftenseiten. BMJ vergibt Artikelnummern; der Locator ist c869. Für wörtliche Zitate ist die stabile Fundstellenangabe die Item-Nummer, nicht die PDF-Seite. Nach § 6.4 Verifikationsregel 2 als Ahead-of-Print-Merkmal in T4 aufzunehmen.

0 Kurzfassung

Die Arbeit ist keine Methodenlehre, sondern eine Berichtsnorm: Sie sagt, was in einem Studienbericht stehen muss, damit ein Leser Verzerrungsrisiken selbst einschätzen kann. Für jedes der 25 Checklistenitems liefert sie ein Positivbeispiel aus der Literatur, die Begründung und – das ist ihr eigentlicher Wert – die empirische Evidenz, wie oft und mit welcher Folge das Item in der publizierten Literatur verfehlt wird.

Vier Befunde für unser Projekt:

1. Die Berichtslogik trägt unsere Arbeit weitgehend schon. Die 25 Checklistenzeilen zerfallen in 37 Einzelpunkte; davon sind 21 im Manuskript oder in den Projektanweisungen bereits verortet, 5 für ein nicht randomisiertes Design gegenstandslos und 11 offen. Kein einziger der offenen Punkte erzwingt eine Designänderung – alle betreffen die Berichterstattung.
2. Item 7a ist tatsächlich die größte Lücke – aber nicht so, wie in der Ausgangsfrage angenommen. CONSORT verlangt nicht eine Poweranalyse, sondern eine Auskunft darüber, wie die Fallzahl zustande kam. Bei uns lautet die wahrheitsgemäße Antwort: über die teilnehmenden Vereine. Das ist zulässig und muss so berichtet werden. Was fehlt, ist die Sensitivitätsanalyse, die aus dieser Fallzahl die nachweisbare Effektgröße ableitet. Sie ist in § 3 dieses Dokuments gerechnet.
3. Das Ergebnis dieser Rechnung ist unbequem und muss den Ton von Kapitel 6 und 7 bestimmen. Der minimal nachweisbare Effekt liegt im günstigsten Fall bei $d = 0,39$ (30 m) bis $d = 1,06$ (505 links) und damit beim Zwei- bis Fünffachen des SESOI. Gegenüber der dokumentierten Vorab-Erwartung für unsere Dosis ($d = 0,06$ bis $0,11$ im Sprint) beträgt die Power 6 bis 9 Prozent. Die Studie kann den erwarteten Sprinteffekt nicht nachweisen – nicht, weil sie schlecht gemacht wäre, sondern weil $N = 28$ dafür um eine Größenordnung zu klein ist.
4. Der Abschnitt zur Analysepopulation (Item 16 und Box 6, S. 17) ist für unsere Adhärenzlage der folgenreichste Teil der Quelle. Er entscheidet einen seit Rev. 15 offenen Streitpunkt – BW-11 neu bleibt in jeder Analyse, weil ein Instrumentenfehler keine Protokollabweichung ist –, verbietet die Fortschreibung von Prä-Werten und verlagert Schwab-Punkt 2 von einer Grundsatzentscheidung auf eine Berichtsaufgabe. Ausgearbeitet in § 2.4.

Konsequenz, die vor dem Schreiben von Kapitel 5 bis 7 feststehen muss: Die Arbeit ist als Schätzstudie zu berichten, nicht als Entscheidungsstudie. Jede Zielgröße wird mit adjustierter Differenz und 95%-Konfidenzintervall berichtet; ein nicht signifikantes Ergebnis wird nirgends als „kein Unterschied“ formuliert. CONSORT nennt genau diesen Fehler ausdrücklich (Item 20) und weist Post-hoc-Poweranalysen als untauglich zurück (Item 7a).

1 Die 25 Items, komprimiert

Wiedergegeben ist jeweils die Kernforderung und die tragende Begründung des Explanation-Teils. Die Spalte „Empirischer Befund“ enthält die Zahlen, mit denen die Autoren die Notwendigkeit des Items belegen – sie sind für unsere Diskussion brauchbar, weil sie den Feldstandard beziffern.

1.1 Titel und Zusammenfassung (Items 1a–1b)

Item	Kernforderung	Begründung	Empirischer Befund
1a	Das Design im Titel kennzeichnen.	Indexierung in Datenbanken hängt davon ab; nicht gekennzeichnete Studien werden in Reviews nicht gefunden.	Nur 21 % von 519 Berichten (2000) beschrieben die Zuteilungsmethode; 34 % von 616 (2006).
1b	Strukturierte Zusammenfassung nach der Abstract-Checkliste (Tab. 2 der Quelle).	Viele Leser entscheiden allein anhand des Abstracts. Abstracts enthalten regelmäßig Aussagen, die im Volltext nicht stehen.	Strukturierte Abstracts sind nachweislich von höherer Qualität und leichter durchsuchbar.

Die Abstract-Checkliste (Tab. 2 der Quelle) verlangt: Design, Eignungskriterien und Setting, Interventionen je Gruppe, Zielsetzung, primäre Zielgröße, Zuteilungsverfahren, Verblindung, zugeteilte n je Gruppe, Studienstatus, analysierte n je Gruppe, Ergebnis der primären Zielgröße mit Effektgröße und Präzision, unerwünschte Effekte, Interpretation, Registrierung, Förderung.

1.2 Einleitung (Items 2a–2b)

Item	Kernforderung	Begründung	Empirischer Befund
2a	Wissenschaftlicher Hintergrund und Begründung der Studie; idealerweise mit Verweis auf ein systematisches Review vorangegangener Studien oder auf dessen Fehlen.	Deklaration von Helsinki: Forschung an Menschen setzt gründliche Kenntnis der Literatur voraus. Studien, deren Frage bereits beantwortet war, sind unethisch.	Mehrere Studien waren nachweislich unnötig, weil ein systematisches Review die Frage schon beantwortet hatte.
2b	Spezifische Ziele oder Hypothesen. Hypothesen sind spezifischer als Ziele und einer statistischen Prüfung zugänglich.	Ziele sind die Fragen, die die Studie beantworten soll; Hypothesen sind die vorab festgelegten prüfbaren Formulierungen.	Dieses Item wird von den meisten Berichten erfüllt.

1.3 Methodik (Items 3a–12b)

Item	Kernforderung	Begründung	Empirischer Befund
3a	Designtyp (parallel, faktoriell, Cluster ...), konzeptioneller Rahmen (Überlegenheit, Nichtunterlegenheit) und Zuteilungsverhältnis explizit angeben. Die Einheit der Zuteilung benennen.	Ungewöhnliche Designs bedeuten größeren Fallzahlbedarf und komplexere Analyse – die Wahl ist zu begründen.	Nur gut die Hälfte publizierter Studien hat ein zweiarmliges Paralleldesign.
3b	Wichtige Änderungen der Methodik nach Studienbeginn, mit Gründen.	Protokollabweichungen sind unvermeidlich; unberichtete Abweichungen verhindern die Einordnung der Ergebnisse.	Rund die Hälfte der Studienberichte weist eine unerklärte Diskrepanz zur primären Zielgröße des Protokolls auf.
4a	Eignungskriterien und Rekrutierungsweg. Die Trennung in Ein- und Ausschlusskriterien ist entbehrlich.	Eignungskriterien berühren die interne Validität nicht (sie wirken vor der Zuteilung), sind aber für die externe Validität zentral.	Von 31 Protokollkriterien erschienen im Artikel im Mittel 63 %; 25 % von 364 chirurgischen

Item	Kernforderung	Begründung	Empirischer Befund
			Studien nannten gar keine.
4b	Setting und Orte der Datenerhebung, einschließlich der Rahmenbedingungen, die das Ergebnis beeinflusst haben könnten.	Institutionen unterscheiden sich in Organisation, Erfahrung und Ausgangsrisiko; auch soziale und klimatische Bedingungen wirken auf die externe Validität.	—
5	Interventionen beider Gruppen so beschreiben, dass sie replizierbar sind – einschließlich wann und wie sie tatsächlich durchgeführt wurden. Auch die Kontrollbedingung („usual care“) vollständig beschreiben.	Ein Anwender muss wissen, wie die Intervention zu verabreichen ist. Verweis auf die CONSORT-Erweiterung für nicht pharmakologische Interventionen.	—
6a	Vorab festgelegte primäre und sekundäre Zielgrößen vollständig definieren, einschließlich wann und wie erhoben. Mehrere primäre Zielgrößen werden nicht empfohlen.	Die primäre Zielgröße ist üblicherweise die, auf der die Fallzahlrechnung beruht. Mehrere primäre Zielgrößen erzeugen ein Mehrfachtestungsproblem.	Nur 45 % (2000) bzw. 53 % (2006) der Studien benannten eine primäre Zielgröße.
6b	Änderungen der Zielgrößen nach Studienbeginn, mit Gründen.	Eine Änderung auf Basis entblindeter Daten ist besonders problematisch.	62 % von 102 Studien hatten mindestens eine gegenüber dem Protokoll geänderte, neu eingeführte oder weggelassene primäre Zielgröße.
7a	Wie die Fallzahl bestimmt wurde. Bei formaler Rechnung: primäre Zielgröße, alle Eingangsgrößen und die resultierende Zielfallzahl je Gruppe. Weicht die erreichte von der geplanten Fallzahl ab, ist der Grund anzugeben.	Vier Elemente einer Fallzahlrechnung: erwartete Ergebnisse je Gruppe (und damit die bedeutsame Differenz), α , Power, bei stetigen Größen die Standardabweichung. Unterpowerete Studien sind vertretbar, wenn sie unverzerrt, vollständig berichtet und unabhängig vom Ergebnis publiziert werden – dann sind sie für Metaanalysen verwertbar.	Medianfallzahl 54 (Arthritis), 46 (Dermatologie), 65 (Schizophrenie), 80 (PubMed-Querschnitt). Nur 27 % (2000) bzw. 45 % (2006) berichteten überhaupt eine Fallzahlrechnung.
7b	Zwischenanalysen und Abbruchregeln, sofern zutreffend.	Vorzeitiger Abbruch aus ethischen Gründen erfordert vorab festgelegte Grenzen.	Von 143 vorzeitig beendeten Studien nannten 28 die geplante Fallzahl nicht, 48 nicht, ob eine Abbruchregel bestand.
8a	Verfahren zur Erzeugung der Zufallsfolge.	Nur ein Zufallsprozess mit Unvorhersagbarkeit verhindert Selektionsverzerrung.	In über 90 % der Fälle Zufallszahlengenerator oder -tabelle.
8b	Art der Randomisierung, Einschränkungen (Blockbildung, Blockgröße, Stratifizierung).	Blockbildung kann bei unverblindeten Studien die nächste Zuteilung vorhersagbar machen.	—
9	Mechanismus der Zuteilungsverbergung („allocation concealment“) und die Schritte, mit denen die Folge bis zur Zuteilung verborgen blieb.	Zuteilungsverbergung schützt die Folge VOR der Zuteilung und verhindert Selektionsverzerrung; sie ist immer umsetzbar. Verblindung schützt NACH der Zuteilung und ist	Studien mit unzureichender Verbergung berichten systematisch größere Effekte. Nur 18 % eines

Item	Kernforderung	Begründung	Empirischer Befund
		nicht immer umsetzbar. Beides ist strikt zu trennen.	repräsentativen PubMed-Querschnitts nannten überhaupt einen Mechanismus.
10	Wer die Folge erzeugte, wer einschloss, wer zuteilte.	Selbst bei einwandfreier Folge kann fehlende Trennung dieser drei Rollen Verzerrung erzeugen.	—
11a	Wer nach der Zuteilung verblindet war und wie. Die Begriffe „doppelblind“ und „dreifachblind“ sind aufzugeben und durch die Nennung der tatsächlich verblindeten Rollen zu ersetzen.	Verblindung schützt vor Durchführungs- und Erhebungsverzerrung, besonders bei subjektiven Zielgrößen. Auch wo Teilnehmer nicht verblindet werden können, sind Datenerheber und Auswerter oft verblindbar.	Von 200 als „doppelblind“ berichteten Studien fanden sich 18 verschiedene Kombinationen; jede fünfte verblindete weder Teilnehmer noch Behandler noch Datenerheber.
11b	Ähnlichkeit der Interventionen, sofern relevant.	Belegt die Plausibilität der behaupteten Verblindung. Ein Test der Verblindung durch Nachbefragung wird seit 2010 nicht mehr empfohlen; bekannte Brüche der Verblindung sind zu berichten.	—
12a	Statistische Verfahren für primäre und sekundäre Zielgrößen. Grundsatz: so detailliert, dass ein kundiger Leser mit den Rohdaten die Ergebnisse reproduzieren kann.	Fast jedes Verfahren liefert eine Effektschätzung; diese ist stets mit Konfidenzintervall zu berichten. Exakte p-Werte sind Schwellenangaben vorzuziehen. Mehrere Messungen an einer Person dürfen nicht als unabhängig behandelt werden.	63 % von 196 Arthritis-Studien werteten mehrere Beobachtungen pro Person fälschlich als unabhängig.
12b	Verfahren für Zusatzanalysen (Subgruppen, adjustierte Analysen).	Adjustierte Analysen sind sinnvoll, wenn eine Variable prognostisch bedeutsam ist, und gehören ins Protokoll. Die Entscheidung zu adjustieren darf NICHT davon abhängen, ob der Baseline-Unterschied signifikant ist – das verzerrt die Schätzung. Subgruppeneffekte erfordern einen Interaktionstest, nicht den Vergleich zweier p-Werte.	Von 50 Studienberichten enthielten 35 Subgruppenanalysen, davon nur 42 % mit Interaktionstest; in einer chirurgischen Stichprobe waren 91 % der Subgruppenanalysen post hoc.

1.4 Ergebnisse (Items 13a–19)

Item	Kernforderung	Begründung	Empirischer Befund
13a	Je Gruppe: Zahl der Zugeteilten, Zahl der die Intervention Erhaltenden, Zahl der für die primäre Zielgröße Ausgewerteten. Flussdiagramm nachdrücklich empfohlen.	Nach der Zuteilung ausgeschlossene Teilnehmer sind vermutlich nicht repräsentativ. Die Zahl der auf Eignung Geprüften betrifft nur die externe Validität.	Selbst die Zahl der Zugeteilten und der von der Analyse Ausgeschlossenen fehlte in bis zu 20 % der Artikel. Berichte mit Flussdiagramm waren deutlich vollständiger.
13b	Je Gruppe: Ausfälle und Ausschlüsse	Ausfall (nicht steuerbar) ist von	—

Item	Kernforderung	Begründung	Empirischer Befund
	nach der Zuteilung, mit Gründen.	untersucherseitigem Ausschluss zu unterscheiden. Der Begriff „Protokollabweichung“ rechtfertigt für sich genommen keinen Ausschluss – Art und exakter Grund sind zu nennen.	
14a	Zeiträume von Rekrutierung und Nachbeobachtung, mit Datum.	Ordnet die Studie historisch ein; Begleitbedingungen ändern sich.	—
14b	Warum die Studie endete oder abgebrochen wurde.	Ein aus ergebnisunabhängigen Gründen beendetes oder planmäßig abgeschlossenes Verfahren erzeugt keine Verzerrung – das ist zu belegen, nicht zu behaupten.	—
15	Tabelle mit demografischen und klinischen Ausgangsmerkmalen je Gruppe. Stetige Größen mit Streuungsmaß; Standardfehler und Konfidenzintervalle sind hier unzulässig, weil sie inferenzstatistisch und nicht deskriptiv sind.	Signifikanztests auf Baseline-Unterschiede sind bei Randomisierung nicht falsch, sondern unlogisch: Man weiß bereits, dass jede Differenz zufällig ist. Der Vergleich soll stattdessen über die prognostische Stärke der Variablen und die Größe der Ungleichheit geführt werden.	Solche Tests wurden 1997 in der Hälfte von 50 Studien führender Zeitschriften berichtet – und sind bis heute verbreitet.
16 (Box 6, S. 17)	Je Gruppe der Nenner jeder Analyse und ob nach ursprünglicher Zuteilung ausgewertet wurde. Die Zahlen variieren zwischen Zielgrößen und sind je Analyse anzugeben.	Der CONSORT-Text verzichtet bewusst auf die Forderung „Intention-to-treat“ als Etikett und verlangt stattdessen eine klare Beschreibung, wer in welcher Analyse enthalten war. Box 6 trennt fehlende Zielgrößenwerte von Nichteinhaltung des Protokolls. Eine Per-Protokoll-Analyse „should be properly labelled as a non-randomised, observational comparison“. Für uns der folgenreichste Abschnitt der Quelle – ausgearbeitet in § 2.4.	In der Hälfte der Studien fehlen bei über 10 % der Teilnehmer Zielgrößenwerte. „Last observation carried forward“ wird als verzerrend scharf kritisiert.
17a	Je Zielgröße: Ergebnis in jeder Gruppe UND die geschätzte Effektgröße mit Präzision (95%-KI). Häufiger Fehler: getrennte Konfidenzintervalle je Gruppe statt eines Intervalls für den Gruppenunterschied.	Konfidenzintervalle sind besonders dort wertvoll, wo ein Unterschied die Signifikanzschwelle verfehlt – sie zeigen, dass ein praktisch bedeutsamer Effekt nicht ausgeschlossen ist. Ergebnisse dürfen nicht ausschließlich als p-Werte berichtet werden. Alle geplanten Zielgrößen sind zu berichten, nicht nur die signifikanten.	—
17b	Bei binären Zielgrößen absolute und relative Effektmaße.	Für uns gegenstandslos (alle Zielgrößen stetig).	—
18	Weitere Analysen, vorab festgelegte von explorativen unterschieden. Bei adjustierten Analysen sind unadjustierte UND adjustierte Ergebnisse zu berichten.	Mehrfachanalysen desselben Datensatzes erzeugen falsch positive Befunde. Vorab festgelegte Analysen sind erheblich verlässlicher als datengetriebene.	Bei allen 25 Studien mit Subgruppenanalysen und bei 23 von 28 mit adjustierten Analysen fanden sich unbenannte Abweichungen vom Protokoll.

Item	Kernforderung	Begründung	Empirischer Befund
19	Alle wichtigen unerwünschten oder unbeabsichtigten Effekte je Gruppe; absolute Häufigkeit je Studienarm und Zahl der wegen unerwünschter Effekte Ausgeschiedenen.	Nicht jedes beobachtete Ereignis ist Folge der Intervention. Abschließend ist eine ausgewogene Abwägung von Nutzen und Schaden zu geben.	89 % von 133 Berichten erwähnten unerwünschte Ereignisse, aber 27 % gaben keine Information zu schweren Ereignissen, 48 % keine zu Abbrüchen deswegen.

1.5 Diskussion und weitere Angaben (Items 20–25)

Item	Kernforderung	Begründung	Empirischer Befund
20	Limitationen: Verzerrungsquellen, Ungenauigkeit (Imprecision) und gegebenenfalls Mehrfachtestung.	Empfohlene Struktur der Diskussion: (1) knappe Zusammenfassung der Kernbefunde, (2) mögliche Mechanismen und Erklärungen, (3) Vergleich mit anderen Studien, (4) Limitationen und die Mittel, mit denen ihnen begegnet wurde, (5) Implikationen. Der ausdrücklich benannte häufige Fehler: ein nicht signifikantes Ergebnis als Gleichwertigkeit zu deuten. Das Konfidenzintervall zeigt unabhängig vom p-Wert, ob ein bedeutsamer Effekt mit den Daten vereinbar bleibt.	Limitationen fehlen häufig ganz. Ein Beispiel im Text: signifikant weniger Komplikationen bei laparoskopischer Cholezystektomie – unerwähnt blieb, dass 80 % der offenen Eingriffe von Ausbildungsassistenten durchgeführt wurden.
21	Generalisierbarkeit (externe Validität, Anwendbarkeit).	Interne Validität ist Voraussetzung: Bei einer verzerrten Studie erübrigt sich die Frage der externen Validität. Externe Validität ist immer nur bezogen auf klar benannte, nicht untersuchte Bedingungen zu beurteilen. Der Anteil der Eignungsgeprüften, die eine Teilnahme ablehnten, gehört dazu.	—
22	Interpretation im Einklang mit den Ergebnissen, unter Abwägung von Nutzen und Schaden und unter Berücksichtigung anderer Evidenz. Die Diskussion soll auf einer umfassenden Suche beruhen, nicht auf den Studien, die zum eigenen Ergebnis passen.	Ideal ist die Einbettung in ein systematisches Review; wo das unpraktikabel ist, ist ein vorhandenes Review zu zitieren.	—
23	Registrierungsnummer und Register.	Für uns gegenstandslos, aber zu erwähnen: Wer nicht registriert hat, soll das ausdrücklich sagen und den Grund nennen.	Die ICMJE-Politik von 2004 hat die Registrierungszahlen sprunghaft erhöht.
24	Wo das vollständige Studienprotokoll zugänglich ist.	Ein Protokoll begrenzt nachträgliche, unbenannte Methodenänderungen und selektives Berichten. Neu in CONSORT 2010.	—
25	Förderquellen und Rolle der Förderer.	Industriefinanzierte Forschung hat eine vierfach erhöhte Chance auf sponsorgünstige Ergebnisse (OR 4,05 [2,98; 5,51]).	29 % von 370 Arzneimittelstudien nannten die Förderquelle nicht.

2 Abgleich mit der Bachelorarbeit

Grundlage ist die Gliederung v3 und der Manuskriptstand vom 08.09.2026. Der Berichtsmodus bleibt durchgängig „in Anlehnung an CONSORT“, weil nicht randomisiert zugeteilt wurde.

2.1 Statusübersicht

Item	Stand in der Arbeit	Verortung v3	Maßnahme
1a	Erfüllt	Titel	Titel führt „quasi-experimentelle, kontrollierte Interventionsstudie“. Keine Änderung.
1b	Offen	Vorspann	Abstract nach der Abstract-Checkliste (Tab. 2 der Quelle) strukturieren. Zwei Punkte fehlen dort erfahrungsgemäß: analysierte n je Gruppe und Effektgröße mit Präzision für die primäre Zielgröße.
2a	Vorbereitet	Kap. 1	Die Korpuslücke ist in den Sitzungsnotizen dokumentiert. CONSORT verlangt genau diese Angabe: Verweis auf ein systematisches Review oder ausdrücklich auf dessen Fehlen. Unsere systematische Suche vom 08.09. ist damit ein Berichtsbestandteil, keine interne Notiz.
2b	Offen	Kap. 3	H0/H1 je Zielgröße in der festen Reihenfolge Sprint → Richtungswechsel → Sprung.
3a	Erfüllt	4.1	Design, drei Cluster, Allokationsverhältnis 1,4 : 1 stehen. Ergänzen: Überlegenheitsrahmen ausdrücklich benennen; die Zuteilungseinheit ist der Verein, nicht der Spieler.
3b	Teilweise	4.1, 4.3	Zu berichten sind: Ausfall SC West vor Studienbeginn mit der Folge Ratio 2:1 → 1,4:1, Wegfall Fragebogen B, KG-Posttermin 15.09. Alle drei sind Änderungen nach Studienbeginn im Sinne von 3b und gehören mit Grund in den Methodenteil, nicht nur in die Limitationen.
4a	Erfüllt	4.2	Ergänzen: Rekrutierungsweg (Ansprache über die Vereine) und die Tier-2-Einordnung nach McKay et al. (2022) als Merkmal der externen Validität.
4b	Erfüllt	4.2, 4.3	Keine Änderung.
5	Erfüllt	4.5.1, 4.5.2	TIDieR deckt Item 5 vollständig ab und geht darüber hinaus. 4.5.2 beschreibt die Vergleichsbedingung – von CONSORT ausdrücklich verlangt („usual care“ vollständig beschreiben).
6a	Teilweise	4.4, 4.7	Die Zielgrößen sind definiert, die primäre ist nicht benannt (Schwab-Punkt 1). CONSORT rät von mehreren primären Zielgrößen ab, weil sie ein Mehrfachtestungsproblem erzeugen. Das ist das stärkste Argument, in 4.7 eine primäre Zielgröße festzulegen.
6b	Betrifft uns	4.4, 4.7	Zwei nachträgliche Festlegungen sind als solche zu kennzeichnen: 5 m nur deskriptiv (wegen KG-Ausfällen und TE/SESOL 2,92) und das COD-Defizit als explorative Zusatzanalyse. Beides ist zulässig, muss aber offengelegt werden.
7a	FEHLT	4.7, Anhang G	Siehe § 3. Ressourcenbegründung plus Sensitivitätsanalyse.
7b	Gegenstandslos	—	Keine Zwischenanalysen, kein vorzeitiger Abbruch.
8a/8b	Gegenstandslos	4.1	Nicht randomisiert. Der Ersatz ist die Beschreibung der pragmatischen Zuteilung anhand struktureller

Item	Stand in der Arbeit	Verortung v3	Maßnahme
			Vereinsmerkmale.
9	Analog erfüllt	4.1	Der Kern von Item 9 ist auf uns übertragbar: Die Zuteilung wurde vor den Eingangstestungen festgelegt, Mannschaften und Trainerteams erfuhren sie erst danach. Das ist funktional eine Zuteilungsverbergung und schützt vor derselben Verzerrung. So – und nicht als Randomisierungersatz – zu formulieren.
10	Analog erfüllt	4.1	Zuteilung, Einschluss und Testung erfolgten durch den Verfasser. CONSORT verlangt die Trennung dieser Rollen; sie war hier nicht möglich. Das ist in 6.2 zu benennen, nicht zu verschweigen.
11a	Teilweise	4.3, 6.2	Die Rollenlogik von CONSORT ist zu übernehmen: Teilnehmer und Trainer nicht verblindet (feldimmanent), Testleiter nicht verblindet (Personalunion), Datenerheber = Testleiter. Die Begriffe „einfach-/doppelblind“ vermeiden. TESTEX klammert die Verblindung in Trainingsstudien bewusst aus – das ist die Einordnung, nicht die Entschuldigung.
11b	Gegenstandslos	—	Keine maskierbare Intervention.
12a	Vorbereitet	4.7	ANCOVA ist spezifiziert. Ergänzen: exakte p-Werte statt Schwellen, KI für jede Effektschätzung, und die Klarstellung, dass die 505-Zeiten seitengetrent und damit nicht als unabhängige Beobachtungen je Spieler behandelt werden.
12b	Vorbereitet	4.7	Wichtig für uns: CONSORT verlangt, dass die Adjustierungsentscheidung NICHT davon abhängt, ob der Baseline-Unterschied signifikant ist. Unsere Begründung ist prognostisch (Ausgangswert, Reifestatus) und vorab festgelegt – genau die zulässige Form. Das in 4.7 so schreiben.
13a/ 13b	Vorbereitet	5.1	Flussdiagramm mit Zahlen und Gründen je Stufe. Die Felder sind derzeit blockiert. CONSORT trennt Ausfall von untersucherseitigem Ausschluss – das ist genau die offene Frage HL-04/BW-01 gegenüber BW-11 neu (Instrumentenfehler).
14a	Erfüllt	4.3, 5.1	Alle Termine dokumentiert. Ergänzen: die gruppenungleichen Prä-Post-Intervalle sind hier zu berichten, nicht erst in der Diskussion.
14b	Betrifft uns	5.1	Die Studie endete planmäßig. Das ist ein Satz und ein guter – ein ergebnisunabhängiges Ende erzeugt keine Verzerrung.
15	Vorbereitet	5.1	Baseline-Tabelle ohne Signifikanztests ist bereits Projektstandard. Die CONSORT-Begründung ist aber eine andere als bisher notiert (s. § 2.2) und muss angepasst werden.
16	Offen – wichtigster Punkt	4.7, 5.1	Nenner je Analyse und je Zielgröße. Bei uns variieren sie stark (5 m n = 26, 505 n = 29, %PAH n = 28). Vier verschiedene Ausschlussklassen, die getrennt zu behandeln sind. Ausgearbeitet in § 2.4.
17a	Offen	5.2	Je Zielgröße: $M \pm SD$ prä und post je Gruppe, adjustierte Differenz mit 95-%-KI, exakter p-Wert. Tabellenschablone in § 4 dieses Dokuments.

Item	Stand in der Arbeit	Verortung v3	Maßnahme
17b	Gegenstandslos	—	Keine binären Zielgrößen.
18	Vorbereitet	5.2	Explorativ gekennzeichnet werden: COD-Defizit, gegebenenfalls 5 m. Zusätzlich verlangt CONSORT bei adjustierten Analysen die unadjustierten Ergebnisse daneben – das ist bisher nirgends vorgesehen und aufzunehmen.
19	Offen	5.1	Das Schmerz-Item des Fragebogens A ist unsere Erfassung unerwünschter Effekte: 12 Meldungen, überwiegend Knie und hinterer Oberschenkel, zwei schmerzbedingte Abbrüche. Absolute Häufigkeit je Gruppe und Zahl der deswegen Ausgeschiedenen berichten. Für die KG existiert keine Erfassung – das ist zu sagen.
20	Vorbereitet	6.1, 6.2	Die 22 Limitationen der Projektanweisungen decken Item 20 ab. Fehlt bisher: die Ungenauigkeit („imprecision“) als eigener, quantifizierter Punkt – genau das liefert § 3.
21	Vorbereitet	6.2	Tier-2-Stichprobe, ausschließlich männlich, drei Kölner Vereine, Anteil der angefragten und nicht teilnehmenden Vereine (Flowchart-Feld).
22	Vorbereitet	6, 7	Die Gegenbefund-Pflicht (§ 6.4) ist strenger als Item 22 und deckt es ab.
23	Betrifft uns	4.1	Nicht registriert. CONSORT verlangt in diesem Fall die ausdrückliche Feststellung und den Grund. Ein Satz in 4.1: studentische Qualifikationsarbeit, Ethikvotum Nr. 157/2026, keine Registrierung.
24	Betrifft uns	4.1 oder Anhang	Der Ethikantrag ist unser Protokoll. Angeben, dass er samt Votum als Anhang E vorliegt – das erfüllt Item 24 und stützt zugleich die Vorab-Festlegung der Analysen.
25	Offen	Vorspann	Ein Satz: keine Drittmittel, Messtechnik durch die DSHS gestellt, keine Rolle Dritter in Design, Auswertung oder Berichterstattung.

2.2 Eine Begründung, die wir bisher falsch führen

Die Projektanweisungen halten fest: „Nach CONSORT keine Signifikanztests auf Baseline-Unterschiede.“ Das ist die richtige Regel mit der falschen Begründung. CONSORT begründet sie damit, dass bei Randomisierung jede Baseline-Differenz per Konstruktion zufällig entstanden ist – ein Test prüft also eine Hypothese, deren Antwort man bereits kennt („not necessarily wrong, just illogical“, Item 15).

Bei uns wurde nicht randomisiert. Die Baseline-Unterschiede sind eben nicht zufällig, sondern Folge der Vereinszugehörigkeit und des Jahrgangs. Die CONSORT-Begründung greift für uns damit nicht.

Vorschlag: Die Regel beibehalten, aber anders begründen – ein Signifikanztest beantwortet die falsche Frage. Relevant ist nicht, ob die Baseline-Differenz zufällig ist (das ist sie nachweislich nicht), sondern wie groß sie ist und wie stark die betreffende Variable prognostisch wirkt. Genau das leistet die Angabe von d neben $M \pm SD$, wie sie in § 3 der Projektanweisungen bereits vorliegt. CONSORT stützt diesen zweiten Teil ausdrücklich: Der Vergleich soll über prognostische Stärke und Größe der Ungleichheit geführt werden. Wir folgen CONSORT damit weiterhin – nur aus dem zweiten seiner beiden Gründe, nicht aus dem ersten.

2.3 Zwei Punkte, die CONSORT für uns entschärft

- Schwab-Punkt 2 (ITT gegen Per-Protokoll). CONSORT 2010 hat die Forderung nach „Intention-to-treat“ als Etikett bewusst gestrichen, weil keines dieser Etiketten verlässlich sagt, wer tatsächlich enthalten

war. Verlangt wird stattdessen eine klare Beschreibung, wer in welche Analyse einging (Item 16). Damit verschiebt sich der Punkt von einer Grundsatzentscheidung zu einer Berichtsaufgabe. Wegen der Bedeutung für unsere Adhärenzlage ist der Sachverhalt in § 2.4 gesondert ausgearbeitet.

- Die Frage, ob eine Studie dieser Größe überhaupt vertretbar ist. CONSORT beantwortet sie mit Bedingungen statt mit einem Verbot: Eine unterpowerete Studie ist vertretbar, wenn sie unverzerrt durchgeführt, vollständig berichtet und unabhängig vom Ergebnis publiziert wird – dann ist sie für die spätere Metaanalyse verwertbar (Item 7a). Das ist der tragfähigste Rahmen für unsere Arbeit und gehört in 6.2 und 7.2.

2.4 Wer in welche Analyse eingeht (Item 16 und Box 6, S. 17)

Dieser Abschnitt der Quelle ist für unsere Stichprobe der folgenreichste. Box 6 trennt zwei Gründe, aus denen eine Intention-to-treat-Analyse in der Praxis scheitert – fehlende Zielgrößenwerte und Nichteinhaltung des Protokolls – und behandelt beide getrennt. Drei Festlegungen der Quelle sind für uns bindend:

- Eine Analyse, die Teilnehmer wegen unzureichender Protokolltreue ausschließt – insbesondere wegen einer nicht erreichten Mindestdosis –, heißt „modified intention-to-treat“ oder „per protocol“. Sie ist in manchen Situationen angemessen, „should be properly labelled as a non-randomised, observational comparison“.
- Eine Vollständige-Fälle-Analyse verliert Power durch die kleinere Fallzahl, und Verzerrung entsteht dann, wenn der Ausfall mit dem Ansprechen auf die Behandlung zusammenhängt. Besorgniserregend ist es insbesondere dann, wenn sich Häufigkeit oder Ursachen des Ausfalls zwischen den Gruppen unterscheiden.
- Kein Etikett – auch nicht „intention-to-treat“ – sagt verlässlich, wer tatsächlich enthalten war. Deshalb hat CONSORT 2010 die Forderung nach ITT gestrichen und durch die Forderung nach einer klaren Beschreibung ersetzt, wer in welche Analyse einging. „Last observation carried forward“ wird ausdrücklich als verzerrend kritisiert.

Angewandt auf unsere Stichprobe zerfallen die Ausschlüsse in vier Klassen, die nach Box 6 unterschiedlich zu behandeln und getrennt zu berichten sind:

Tab. A. Ausschlussklassen der Studie und ihre Einordnung nach Box 6.

Klasse	Betroffene Fälle	Einordnung nach Box 6	Konsequenz
Nichteinhaltung des Protokolls	HL-04 und BW-01: konnten dokumentieren und taten es nicht. Dazu alle Spieler unterhalb einer noch zu definierenden Mindestdosis (Adhärenz gesamt 43 %, 92 von 216 Einheiten).	Genau der Fall, den Box 6 beschreibt: „did not take all the intended treatment“. Ein Ausschluss macht die Analyse zur Per-Protokoll-Rechnung.	Nur zusätzlich zur Hauptanalyse, ausdrücklich als nicht randomisierter, beobachtender Vergleich gekennzeichnet. Mindestdosis vorab definieren, nicht nach Sichtung der Post-Werte.
Instrumentenfehler	BW-11 neu (BW-21 alt): stand in der Auswahlliste des Fragebogens nicht zur Verfügung.	KEINE Nichteinhaltung. Box 6 zählt auf, was als Protokollabweichung gilt – ein Erhebungsfehler des Instruments steht nicht darunter. Der Spieler kann das Programm vollständig absolviert haben; wir wissen es nur nicht.	Bleibt in jeder Analyse. Ein Ausschluss wäre ein Ausschluss wegen unseres Messfehlers, nicht wegen seines Verhaltens. Damit ist die offene Frage HL-04/BW-01 gegenüber BW-11 aus der Quelle entschieden.
Fehlende Kovariate	HL-08 (Elterngrößen), VS-11 (Geburtsdatum), VS-18 (Alter außerhalb des Khamis-Roche-Koeffizientenbereichs) →	Vollständige-Fälle-Analyse. Box 6 nennt Powerverlust und, wenn der Ausfall mit dem Ansprechen zusammenhängt,	Bei VS-18 ist der Ausschlussgrund nicht zufällig, sondern liegt im Reifestatus selbst – also in der Variablen, für die adjustiert wird. Das ist als

Klasse	Betroffene Fälle	Einordnung nach Box 6	Konsequenz
	analysierbares N = 28 statt 31.	Verzerrung.	Verzerrungsrisiko zu benennen, nicht nur als Fallzahlverlust. Alle drei Fälle sind in die KG-nahe Randlage einzuordnen (zwei von drei aus Verein C).
Versuchsausschluss	Sechs 505-Versuche wegen „Linie nicht getroffen“; ungleiche Zahl gültiger Versuche (IG 2,2–2,6; KG 1,0–2,4).	Kein Teilnehmerschluss, sondern eine Ungleichheit der Testbedingungen unterhalb der Teilnehmerebene.	In 5.1 zu berichten. Betrifft Item 16 insofern, als die Nenner je Zielgröße auseinanderfallen.

Was das für die Per-Protokoll-Frage bedeutet

Box 6 begründet die Warnung vor Per-Protokoll-Analysen damit, dass jeder nachträgliche Ausschluss die Randomisierung entwertet. Bei uns gibt es keine Randomisierung, die entwertet werden könnte – die Zuteilung war pragmatisch. Daraus folgt aber nicht, dass der Einwand entfällt, sondern dass er sich verschärft: Eine Per-Protokoll-Rechnung wäre bei uns eine zweite, individuelle Selektionsschicht über einer bereits nicht randomisierten Zuteilung auf Vereinsebene. Die Auswahl geschähe nach einem Merkmal – der selbstberichteten Adhärenz im unbeaufsichtigten Setting –, das plausibel mit Motivation und damit mit dem Ansprechen auf das Training zusammenhängt. Genau die Konstellation, vor der Box 6 warnt.

Der Preis in der Aussagekraft ist dagegen gering. Die folgende Rechnung folgt dem Verfahren aus § 3.2; die Kontrollgruppe bleibt bei $n = 11$, weil dort keine Adhärenzdaten erhoben wurden.

Tab. B. Minimal nachweisbarer Effekt bei schrittweiser Verkleinerung der Interventionsgruppe.

IG n	Sprint 10 m	Sprint 30 m	Standweitsprung	505 rechts	Verlust ggü. n = 17
17	0,52 (2,7×)	0,39 (1,9×)	0,56 (2,9×)	0,96 (5,0×)	—
15	0,54 (2,8×)	0,40 (2,0×)	0,57 (2,9×)	0,99 (5,2×)	+3,0 %
13	0,56 (2,9×)	0,42 (2,1×)	0,59 (3,1×)	1,03 (5,4×)	+6,8 %
11	0,58 (3,1×)	0,44 (2,1×)	0,62 (3,2×)	1,08 (5,6×)	+11,8 %
9	0,62 (3,2×)	0,46 (2,3×)	0,66 (3,4×)	1,15 (6,0×)	+18,7 %

MDES d, in Klammern das Vielfache des SESOI. Zwei Kovariaten, $\alpha = 0,05$ zweiseitig, Power = 0,80, ohne Kovariaten-Inflation.

Das ist ein Befund, der die Argumentation ändert. Der Einwand gegen eine Per-Protokoll-Rechnung ist bei uns kein Power-Argument: Vier ausgeschlossene Spieler kosten rund sieben Prozent MDES, was gegenüber dem Zwei- bis Fünffachen des SESOI nichts entscheidet. Der Einwand ist ein Verzerrungsargument – und zwar das von Box 6 benannte. In 4.7 und 6.2 ist er deshalb so und nicht anders zu führen. Wer ihn als Fallzahlargument vorträgt, verliert ihn, sobald jemand nachrechnet.

Zwei Festlegungen, die daraus folgen

- Fehlende Post-Werte dürfen nicht durch Fortschreibung des Prä-Werts ersetzt werden. Box 6 kritisiert „last observation carried forward“ ausdrücklich als verzerrend und als Verfahren, das die Unsicherheit der Imputation verschweigt. Bei uns wäre der Effekt zusätzlich systematisch: Fortgeschriebene Prä-Werte bedeuten „keine Veränderung“ und ziehen jede Gruppendifferenz gegen null – bei einer erwarteten Nullhypothese wäre das eine Bestätigung der eigenen Erwartung durch das Auffüllverfahren.
- Die Mindestdosis einer etwaigen Per-Protokoll-Rechnung ist vor Sichtung der Post-Werte festzulegen und in 4.7 zu dokumentieren. Wird sie danach gewählt, ist sie eine Auswahl am Ergebnis – dieselbe Logik, aus der in § 11.6 der Projektanweisungen bereits die nachträgliche Wahl einer Wenderichtung ausgeschlossen ist.

3 Die Fallzahlbegründung (Item 7a)

3.1 Was CONSORT verlangt – und was nicht

Item 7a lautet „How sample size was determined“ – wie die Fallzahl zustande kam, nicht: wie sie berechnet wurde. Eine formale Rechnung ist ein möglicher Weg, kein verpflichtender. Ausdrücklich verlangt wird, dass ein Abweichen der erreichten von der geplanten Fallzahl erklärt wird.

Für uns heißt das: Die wahrheitsgemäße Antwort ist, dass die Fallzahl durch die teilnehmenden Vereine vorgegeben war und sich durch den Ausfall von SC West vor Studienbeginn von einem geplanten Verhältnis 2 : 1 auf 1,4 : 1 verschob. Diese Auskunft erfüllt Item 7a. Eine nachträglich konstruierte A-priori-Poweranalyse würde es nicht besser erfüllen, sondern schlechter – sie behauptete eine Planung, die es nicht gab.

Korrektur der Ausgangsannahme: Es fehlt uns nicht die Analyse, welche die nötige Stichprobengröße bestimmt. Verfahren und Begründung stehen seit Fassung 5 in den Projektanweisungen (§ 11.1: Ressourcenbegründung nach Lakens 2022 plus Sensitivitäts-Poweranalyse je Zielgröße). Was fehlt, ist die Durchführung – 4.7 ist leer und Anhang G existiert nicht. Der Rest dieses Abschnitts schließt genau diese Lücke.

CONSORT stützt das gewählte Verfahren an zwei Stellen zusätzlich:

- Post-hoc-Power ist untauglich: „There is little merit in a post hoc calculation of statistical power using the results of a trial; the power is then appropriately indicated by confidence intervals“ (Item 7a). Das ist zugleich die Begründung dafür, warum die Präzision der Ergebnisse über Konfidenzintervalle zu berichten ist (§ 3.6) – und ein Argument, das gegenüber Schwab besser trägt als Lakens allein, weil es aus der Berichtsnorm selbst stammt.
- Der erwartbare Fehlschluss ist benannt: „Reports of studies with small samples frequently include the erroneous conclusion that the intervention groups do not differ, when in fact too few patients were studied to make such a claim“ (Item 7a). Bei unseren Erwartungswerten ist das der wahrscheinlichste Fehler unserer eigenen Diskussion.

3.2 Rechenweg

Verfahren: Sensitivitäts-Poweranalyse. Bei fester Fallzahl, festem α und fester Power wird die minimal nachweisbare Effektgröße (MDES) bestimmt. Die Effektgröße ist damit Ergebnis der Rechnung, nicht deren Eingangsgröße.

Größe	Wert und Herkunft
Testfamilie / Test	F-Tests · ANCOVA: Fixed effects, main effects and interactions (G*Power-Bezeichnung)
Modell	Post ~ Gruppe + Baseline + %PAH
Numerator df	1 (zwei Gruppen)
Gruppen / Kovariaten	2 / 2
n je Gruppe	IG 17 · KG 11 (analysierbares N mit %PAH-Kovariate = 28)
Denominator df	$N - \text{Gruppen} - \text{Kovariaten} = 28 - 2 - 2 = 24$
α	0,05, zweiseitig
Power	0,80
R ² der Kovariaten	nicht frei gewählt, sondern je Zielgröße aus der eigenen Messgüte abgeleitet (s. u.)
Software	Berechnung in Python 3.11 über die nichtzentrale F-Verteilung (SciPy 1.17.1). In G*Power (Version eintragen) exakt reproduzierbar; Skript und Ausgabe liegen als Anhang G bei.

Ableitung des R^2

Die Prädiktionsgüte der Baseline-Kovariate ist keine freie Annahme, sondern nach oben begrenzt durch die Reliabilität des jeweiligen Tests. Aus der klassischen Testtheorie folgt mit dem typischen Messfehler TE und der Zwischen-Athleten-Standardabweichung SD:

$$\text{rel} = 1 - \text{TE}^2 / \text{SD}^2 \quad \text{und daraus} \quad R^2_{\text{max}} = \text{rel}^2$$

Beide Größen liegen im Blatt 04_Kennwerte vor. Weil rel der Within-Session-Wert ist, die tatsächliche Prä-Post-Korrelation über neun bis elf Wochen aber niedriger ausfällt, ist R^2_{max} eine Obergrenze – und der damit berechnete MDES entsprechend eine Untergrenze. Die Studie ist also in Wirklichkeit eher unempfindlicher als hier ausgewiesen, nicht empfindlicher.

3.3 Ergebnis: minimal nachweisbarer Effekt je Zielgröße

Tab. 1. Sensitivitäts-Poweranalyse. $n = 17 / 11$, zwei Kovariaten, $\alpha = 0,05$ zweiseitig, Power = 0,80. Werte im günstigsten Fall ($R^2 = R^2_{\text{max}}$).

Zielgröße	SD	TE	SESOI	R^2_{max}	MDES d	MDES roh	MDES / SESOI
Sprint 5 m (s)	0,08	0,046	0,016	0,448	0,84	0,067	4,2
Sprint 10 m (s)	0,11	0,037	0,021	0,787	0,52	0,057	2,7
Sprint 30 m (s)	0,31	0,077	0,063	0,880	0,39	0,121	1,9
Standweitsprung (cm)	17	6,1	3,3	0,759	0,56	9,43	2,9
505 links (s)	0,11	0,089	0,023	0,119	1,06	0,117	5,1
505 rechts (s)	0,12	0,083	0,023	0,272	0,96	0,116	5,0

MDES roh = MDES d $\times$ SD. SESOI = $0,2 \times \text{SD}$ (Hopkins, 2000). Die letzte Spalte ist die entscheidende: Der kleinste Effekt, den die Studie mit 80 % Wahrscheinlichkeit als signifikant erkennen würde, ist das Zwei- bis Fünffache des kleinsten Effekts, den wir überhaupt für bedeutsam halten.

Achtung vor einer Verwechslung, die in § 11.3 der Projektanweisungen angelegt ist. Dort steht zu Recht: $\text{TE}/\sqrt{n}$ liegt bei allen Zielgrößen unter dem SESOI, Gruppenvergleiche sind also tragfähig. Das ist eine Aussage über die Messpräzision des Gruppenmittelwerts – und sie bleibt richtig. Sie ist keine Aussage über statistische Aussagekraft. Für den 10-m-Sprint beträgt $\text{TE}/\sqrt{n} \div \text{SESOI} = 0,31$, $\text{MDES} \div \text{SESOI}$ dagegen 2,7. Der Unterschied liegt darin, dass in den MDES die Streuung zwischen den Spielern eingeht, nicht nur der Messfehler. Beide Kennwerte gehören nebeneinander in 4.7, sonst liest sich § 11.3 als Beleg für eine Aussagekraft, die nicht besteht.

3.4 Zusatzkorrektur: das Kovariaten-Ungleichgewicht

G*Power berücksichtigt Kovariaten nur über den Verlust an Freiheitsgraden. Das ist bei randomisierten Studien vertretbar, weil die Kovariaten dort im Mittel ausbalanciert sind. Bei uns sind sie es nicht: Die IG ist im Ausgangswert schneller ($d = -1,22$ bis $-1,68$) und reifer (%PAH $d = 1,57$). Das erhöht die Varianz der adjustierten Differenz:

$$\text{Var}(\text{adj. Differenz}) = \sigma^2_{\text{res}} \cdot [1/n_1 + 1/n_2 + Q]$$

$$Q (\text{eine Kovariate}) = d^2 / (N - 2) \quad \cdot \quad Q (\text{zwei Kovariaten}) = (d_1^2 - 2r \cdot d_1 \cdot d_2 + d_2^2) / [(1 - r^2)(N - 2)]$$

Mit $1/17 + 1/11 = 0,1497$ und den beobachteten Ungleichgewichten liegt Q in derselben Größenordnung wie der Basisterm. Der Standardfehler und damit der MDES erhöhen sich um den Faktor:

Tab. 2. Erhöhungsfaktor des Standardfehlers durch das Kovariaten-Ungleichgewicht, je nach der within-group-Korrelation r zwischen Ausgangswert und %PAH.

Zielgröße	r = -0,6	r = -0,4	r = -0,2	r = 0	r = +0,2	r = +0,4	MDES/ SESOI bei r = 0
Sprint 5 m	1,29	1,32	1,36	1,42	1,50	1,64	6,0
Sprint 10 m	1,30	1,33	1,37	1,43	1,52	1,66	3,9
Sprint 30 m	1,36	1,40	1,46	1,54	1,64	1,81	3,0
Standweitsprung	1,70	1,51	1,41	1,35	1,31	1,28	3,8
505 links	1,29	1,28	1,29	1,33	1,38	1,47	6,7
505 rechts	1,37	1,30	1,28	1,28	1,30	1,35	6,4

r ist die einzige Eingangsgröße dieser Tabelle, die nicht vorliegt. Sie ist aus Blatt 02_Rohdaten in einem Schritt zu berechnen: within-group-Pearson-Korrelation zwischen dem Prä-Bestwert der jeweiligen Zielgröße und %PAH, über beide Gruppen gepoolt (Abweichungen vom jeweiligen Gruppenmittel). Erst danach ist der Wert der Tabelle endgültig. Für zeitbasierte Zielgrößen ist ein negatives r zu erwarten (reifer → schneller → kleinere Zeit), für den Standweitsprung ein positives.

Das ist ein eigenständiger methodischer Befund und gehört in 6.1: Der Verzicht auf Randomisierung kostet uns nicht nur Interpretierbarkeit, er kostet auch Präzision. Weil die Cluster sich in Ausgangsleistung und Reifestatus systematisch unterscheiden, muss die ANCOVA stärker adjustieren, und der Standardfehler der adjustierten Differenz steigt um rund 30 bis 55 Prozent. Die Aussage „ANCOVA adressiert die Baseline-Unterschiede“ ist richtig, aber sie ist nicht kostenlos.

3.5 Sensitivität der Annahmen

Nach § 11.5 Punkt 2 der Projektanweisungen ist die Prä-Post-Korrelation über eine plausible Spanne zu variieren. Für den 10-m-Sprint (ohne Kovariaten-Inflation):

R ²	MDES d	MDES roh (s)	MDES / SESOI	Lesart
0,30	0,95	0,104	5,0	pessimistisch
0,50	0,80	0,088	4,2	
0,60	0,72	0,079	3,7	realistisch
0,70	0,62	0,068	3,2	
0,79	0,52	0,057	2,7	Obergrenze (Within-Session-Reliabilität)

Über die gesamte plausible Spanne bleibt der MDES beim Drei- bis Fünffachen des SESOI. Die Schlussfolgerung hängt also nicht an der Wahl von R². Das ist die eigentliche Aussage der Sensitivitätsanalyse und der Satz, der in 4.7 stehen sollte.

Zum Vergleich: Der Verzicht auf die %PAH-Kovariate (N = 31 statt 28, eine Kovariate statt zwei) senkt den MDES bei R² = 0,60 nur von d = 0,72 auf d = 0,67, also um 6,5 Prozent. Der Gewinn an Fallzahl wiegt den Verlust der Reifeadjustierung nicht auf – das beantwortet Schwab-Punkt 11 zugunsten der Beibehaltung der Kovariate.

3.6 Erwartete Präzision: die Konfidenzintervalle

CONSORT verweist für die Aussagekraft einer Studie ausdrücklich auf die Konfidenzintervalle statt auf Power. Mit t(0,975; 24) = 2,064 ergibt sich für die adjustierte Differenz:

Tab. 3. Erwartete Halbbreite des 95%-Konfidenzintervalls der adjustierten Gruppendifferenz.

Zielgröße	± ohne Q	± mit Q (r = 0)	SESOI	KI-Breite / SESOI
Sprint 5 m (s)	0,047	0,067	0,016	8,4
Sprint 10 m (s)	0,041	0,058	0,021	5,5

Zielgröße	± ohne Q	± mit Q (r = 0)	SESOI	KI-Breite / SESOI
Sprint 30 m (s)	0,086	0,131	0,063	4,2
Standweitsprung (cm)	6,66	8,97	3,30	5,4
505 links (s)	0,082	0,109	0,023	9,5
505 rechts (s)	0,082	0,105	0,023	9,1

Ein Konfidenzintervall von vier- bis neunfacher SESOI-Breite schließt praktisch bedeutsame Effekte in keine Richtung aus. Genau das ist der Satz, der bei jedem nicht signifikanten Ergebnis in Kapitel 5 und 6 stehen muss – und genau dieser Fehlschluss ist in Item 20 als der häufigste benannt.

3.7 Einordnung gegen die Literaturerwartung

Die folgenden Werte sind Einordnungsmaßstab, nicht Eingangsgröße der Poweranalyse – die Unterscheidung ist in § 11.1 der Projektanweisungen verbindlich und hier eingehalten. Angegeben ist, welche Power die Studie hätte, wenn der jeweils dokumentierte Effekt zuträfe.

Tab. 4. Power bei den dokumentierten Vorab-Erwartungen.

Erwartungsquelle	d	Power ohne Q	Power mit Q (r = 0)
Lloyd et al. (2016), 10 m, exakt unsere Dosis	0,06	0,06	0,06
Ramirez-Campillo et al. (2020), 10 m, ≤ 7 Wo. / ≤ 14 Einheiten	0,11	0,09	0,07
Moran et al. (2017), CMJ, < 14,5 Einheiten	0,37	0,46	0,28
Moran et al. (2017), CMJ, < 7,5 Wochen	0,38	0,48	0,30
Ramirez-Campillo et al. (2020), 10 m, > 7 Wochen	0,93	> 0,99	0,94

Das ist die härteste Zahl dieses Dokuments. Limitation Nr. 1 der Projektanweisungen lautet bisher „Sprint vermutlich unterpower“. Sie ist damit beziffert: Trifft die dosisnächste Erwartung zu, liegt die Wahrscheinlichkeit eines signifikanten Sprintbefunds bei 6 bis 9 Prozent. Das Wort „vermutlich“ kann entfallen.

Für den Standweitsprung ist die Lage weniger eindeutig: Bei der metaanalytischen Erwartung von d = 0,37 bis 0,38 liegt die Power zwischen 28 und 48 Prozent – unzureichend, aber nicht aussichtslos. Der Standweitsprung ist damit die einzige Zielgröße, die als primäre Zielgröße überhaupt in Betracht kommt (Schwab-Punkt 1).

3.8 Welche Fallzahl nötig wäre

Für Kapitel 7.2. Balanciertes Design, zwei Kovariaten, $\alpha = 0,05$, Power = 0,80, ohne Kovariaten-Inflation – also die Fallzahl, die eine sauber randomisierte Nachfolgestudie bräuchte.

Tab. 5. Erforderliches Gesamt-N.

Zielgröße	R ²	für d = 0,20 (SESOI)	für d = 0,37	für d = 0,50
Sprint 5 m	0,448	436	129	72
Sprint 10 m	0,787	170	52	30
Sprint 30 m	0,880	96	30	18
Standweitsprung	0,759	192	58	33
505 links	0,119	694	204	113
505 rechts	0,272	574	169	94

Zwei Folgerungen für den Ausblick. Erstens: Ein Nachweis auf SESOI-Niveau ist im 505 mit realistischen Vereinsstichproben nicht zu führen – nicht wegen der Fallzahl allein, sondern weil die geringe Reliabilität ($R^2 = 0,12$ bis $0,27$) den Bedarf vervielfacht. Der Hebel liegt dort in der Messgüte, nicht in der Rekrutierung. Zweitens: Für den 30-m-Sprint und den Standweitsprung liegen die Fallzahlen in einer Größenordnung, die ein Verband oder ein Verbund mehrerer Vereine erreichen kann. Das ist eine konkrete, belegte Empfehlung statt der üblichen Formel „weitere Forschung ist nötig“.

3.9 Offene Eingangsgrößen

5. Die within-group-Korrelation r zwischen Ausgangswert und %PAH je Zielgröße (Blatt 02_Rohdaten). Bis dahin bleibt Tab. 2 eine Spanne.
6. Die endgültigen n je Zielgröße nach Eintragung der Post-Werte. Die Rechnung ist mit den tatsächlichen n zu wiederholen; das Skript ist parametrisiert.
7. Die Versionsnummern von G*Power und SPSS für die Berichtspflicht nach § 11.4.
8. Entscheidung Schwab zur primären Zielgröße – sie bestimmt, welche Zeile aus Tab. 1 in 4.7 die tragende ist.

4 Vorschlagsliste

Nach der Prozessregel (§ 1.2) als nummerierte Vorschläge zur Begutachtung, nicht als Einbau. Fundstelle, Vorschlag, Begründung.

4.1 Neu zu schreibender Text

Nr.	Fundstelle	Vorschlag	Begründung
1	4.7, neuer Absatz	Absatz „Fallzahlbegründung“: Ressourcenbegründung (Vereine geben die Fallzahl vor; SC West fiel vor Studienbeginn aus, Verhältnis 2:1 → 1,4:1), gefolgt von der Sensitivitätsanalyse mit MDES je Zielgröße, den Berichtsgrößen nach § 11.4 und dem Verweis auf Anhang G. Zielumfang 180–220 Wörter.	CONSORT Item 7a. Erfüllt zugleich § 11.1 der Projektanweisungen, der bisher nur beschrieben, nie ausgeführt war.
2	4.7, Anschlussabsatz	Absatz „Präzision“: TE//n gegen SESOI (Messpräzision des Gruppenmittelwerts) UND MDES gegen SESOI (statistische Auflösung) nebeneinander, mit dem Satz, dass beide verschiedene Fragen beantworten. Zielumfang 90–110 Wörter.	Verhindert die in § 3.3 beschriebene Verwechslung. Ohne diesen Absatz liest sich § 11.3 als Beleg für eine Aussagekraft, die nicht besteht.
3	4.1, ein Satz	„Die Studie wurde nicht in einem Studienregister registriert. Das Untersuchungsvorhaben wurde vor Beginn der Datenerhebung der Ethikkommission der Deutschen Sporthochschule Köln vorgelegt und unter der Nummer 157/2026 positiv beschieden; der Antrag liegt als Anhang E bei.“	CONSORT Item 23 verlangt bei fehlender Registrierung die ausdrückliche Feststellung samt Grund. Item 24 wird durch den Verweis auf den Ethikantrag als Protokoll miterfüllt.
4	4.1, ein Satz	Ergänzung im Absatz zur Zuteilung: Die Festlegung vor den Eingangstestungen und die Unkenntnis der Mannschaften bis zu deren Abschluss ausdrücklich als funktionales Äquivalent der Zuteilungsverbergung benennen – mit dem Zusatz, dass sie die Randomisierung nicht ersetzt.	CONSORT Item 9 trennt Verbergung (schützt vor der Zuteilung, immer umsetzbar) von Verblindung (schützt danach). Unsere Stärke ist die erste, nicht die zweite. Ohne die Trennung wirkt das Argument stärker, als es ist.
5	4.3 oder 6.2	Verblindungsstatus rollenweise angeben statt pauschal: Teilnehmer und Trainerteams nicht verblindet, Testleiter und Datenerheber in Personalunion und nicht verblindet, Auswertung ebenfalls durch den Verfasser.	CONSORT Item 11a fordert ausdrücklich die Aufgabe der Sammelbegriffe zugunsten der Rollennennung. Item 10 verlangt zusätzlich die Offenlegung, dass Zuteilung, Einschluss und Testung nicht getrennt waren.
6	5.1	Absatz zu unerwünschten Effekten: 12 Schmerzmeldungen, Lokalisation, zwei schmerzbedingte Abbrüche, absolute Häufigkeiten; dazu die Feststellung, dass für die KG kein Erfassungsinstrument bestand.	CONSORT Item 19. Bisher in keiner Kapitelplanung vorgesehen, obwohl die Daten vorliegen.
7	Vorspann	Ein Satz zur Förderung: keine Drittmittel, Messtechnik durch die DSHS gestellt, keine Beteiligung Dritter an Design, Auswertung oder Berichterstattung.	CONSORT Item 25.
8	6.1	Absatz zum Preis der nicht randomisierten Zuteilung: Weil sich die Cluster in Ausgangsleistung und Reifestatus systematisch unterscheiden, erhöht die notwendige Adjustierung den Standardfehler der adjustierten Differenz um rund 30 bis 55 Prozent. Die ANCOVA adressiert die Baseline-Unterschiede,	Eigener Befund aus § 3.4. Bislang steht in Limitation 2 nur, dass die ANCOVA die Unterschiede „adressiert“ – der Präzisionsverlust ist nirgends benannt.

Nr.	Fundstelle	Vorschlag	Begründung
		aber nicht kostenlos.	
9	7.2	Konkrete Fallzahlempfehlung statt „weitere Forschung ist nötig“: $N \approx 96$ (30 m) bzw. 192 (Standweitsprung) für einen Nachweis auf SESOI-Niveau; für den 505 liegt der Hebel in der Messgüte, nicht in der Rekrutierung.	Tab. 5. Macht aus einer Leerformel eine belegte Aussage.
10	4.7, neuer Absatz	Absatz „Analysepopulation“: die vier Ausschlussklassen aus § 2.4 benennen, je Klasse die betroffenen Fälle und die Behandlung. Ausdrücklich: BW-11 neu bleibt in jeder Analyse; eine etwaige Per-Protokoll-Rechnung wird als nicht randomisierter, beobachtender Vergleich gekennzeichnet; die Mindestdosis dafür steht vor Sichtung der Post-Werte fest. Zielumfang 150–180 Wörter.	CONSORT Item 16 und Box 6 (S. 17). Ersetzt die Etikettenfrage „ITT oder Per-Protokoll“ durch die von CONSORT 2010 verlangte Beschreibung, wer in welche Analyse eingeht.
11	4.7, ein Satz	Ausschluss der Fortschreibung von Prä-Werten („last observation carried forward“) ausdrücklich festhalten, mit der Begründung, dass fortgeschriebene Werte „keine Veränderung“ bedeuten und jede Gruppendifferenz gegen null ziehen.	Box 6 kritisiert LOCF ausdrücklich. Bei einer erwarteten Nullhypothese wäre der Effekt bei uns systematisch in Richtung der eigenen Erwartung.
12	6.2	Die drei fehlenden %PAH-Werte nicht nur als Fallzahlverlust führen: Bei VS-18 liegt der Ausschlussgrund im Reifestatus selbst, also in der Adjustierungsvariablen. Zwei der drei Fälle stammen aus der KG.	Box 6: Verzerrung entsteht, wenn der Ausfall mit dem Ansprechen zusammenhängt, und ist besonders kritisch, wenn sich die Ausfallursachen zwischen den Gruppen unterscheiden. Bisher ist der Punkt nur als $N = 28$ statt 31 vermerkt.

4.2 Zu ändernder Text und zu ändernde Regeln

Nr.	Fundstelle	Vorschlag	Begründung
13	Projektanweisungen § 4	Die Begründung für den Verzicht auf Baseline-Signifikanztests austauschen: nicht „weil Differenzen zufällig sind“ (gilt nur bei Randomisierung), sondern „weil der Test die falsche Frage beantwortet; maßgeblich sind Größe der Ungleichheit und prognostische Stärke“.	Siehe § 2.2. Die derzeitige Begründung ist für ein nicht randomisiertes Design sachlich falsch und wäre in der Verteidigung angreifbar.
14	Projektanweisungen § 12 Nr. 1	„Sprint vermutlich unterpower“ ersetzen durch die bezifferte Fassung: Power 6 bis 9 Prozent bei der dosisnächsten Erwartung ($d = 0,06$ bis $0,11$).	Tab. 4. „Vermutlich“ ist jetzt gerechnet.
15	Projektanweisungen § 11.5	Sensitivitätsanalyse 2 präzisieren: Variiert wird R^2 (0,30 bis 0,79), nicht die Prä-Post-Korrelation als solche; das Ergebnis ist, dass die Schlussfolgerung über die gesamte Spanne stabil bleibt.	Ergebnis aus § 3.5.
16	Projektanweisungen § 5, Objektzuordnung	Anhang G umbenennen von „G*Power-Protokoll“ in „Protokoll der Sensitivitäts-Poweranalyse“ und um das Rechenskript ergänzen.	Die Rechnung ist keine G*Power-Ausgabe, sondern reproduziert diese und geht mit der Kovariaten-Inflation darüber hinaus. § 11.4 verlangt einen dokumentierten Rechenweg.
17	Projektanweisung	Schwab-Punkt 2 umformulieren: Nicht „ITT oder	CONSORT Item 16 hat die

Nr.	Fundstelle	Vorschlag	Begründung
	ngen § 13, Punkt 2	Per-Protokoll“, sondern „beide berichten, Nenner und Ausschlussgründe je Analyse, Per-Protokoll ausdrücklich als nicht randomisierter beobachtender Vergleich gekennzeichnet“. Ergänzend die Klarstellung, dass der Einwand gegen die Per-Protokoll-Rechnung ein Verzerrungs- und kein Fallzahlargument ist (Tab. B).	Etikettenforderung 2010 bewusst gestrichen. Damit ist der Punkt keine Grundsatzentscheidung mehr, sondern eine Berichtsaufgabe. Die Präzisierung verhindert, dass das Argument in der Verteidigung an der Fallzahlrechnung scheitert.
18	Projektanweisungen § 13, Punkt 11	Zur Entscheidung vorlegen mit Empfehlung: %PAH-Kovariate beibehalten. Der Verzicht brächte N = 31 statt 28, senkt den MDES aber nur um 6,5 Prozent und kostet die Reifeadjustierung.	Ergebnis aus § 3.5.
19	Projektanweisungen § 13, Ergänzungen	Den Streitpunkt „unterschiedliche Behandlung von HL-04/BW-01 gegenüber BW-11 neu“ von der Liste nehmen und als entschieden führen: BW-11 neu bleibt in jeder Analyse, weil ein Instrumentenfehler nach Box 6 keine Protokollabweichung ist.	Der Punkt steht seit Rev. 15 als offen auf der Schwab-Liste. Die Quelle entscheidet ihn.
20	Projektanweisungen § 8	Zitierregel für die Quelle ergänzen: BMJ vergibt Artikelnummern; der vorliegende PDF-Seitenzähler „Page x of 28“ ist keine Zeitschriftenpaginierung. Stabile Fundstelle ist die Item-Nummer.	Zitierfalle, in T4 aufzunehmen.

4.3 Tabellenschablone für 5.2

CONSORT Item 17a verlangt je Zielgröße das Ergebnis in beiden Gruppen und die Effektschätzung mit Präzision. Die Vorlage der Quelle (Tab. 6, Item 17a) lässt sich unmittelbar übernehmen und erfüllt zugleich Item 16 (Nenner je Analyse) und Item 18 (adjustiert neben unadjustiert):

Zielgröße	IG prä M (SD)	IG post M (SD)	KG prä M (SD)	KG post M (SD)	Adjustierte Differenz (95 % KI)	p
Sprint 10 m (s), n = .../...						
505 links (s), n = .../...						
505 rechts (s), n = .../...						
Standweitsprung (cm), n = .../...						

Reihenfolge Sprint → Richtungswechsel → Sprung nach § 5 der Projektanweisungen. Die Nenner gehören nach Item 16 in die Zeile, weil sie zwischen den Zielgrößen variieren. Fußnote: welche Kovariaten adjustiert wurden. Die unadjustierten Differenzen nach Item 18 entweder als zusätzliche Spalte oder im Fließtext.

5 Was CONSORT für uns nicht leistet

Damit die Grenze klar ist und nichts überinterpretiert wird:

- CONSORT ist keine Qualitätsbewertung. Die Autoren sagen das ausdrücklich: Die Checkliste betrifft die Berichterstattung, nicht die Güte der Studie. Ein CONSORT-Score existiert nicht und wäre nicht vorgesehen – dieselbe Logik, die bei TESTEX bereits gilt.

- CONSORT ersetzt keine der Entscheidungen, die noch bei Schwab liegen. Es liefert Argumente für Punkt 1 (Mehrfachtestung), Punkt 2 (ITT) und Punkt 11 (%PAH), entscheidet aber keinen davon.
- Die Items 8a, 8b, 10 (in der Rollentrennung), 11b, 17b und 23 sind für unser Design ganz oder überwiegend gegenstandslos. Sie sind nicht zu „umgehen“, sondern schlicht nicht anwendbar – und das ist der Grund, warum durchgängig „in Anlehnung an“ berichtet wird.
- CONSORT deckt die Interventionsbeschreibung nur grob ab (Item 5). Die Replizierbarkeit trägt bei uns TIDieR, das über Item 5 deutlich hinausgeht. Die beiden Normen konkurrieren nicht.
- Für die inhaltliche Bewertung der Evidenz leistet CONSORT nichts. Das bleibt Aufgabe des Forschungsstand-Verfahrens nach § 6.4.

Rechenskripte und vollständige Ausgabe: mdes.py und mdes2.py, beigelegt. Alle Eingangsgrößen stammen aus Blatt 04_Kennwerte und § 3 der Projektanweisungen (Fassung 8). Keine Größe ist geschätzt; nicht vorliegende Größen sind als Gitter variiert.