

Korrelation, Überlappung, Streuung, Power

Statistik-Lehrgang II · 11.09.2026

Bachelorarbeit U15-Plyometrie · DSHS Köln · Arbeitsdokument, kein Manuskripttext

1 Datenlage: was „16 Spieler“ wirklich heißt

⚠ Vor jeder Löschung zu klären. Ohne Post-Werte sind es nicht zwei Spieler, sondern fünfzehn. Dreizehn davon sind die vollständige Kontrollgruppe, deren Testtermin am 15.09. noch bevorsteht. Hätte man „alle Spieler ohne Post-Werte“ aus dem Datenpool entfernt, wäre die Kontrollgruppe verschwunden und mit ihr die Studie.

Tab. 1. Post-Datenlage am 11.09.2026

Gruppe	Spieler	Post-Werte	Einordnung
Intervention	16 von 18	vorhanden	auswertbar
Intervention	BW-07 · BW-21	keine	bei der Testeinheit nicht anwesend — echter Ausfall
Kontrolle	13 von 13	keine	Termin 15.09.2026 steht aus — kein Ausfall

1.1 Warum die beiden Spieler nicht gelöscht, sondern gekennzeichnet wurden

Die Zeilen aus dem Workbook zu entfernen wäre der eine Eingriff, der der Arbeit schadet. Drei Gründe:

- Das Flussdiagramm in 5.1 verlangt für jede Stufe Zahl und Grund. Wer die Zeilen löscht, kann nicht mehr belegen, wie viele zugeteilt wurden und warum zwei fehlen.
- CONSORT Item 16 verlangt den Nenner je Analyse. Die richtige Angabe lautet: 18 zugeteilt, 16 ausgewertet, 2 nicht angetreten. Ohne die Zeilen ist die 18 nicht mehr belegbar.
- Die Ausfallquote ist berichtspflichtig (§ 12 Nr. 8). Sie beträgt 2 von 18, also 11,1 Prozent. Diese Zahl entsteht nur, wenn beide Spieler im Datensatz bleiben.

Umgesetzt wurde deshalb: Die Spalte Status in Blatt 01_Personen ist gefüllt — sie war bisher bei allen 31 Spielern leer und ist genau für diesen Zweck angelegt. BW-07 und BW-21 tragen jetzt „Post-Testung nicht angetreten – bei der Testeinheit nicht anwesend; kein Post-Wert, nicht auswertbar“, die Kontrollgruppe „Post-Testung ausstehend (Termin 15.09.2026)“, die übrigen sechzehn „ausgewertet“. Damit fallen die beiden Spieler aus jeder Auswertung heraus, bleiben aber für den Teilnehmerfluss dokumentiert.

Prüfung nach dem Eingriff: 16.048 Zellen gegen die Ausgangsdatei verglichen, null Abweichungen außer der Status-Spalte. 2.788 Formeln neu berechnet, null Fehler. Die Blätter 03_Analyse, 04_Kennwerte und 06_Überlappung liefern unverändert dieselben Werte.

2 ⚠ Korrektur: p-Wert und Konfidenzintervall lassen sich nicht vergleichen

In der Frage stand sinngemäß: *Beim 505 rechts liege der p-Wert von 0,023 außerhalb des Intervalls [0,069; 0,701] und sei deshalb signifikant; beim 30-m-Sprint liege der p-Wert von 0,094 innerhalb von [−0,057; 0,621] und sei deshalb nicht signifikant.*

Das Ergebnis stimmt zufällig, die Begründung nicht. Die beiden Zahlen stehen auf völlig verschiedenen Skalen und werden niemals miteinander verglichen. Das Konfidenzintervall liegt auf der Skala des Korrelationskoeffizienten und reicht von −1 bis +1. Der p-Wert ist eine Wahrscheinlichkeit und reicht von 0 bis 1. Dass 0,094 zahlenmäßig zwischen −0,057 und 0,621 fällt, ist reiner Zufall des Zahlenstrahls und bedeutet nichts.

2.1 Die richtige Regel

Man sieht nach, ob das Konfidenzintervall die NULL enthält. Null bedeutet: kein Zusammenhang. Enthält das Intervall die Null, ist ein Zusammenhang von null mit den Daten vereinbar — das Ergebnis ist nicht signifikant. Enthält es sie nicht, ist es signifikant.

Tab. 2. Beide Wege führen immer zum selben Ergebnis, weil sie aus derselben Rechnung stammen

Zielgröße	95%-KI	enthält die Null?	p	p < 0,05?	Urteil
505 rechts	0,069 bis 0,701	nein	0,023	ja	signifikant
505 links	0,068 bis 0,709	nein	0,023	ja	signifikant
Standweitsprung	0,076 bis 0,696	nein	0,020	ja	signifikant
Sprint 30 m	-0,057 bis 0,621	ja	0,094	nein	nicht signifikant
Sprint 10 m	-0,134 bis 0,571	ja	0,196	nein	nicht signifikant
Sprint 5 m	-0,135 bis 0,617	ja	0,179	nein	nicht signifikant

2.2 Und was „nicht signifikant“ hier NICHT heißt

Der Satz „damit steht die Reife nicht im Zusammenhang mit dem Ausgangswert“ ist zu stark. Das Intervall für den 30-m-Sprint reicht von -0,057 bis 0,621. Mit den Daten vereinbar ist also alles zwischen „gar kein Zusammenhang“ und „starker Zusammenhang“. Bei 29 Spielern ist das Intervall schlicht zu breit, um zu entscheiden. Die richtige Aussage lautet: Ein Zusammenhang ließ sich bei dieser Fallzahl nicht sichern — nicht: es gibt keinen.

Umgekehrt heißt $p < 0,05$ nicht „%PAH beeinflusst die Leistung“. Es heißt: Ein Zusammenhang von genau null wäre mit diesen Daten schwer vereinbar. Über die Ursache sagt das nichts, und über die Stärke nur das, was im Intervall steht. Für die Kovariatenentscheidung ist ohnehin keines von beidem maßgeblich — sie ist vorab und prognostisch begründet (§ 11.2).

3 Die Within-Group-Korrelation, Schritt für Schritt

3.1 Warum überhaupt zentrieren

Stellen Sie sich ein Streudiagramm vor: waagrecht der Reifestatus, senkrecht die 30-m-Zeit, 29 Punkte. Die Interventionsgruppe bildet eine Wolke oben rechts — reifer und schneller. Die Kontrollgruppe bildet eine Wolke unten links — weniger reif und langsamer.

Zieht man eine Gerade durch alle 29 Punkte, misst sie vor allem den Abstand zwischen den beiden Wolken, nicht den Zusammenhang in ihnen. Beim 5-m-Sprint beträgt diese unzentrierte Korrelation -0,507, die Within-Group-Korrelation dagegen nur -0,284. Die Differenz ist reiner Gruppeneffekt: Zwei Gruppen, die sich in beiden Größen unterscheiden, erzeugen eine Korrelation, auch wenn innerhalb der Gruppen gar keine bestünde.

Das Zentrieren schiebt beide Wolken übereinander, indem von jedem Wert der Mittelwert seiner eigenen Gruppe abgezogen wird. Danach liegen beide Wolken um den Nullpunkt. Übrig bleibt nur noch, wie die Punkte innerhalb ihrer Wolke streuen — und genau das ist die gesuchte Größe.

3.2 Warum nicht einfach die Mittelwerte korrelieren

Weil zwei Mittelwerte zwei Punkte sind. Durch zwei Punkte geht immer exakt eine Gerade; die Korrelation wäre rechnerisch immer +1 oder -1, ganz gleich wie die Daten aussehen. Es gibt keinen Freiheitsgrad und damit keine Information. Außerdem beantwortete das eine andere Frage — nämlich, ob Gruppen mit höherem Reifemittel besser abschneiden. Das ist eine Aussage über zwei Vereine, nicht über Spieler.

3.3 Warum „within group“, obwohl es zwei Gruppen sind

„Within“ ist der Gegenbegriff zu „between“, nicht die Angabe einer Anzahl. Die Gesamtstreuung eines Datensatzes zerfällt in zwei Teile: die Streuung zwischen den Gruppen und die Streuung innerhalb der Gruppen. Die Within-Group-Korrelation nutzt ausschließlich den zweiten Teil. Sie wird aus beiden Gruppen berechnet, beschreibt aber, was in jeder einzelnen passiert.

Das Zusammenlegen („poolen“) hat einen praktischen Grund: Getrennt gerechnet hätten wir zwei sehr ungenaue Schätzungen — beim 30-m-Sprint $-0,309$ aus 18 Spielern und $-0,348$ aus 11. Gepoolt ergibt sich eine Schätzung mit mehr Freiheitsgraden. Voraussetzung ist, dass der Zusammenhang in beiden Gruppen ähnlich ist; genau das prüft der Test auf Homogenität der Regressionssteigungen, der in § 11.2 ohnehin vorgeschrieben ist.

3.4 Wird eine Gerade durch alle Werte gezogen?

Ja — und das ist dasselbe wie zwei parallele Geraden. Nach dem Zentrieren wird eine einzige Gerade an alle 29 Punkte angepasst. Rechnerisch ist das identisch damit, in jede Gruppe eine eigene Gerade zu legen und beide zu zwingen, dieselbe Steigung zu haben. Die Geraden unterscheiden sich dann nur in der Höhe, nicht in der Neigung. Genau diese Annahme — eine gemeinsame Steigung, zwei Höhen — ist die Voraussetzung der ANCOVA.

4 Was „entlang der Regressionsgeraden verschieben“ heißt

Am Beispiel des 30-m-Sprints, gerechnet an den Prä-Werten, weil die Post-Werte der Kontrollgruppe noch fehlen. Der Rechenweg ist im Endmodell derselbe.

Schritt	Rechnung	Ergebnis
1 · gemeinsame Steigung	Summe($x \cdot y$) / Summe(x^2) der zentrierten Werte	$-0,0280$ s je %PAH-Punkt
2 · Ablesung	ein Prozentpunkt mehr Reife entspricht	$0,028$ s schnellerer 30-m-Zeit
3 · Gesamtmittel der Kovariate	alle 29 Spieler	$92,57$ %PAH
4 · Gruppenmittel	IG $94,31$ · KG $89,73$	IG liegt $1,74$ darüber, KG $2,85$ darunter
5 · IG verschieben	$4,5256 \text{ s} + (-1,7388 \times -0,0280)$	$4,5743 \text{ s}$
6 · KG verschieben	$4,9100 \text{ s} + (2,8452 \times -0,0280)$	$4,8302 \text{ s}$
7 · Differenz vorher	$4,5256 - 4,9100$	$-0,3844 \text{ s}$
8 · Differenz nachher	$4,5743 - 4,8302$	$-0,2559 \text{ s}$

So sieht man, was die Kovariate tut. Die Interventionsgruppe ist im Prä-Test $0,384$ s schneller. Ein Drittel dieses Vorsprungs — $0,128$ s — lässt sich rechnerisch darauf zurückführen, dass sie reifer ist. Nach der Adjustierung bleibt ein Vorsprung von $0,256$ s. Das Modell fragt: Wie schnell wären beide Gruppen, wenn sie denselben Reifestatus hätten? Und um das zu beantworten, muss es jede Gruppe rechnerisch auf den gemeinsamen Wert von $92,57$ schieben — die IG nach unten, die KG nach oben.

Und daher der Präzisionsverlust: Die Steigung von $-0,0280$ ist selbst nur geschätzt. Ihre Unsicherheit wird mit der Verschiebungstrecke multipliziert. Die KG muss um $2,85$ Punkte verschoben werden, die IG um $1,74$ — je länger die Strecke, desto mehr Unsicherheit kommt beim Vergleich an.

5 Überlappung: Muss sie vorliegen?

Nein. Die Daten sind in beiden Fällen verwendbar. Die Überlappung entscheidet nicht darüber, OB gerechnet werden kann, sondern darüber, WORAUF die Rechnung sich stützt.

	Überlappung vorhanden	Überlappung fehlt
Was das Modell tut	Es rechnet zwischen gemessenen Werten — Interpolation	Es rechnet über den gemessenen Bereich hinaus — Extrapolation
Worauf es sich stützt	auf Daten, die es beide Gruppen betreffend gibt	auf die Annahme, dass die Gerade jenseits der Daten weiterläuft
Prüfbar?	ja, an den Daten	nein — dort liegen keine Daten
Konsequenz bei uns	inferenzstatistische Aussage zulässig	nur deskriptiver Bericht (§ 11.9)

Anschaulich am 5-m-Sprint: Zwölf der achtzehn IG-Spieler waren schneller, als der schnellste Spieler der Kontrollgruppe je gelaufen ist. Für diese zwölf gibt es in der KG keinen einzigen vergleichbaren Fall. Das Modell müsste behaupten, wie ein Kontrollgruppenspieler dieser Geschwindigkeit sich verhalten hätte — und es gibt keinen, an dem sich das prüfen ließe. Die Zahl, die dabei herauskäme, wäre nicht falsch berechnet, sie wäre unbelegt. Deshalb wird der 5-m-Sprint deskriptiv berichtet und nicht gelöscht.

6 Der SESOI bei Hopkins: Zweck und Nutzen

Geprüft am Volltext von Hopkins (2000), Sports Medicine 30(1), 1–15. Der Begriff „SESOI“ kommt dort nicht vor; Hopkins schreibt durchgehend „smallest worthwhile effect“.

6.1 Wozu Hopkins die Größe einführt

Nicht als Schwelle für „wirklich passiert“, sondern als Planungsmaß für ausreichende Genauigkeit:

“I advocate a new approach to sample size estimation, in which sample size is chosen to give adequate precision for an outcome. Precision is defined by confidence limits: the range within which the true value of the outcome is 95% likely to occur. Adequate precision means that the outcome has no substantial change in impact on an individual volunteer over the range of values represented by the confidence limits.”

Hopkins (2000), S. 7

Übersetzt: Der kleinste lohnende Effekt ist die Spanne, innerhalb derer es gleichgültig ist, wo die Wahrheit liegt. Ist das Konfidenzintervall schmäler als diese Spanne, ist die Studie entschieden — egal welcher Wert im Intervall zutrifft, die praktische Konsequenz ist dieselbe. Ist es breiter, ist sie es nicht.

6.2 Woher der Wert 0,2 kommt — und dass er nicht von Hopkins stammt

“When interest centres on experiments involving the average person in a population, Cohen argued that clinical judgement should be guided by the spread of raw scores (not change scores) in the population, and suggested that the smallest worthwhile value of d is 0.2 of the between-subject standard deviation.”

Hopkins (2000), S. 8

⚠ Zwei Auflagen folgen daraus, beide bereits in § 11.3: Erstens ist die Regel Cohens und bis zur Beschaffung von Cohen (1988) als Sekundärzitat zu führen. Zweitens nennt Hopkins auf derselben Seite einen ANDEREN Maßstab für Athleten — „In research on factors affecting athletic performance, d is about half the typical error of an athlete’s performance between races“ (S. 8). Wir verwenden den Populationsmaßstab für eine Athletenstichprobe; das ist zulässig, aber begründungspflichtig, und Hopkins liefert die Begründung nicht.

6.3 Wozu wir ihn brauchen

- Als Maßstab für die Messgüte: Der typische Messfehler wird gegen ihn gestellt. Liegt er darüber, kann der Test kleine Veränderungen nicht auflösen (§ 11.3 und die Sensitivitätsregel nach Sammoud et al., 2021).
- Als Maßstab für die Aussagekraft: Der kleinste nachweisbare Effekt und die Breite des Konfidenzintervalls werden in Vielfachen des SESOI ausgedrückt. Das ist genau die von Hopkins vorgesehene Verwendung.
- Als Eingangsgröße der Fallzahlrechnung: Hopkins gibt für eine Studie mit Kontrollgruppe $4n = 32 \frac{s^2}{d^2}$ an, mit s als typischem Messfehler und d als kleinstem lohnenden Effekt.

Nützlich für Kapitel 6.2 und 7.2 ist zudem diese Stelle:

"The resulting sample sizes are often beyond the resources or inclination of researchers, but studies with smaller sample sizes nevertheless produce confidence limits that are more useful than nothing at all. These studies should therefore be published, perhaps designated as pilot studies, so they can be included in meta-analyses."

Hopkins (2000), S. 7

Das ist eine zitierfähige Verteidigung unserer Fallzahl — aus der Quelle, auf die sich unsere Messgütekennwerte ohnehin stützen, und ohne die Schwäche kleinzureden.

7 Standardabweichung: was sie ist und was unsere Werte sagen

Die Standardabweichung beschreibt, wie weit die Einzelwerte typischerweise vom Mittelwert entfernt liegen. Sie hat dieselbe Einheit wie die Messgröße — bei %PAH also Prozentpunkte.

Tab. 3. Rechenweg an der Interventionsgruppe, %PAH, n = 18

Schritt	Rechnung	Ergebnis
1 · Mittelwert	1697,564 geteilt durch 18	94,3091
2 · Abweichungen	jeder Wert minus Mittelwert	–7,658 bis +3,878
3 · quadrieren und summieren	Vorzeichen fallen weg, große Abweichungen zählen stärker	142,7285
4 · Varianz	142,7285 geteilt durch (18 – 1)	8,3958
5 · Standardabweichung	Wurzel aus der Varianz, zurück in die Ausgangseinheit	2,8975

Warum durch n – 1 und nicht durch n: Weil der Mittelwert aus denselben Daten geschätzt wurde. Er liegt zwangsläufig so, dass die Abweichungen möglichst klein ausfallen. Ohne die Korrektur würde die Streuung systematisch unterschätzt.

Faustregel und Prüfung an unseren Daten: Bei annähernd glockenförmiger Verteilung liegen rund zwei Drittel der Werte im Bereich Mittelwert plus/minus eine Standardabweichung. Für die Interventionsgruppe heißt das 91,41 bis 97,21 — tatsächlich liegen dort 14 von 18 Spielern, also 78 Prozent. Für die Kontrollgruppe 86,94 bis 92,51 mit 7 von 11, also 64 Prozent. Beides passt zur Erwartung.

7.1 Was „anderthalb Standardabweichungen Unterschied“ bedeutet

Schritt	Rechnung	Ergebnis
Streuung IG	SD aus 18 Werten	2,8975
Streuung KG	SD aus 11 Werten	2,7850
gepoolte Streuung	beide zusammengefasst, nach Fallzahl gewichtet	2,8564
Differenz der Mittelwerte	94,3091 – 89,7251	4,5840
standardisierte Differenz d	4,5840 geteilt durch 2,8564	1,6048

Anschaulich: Der Abstand zwischen den Gruppenmittelwerten ist etwa anderthalbmal so groß wie die typische Streuung innerhalb einer Gruppe. Zum Vergleich: Ein d von 0,2 gilt als klein, 0,5 als mittel, 0,8 als groß. Ein d von 1,60 ist sehr groß — die beiden Gruppen sind im Reifestatus deutlich verschiedene Kollektive. Genau deshalb ist die Adjustierung nötig, und genau deshalb kostet sie Präzision.

Verbindung zum SESOI: Der SESOI ist als $0,2 \times \text{Standardabweichung}$ definiert. Ein SESOI entspricht also genau einem d von 0,2. Beide Größen stehen auf derselben Skala, nur in verschiedenen Einheiten. Wer den kleinsten nachweisbaren Effekt als $d = 0,73$ angibt, sagt damit zugleich: das ist das 3,6-Fache des SESOI.

8 Poweranalyse: welche Fallzahl für welchen Effekt

Gerechnet über die nichtzentrale t-Verteilung, $\alpha = 0,05$ zweiseitig, Power 0,80, zwei Kovariaten. Die Erklärungskraft des Modells (R^2) stammt je Zielgröße aus der eigenen Messgüte.

8.1 Bei unserer Fallzahl: was wäre nachweisbar?

Tab. 4. Kleinster mit 80 % Power nachweisbarer Effekt · Stand 11.09.2026, IG 18

Zielgröße	n IG/KG	R^2	MDES d	in SESOI	in Messeinheiten
Sprint 30 m	18 / 11	0,881	0,54	2,7	0,168 s
Sprint 10 m	18 / 11	0,777	0,71	3,6	0,076 s
Standweitsprung	18 / 11	0,744	0,73	3,6	12,0 cm
505 rechts	17 / 11	0,245	1,31	6,6	0,153 s
505 links	17 / 10	0,155	1,33	6,7	0,152 s
Sprint 5 m	18 / 7	0,435	1,42	7,1	0,113 s

Lesart: Beim Standweitsprung wären 12 cm nachweisbar. Der kleinste Unterschied, den wir für bedeutsam halten, sind 3,3 cm. Alles zwischen 3,3 und 12 cm bliebe unentdeckt, obwohl es praktisch relevant wäre. Der 30-m-Sprint ist mit dem 2,7-Fachen des SESOI die günstigste Zielgröße, der 5-m-Sprint mit dem 7,1-Fachen die ungünstigste.

8.2 Umgekehrt: wie viele Spieler bräuchte man?

Tab. 5. Erforderliches Gesamt-N bei ausgeglichenen Gruppen und ausgeglichenen Kovariaten

Zielgröße	1 SESOI	1,5 SESOI	2 SESOI	2,5 SESOI	3 SESOI	4 SESOI
Sprint 30 m	96	44	26	18	14	10
Sprint 10 m	178	80	46	32	22	14
Standweitsprung	204	92	54	36	26	16
Sprint 5 m	446	200	114	74	52	30
505 rechts	596	266	152	98	68	40
505 links	666	298	168	110	76	44

Zwei Folgerungen für Kapitel 7.2. Erstens: Für den 30-m-Sprint und den Standweitsprung liegen die Fallzahlen in einer Größenordnung, die ein Verband oder ein Vereinsverbund erreichen kann — 96 beziehungsweise 204 Spieler für einen Effekt in SESOI-Größe. Das ist eine belegte Empfehlung statt der Floskel „weitere Forschung ist nötig“. Zweitens: Beim 505 liegt der Hebel nicht in der Rekrutierung, sondern in der Messgüte. Dort wären fast 700 Spieler nötig, weil die Erklärungskraft des Modells bei 0,155 liegt. Ein zweiter Messtermin mit mehr Versuchen würde mehr bringen als hundert zusätzliche Spieler.

8.3 Power bei den dokumentierten Vorab-Erwartungen

Tab. 6. Wie wahrscheinlich wäre es, den erwarteten Effekt zu finden?

Erwartungsquelle	d	geprüft an	Power
Lloyd et al. (2016), 10 m, exakt unsere Dosis	0,06	Sprint 10 m	0,06
Ramirez-Campillo et al. (2020), 10 m ≤ 7 Wo.	0,11	Sprint 10 m	0,07
Moran et al. (2017), CMJ < 14,5 Einheiten	0,37	Standweitsprung	0,30
Moran et al. (2017), CMJ < 7,5 Wochen	0,38	Standweitsprung	0,31

Erwartungsquelle	d	geprüft an	Power
Ramirez-Campillo et al. (2020), 30 m ≤ 7 Wo.	0,68	Sprint 30 m	0,94
Ramirez-Campillo et al. (2020), 10 m > 7 Wo.	0,93	Sprint 10 m	0,96

Das ist die Zahl für § 12 Nr. 1. Bei der dosisnächsten Erwartung liegt die Wahrscheinlichkeit, den Effekt zu finden, bei 6 bis 7 Prozent. Ein Nullbefund beim Sprint ist damit erwartbar und kein Beleg für Unwirksamkeit. Beim Standweitsprung liegt sie bei rund 30 Prozent — besser, aber ebenfalls nicht ausreichend. Nur für die beiden großen Erwartungswerte über 0,68 wäre die Studie ausreichend ausgestattet.

⚠ Abgrenzung, die in 4.7 stehen muss: Diese Rechnung ist eine Sensitivitätsanalyse und keine nachträgliche Poweranalyse. Sie verwendet keine beobachteten Effekte, sondern vorab dokumentierte Literaturerwartungen und die feste Fallzahl. Eine Post-hoc-Power aus dem eigenen Ergebnis wäre nach CONSORT Item 7a ausdrücklich wertlos.