

Überlappung, Kovariate und die Frage „hat %PAH Einfluss?“

Statistik-Lehrgang · 11.09.2026, Fassung 2 (Abschnitt 5 korrigiert)

Bachelorarbeit U15-Plyometrie · DSHS Köln · Arbeitsdokument, kein Manuskripttext

Anlass. Die Frage lautete: Wenn zwischen Interventions- und Kontrollgruppe eine Überlappung besteht — darf man dann annehmen, dass die Kovariate %PAH keinen Einfluss auf die Leistungsdaten hatte? Die kurze Antwort ist nein, und unsere eigenen Daten liefern das Gegenbeispiel. Der Grund dafür ist lehrreich und betrifft drei Begriffe, die im Alltag gern zusammenfallen, statistisch aber streng zu trennen sind.

1 Drei Dinge, die auseinandergehalten werden müssen

Fast alle Missverständnisse in dieser Frage entstehen daraus, dass drei verschiedene Eigenschaften mit demselben Wort beschrieben werden.

Begriff	Was er beschreibt	Kennzahl	Beantwortet die Frage
Unterschied	Wie weit die Gruppenmittelwerte auseinanderliegen	d	Sind die Gruppen im Mittel verschieden?
Überlappung	Ob sich die Wertebereiche beider Gruppen decken	Anteil im gemeinsamen Bereich	Kann ich überhaupt vergleichen, ohne zu extrapolieren?
Zusammenhang	Wie stark eine Variable die Zielgröße vorhersagt	r bzw. Regressionssteigung	Wirkt sie?

Diese drei sind logisch unabhängig voneinander. Zwei Gruppen können sich vollständig überlappen und trotzdem deutlich unterschiedliche Mittelwerte haben. Eine Variable kann vollständig überlappen und trotzdem stark mit der Leistung zusammenhängen. Und umgekehrt. Aus der Überlappung folgt weder etwas über den Unterschied noch etwas über den Zusammenhang.

2 Es gibt bei uns zwei verschiedene Überlappungen

Die ANCOVA lautet $\text{Post} \sim \text{Gruppe} + \text{Ausgangswert} + \% \text{PAH}$. Sie enthält zwei Kovariaten, und jede hat ihre eigene Überlappungsfrage. Beide stehen in den Projektanweisungen, aber in verschiedenen Abschnitten — sie werden leicht verwechselt.

Tab. 1. Überlappung der Kovariate %PAH · Stand 11.09.2026, n = 18/11

Gruppe	n	Bereich	Mittel	im gemeinsamen Bereich 86,65–95,02
Intervention	18	86,65–98,19	94,31	10 von 18 (56 %)
Kontrolle	11	85,92–95,02	89,73	10 von 11 (91 %)

Lesart: Acht der achtzehn IG-Spieler liegen mit ihrem Reifestatus über dem höchsten Wert, den die Kontrollgruppe überhaupt erreicht. Für diese acht gibt es in der KG kein Gegenstück. Die Breite des gemeinsamen Bereichs beträgt 8,4 Prozentpunkte.

Tab. 2. Überlappung der Ausgangswerte je Zielgröße · nur Fälle mit %PAH

Zielgröße	n IG	n KG	gemeinsamer Bereich	IG darin	KG darin	IG-Anteil
Sprint 5 m (s)	18	7	1,09–1,18	6 / 18	6 / 7	33 %
Sprint 10 m (s)	18	11	1,78–2,06	15 / 18	10 / 11	83 %
Sprint 30 m (s)	18	11	4,45–5,00	13 / 18	8 / 11	72 %

Zielgröße	n IG	n KG	gemeinsamer Bereich	IG darin	KG darin	IG-Anteil
Standweitsprung (cm)	18	11	207–255	18 / 18	8 / 11	100 %
505 links (s)	17	10	2,35–2,65	14 / 17	10 / 10	82 %
505 rechts (s)	17	11	2,29–2,67	16 / 17	10 / 11	94 %

Der 5-m-Sprint ist der Problemfall, und zwar aus einem anderen Grund als gedacht: Die schnellsten zwölf IG-Spieler sind schneller, als der schnellste Spieler der Kontrollgruppe je war. Für sie enthält die KG keinen vergleichbaren Fall. § 11.9 führt das bereits als drittes, unabhängiges Argument dafür, den 5-m-Sprint nur deskriptiv zu berichten.

3 Die Antwort auf die Frage — und warum sie nein lautet

Die Überlappung beantwortet die Frage „kann ich vergleichen?“. Der Zusammenhang beantwortet die Frage „wirkt es?“. Eine Antwort auf die erste Frage sagt nichts über die zweite. Alle vier Kombinationen sind möglich:

Tab. 3. Überlappung und Zusammenhang sind unabhängig

	Zusammenhang stark	Zusammenhang schwach
Überlappung gut	Kovariate ist nützlich UND die Adjustierung ruht auf gemessenen Daten — der Idealfall	Kovariate kostet einen Freiheitsgrad und bringt wenig; die Adjustierung ist aber unbedenklich
Überlappung schlecht	Der ungünstigste Fall: die Adjustierung wirkt stark und beruht zugleich auf Extrapolation	Adjustierung ist unbegründet, aber folgenlos, weil die Steigung ohnehin nahe null ist

Unsere eigenen Daten liefern das Gegenbeispiel. Der Standweitsprung hat die vollständigste Überlappung von allen sechs Zielgrößen — alle achtzehn IG-Spieler liegen im gemeinsamen Bereich. Wäre die Annahme richtig, dürfte %PAH dort keinen Einfluss haben. Tatsächlich ist der Standweitsprung die Zielgröße mit dem STÄRKSTEN Zusammenhang zum Reifestatus im ganzen Datensatz ($r = +0,44$). Umgekehrt hat der 10-m-Sprint eine gute Überlappung von 83 % und zugleich den schwächsten Reifezusammenhang ($r = -0,25$). Die beiden Größen laufen bei uns nicht einmal in dieselbe Richtung.

4 Was die Daten zum Einfluss von %PAH tatsächlich sagen

Verfahren: gepoolte Within-Group-Korrelation. Jeder Wert wird vom Mittelwert seiner eigenen Gruppe abgezogen, danach werden beide Gruppen gemeinsam korreliert. Damit ist der Gruppenunterschied aus der Rechnung entfernt und übrig bleibt der Zusammenhang innerhalb der Gruppen — genau die Größe, die die ANCOVA als Steigung verwendet. Freiheitsgrade $N - 2$ Gruppen $- 1$. Vollständiges Rechenprotokoll: Kovariatenprotokoll_2026-09-11.txt.

⚠ Warum nicht die einfache Korrelation über alle Spieler: Sie wäre irreführend. Die IG ist zugleich reifer und schneller; allein dadurch entsteht ein Zusammenhang, auch wenn innerhalb der Gruppen keiner bestünde. Beim 5-m-Sprint beträgt die unzentrierte Korrelation $-0,507$, die Within-Group-Korrelation nur $-0,284$. Die Differenz ist reiner Gruppeneffekt.

Tab. 4. Zusammenhang zwischen %PAH und dem Ausgangswert · neu gerechnet 11.09.2026, IG 18 · Vorzeichen so gedreht, dass + = reifer ist besser

Zielgröße	n IG/KG	r within	95%-KI	p	Richtung
Sprint 5 m	18 / 7	0,284	–0,135 bis 0,617	0,179	reifer = schneller
Sprint 10 m	18 / 11	0,252	–0,134 bis 0,571	0,196	reifer = schneller

Zielgröße	n IG/KG	r within	95%-KI	p	Richtung
Sprint 30 m	18 / 11	0,323	−0,057 bis 0,621	0,094	reifer = schneller
Standweitsprung	18 / 11	0,437	0,076 bis 0,696	0,020	reifer = weiter
505 links	17 / 10	0,444	0,068 bis 0,709	0,023	reifer = schneller
505 rechts	17 / 11	0,437	0,069 bis 0,701	0,023	reifer = schneller

Drei Befunde daraus. Erstens: Die Richtung stimmt in allen sechs Zielgrößen — wer reifer ist, ist im Mittel schneller und springt weiter. Ihre Annahme ist damit nicht mehr Annahme, sondern an den eigenen Daten gemessen. Das ist genau das, was § 1.1 verlangt: Modellrechnung und Messung trennen. Zweitens: Bei drei der sechs Zielgrößen schließt das Konfidenzintervall die Null aus. Drittens: Die Größenordnung liegt zwischen 6 und 20 Prozent erklärter Streuung — nicht überwältigend, aber weit entfernt von „kein Einfluss“.

⚠ Eine Einschränkung, die dazugehört: Bei $n = 24$ bis 28 sind diese Korrelationen sehr ungenau geschätzt — das sieht man an der Breite der Intervalle. Die richtige Formulierung lautet deshalb nicht „%PAH erklärt 19 % der Streuung“, sondern „der Zusammenhang ist in allen Zielgrößen gleichgerichtet und liegt in einer Größenordnung, die eine Adjustierung rechtfertigt“.

5 Was die Kovariate kostet — korrigierte Fassung

⚠ Korrektur gegenüber der ersten Fassung dieses Dokuments. Dort stand eine Nettobilanz mit der Aussage, die Kovariate koste 11 bis 37 Prozent Präzision. Diese Tabelle war in zwei Punkten falsch und ist ersatzlos gestrichen. Erstens enthielt der ausgewiesene Standardfehler-Faktor auch den Beitrag des Ausgangswerts, nicht nur den von %PAH. Zweitens war die gegengerechnete „Rauschminderung“ mit der falschen Größe gebildet — sie beruhte auf dem Zusammenhang von %PAH mit dem PRÄ-Wert, während für die Modellgüte der zusätzliche Beitrag zum POST-Wert nach bereits erfolgter Ausgangswert-Adjustierung maßgeblich wäre. Diese Größe ist derzeit nicht berechenbar, weil die Post-Werte der Kontrollgruppe fehlen.

5.1 Was ein Standardfehler-Aufschlag überhaupt ist

Die ANCOVA vergleicht die beiden Gruppen nicht dort, wo sie gemessen wurden, sondern bei einem gemeinsamen Kovariatenwert — beim Gesamtmittel. Unser Gesamtmittel des Reifestatus liegt bei rund 92,6 Prozent. Die Interventionsgruppe liegt im Mittel bei 94,3, die Kontrollgruppe bei 89,7. Keine der beiden Gruppen wurde also tatsächlich bei 92,6 gemessen; das Modell muss beide entlang ihrer Regressionsgeraden dorthin verschieben.

Und hier entsteht der Aufschlag: Die Regressionsgerade ist selbst nur geschätzt, und zwar aus wenigen, streuenden Punkten. Je weiter eine Gruppe verschoben werden muss, desto stärker schlägt die Unsicherheit dieser Steigung auf den Vergleich durch. Man vergleicht am Ende nicht mehr zwei gemessene Mittelwerte, sondern zwei hochgerechnete Punkte — und die Hochrechnungsstrecke kostet Sicherheit. Genau das bildet die Formel ab: der Zusatzterm wächst mit dem Quadrat der Gruppendifferenz in der Kovariate.

⚠ Eine Verwechslung, die naheliegt, aber nicht zutrifft: Mit dem Zusammenrechnen verschiedener Messparameter hat das nichts zu tun. Sprint, Standweitsprung und Richtungswechsel werden niemals in einem Modell zusammengefasst. Jede Zielgröße erhält ihre eigene, getrennte ANCOVA. Der Aufschlag entsteht innerhalb eines einzelnen Modells und stammt allein daraus, dass die Kovariaten zwischen den Gruppen ungleich verteilt sind.

Und „Reststreuung“ ist der Teil der Unterschiede zwischen Spielern, den das Modell nicht erklären kann. Wenn Ausgangswert und Reifestatus einen Teil der Unterschiede erklären, bleibt weniger unerklärter Rest — und je kleiner dieser Rest, desto genauer die Schätzung der Gruppendifferenz.

5.2 Was der Aufschlag konkret kostet — in Messeinheiten statt in Prozent

Ein Prozentwert allein sagt wenig: 30 Prozent Aufschlag auf einen ohnehin winzigen Standardfehler sind belanglos, 10 Prozent auf einen großen sind es nicht. Aussagekräftig wird die Angabe erst, wenn man sie in die Einheit der Messung und in Vielfache des SESOI übersetzt.

Tab. 5. Aufschlag auf die Halbbreite des 95-%-Konfidenzintervalls durch die Kovariate %PAH

Zielgröße	SESOI	nur Ausgangswert	beide Kovariaten	Aufschlag durch %PAH	in SESOI	volle KI-Breite in SESOI
Sprint 30 m (s)	0,063	± 0,108	± 0,119	+ 0,011	0,18	3,8
Sprint 10 m (s)	0,022	± 0,047	± 0,054	+ 0,007	0,34	5,0
Standweitsprung (cm)	3,32	± 6,94	± 8,50	+ 1,57	0,47	5,1
505 links (s)	0,023	± 0,089	± 0,107	+ 0,019	0,82	9,4
Sprint 5 m (s)	0,016	± 0,062	± 0,080	+ 0,018	1,11	10,1
505 rechts (s)	0,023	± 0,081	± 0,108	+ 0,028	1,18	9,3

Jetzt ist die Angabe brauchbar. Beim Standweitsprung — der einzigen Zielgröße, die nach § 11.1 als primäre in Betracht kommt — kostet die Reifeadjustierung knapp einen halben SESOI an Intervallbreite. Das ist wenig für das, was sie leistet. Beim 30-m-Sprint sind es weniger als ein Fünftel SESOI, also fast nichts. Teuer wird sie beim 5-m-Sprint und beim 505 rechts, wo der Aufschlag allein größer ist als der SESOI selbst — beides Zielgrößen, die aus anderen Gründen ohnehin nicht tragen.

Die eigentlich beunruhigende Zahl steht in der letzten Spalte. Das Konfidenzintervall der adjustierten Gruppendifferenz ist bei allen Zielgrößen drei- bis zehnmal so breit wie der kleinste Unterschied, den wir für bedeutsam halten würden. Gegen diese Größenordnung ist der Aufschlag durch die Kovariate zweitrangig. Wer die Kovariate streicht, um Präzision zu sparen, gewinnt beim Standweitsprung ein halbes SESOI und handelt sich dafür eine bekannte, unadjustierte Reifekonfundierung ein. Das ist kein guter Tausch.

⚠ Modellrechnung, keine Messung. Die Intervallbreiten beruhen auf einer aus der Messgüte abgeleiteten Annahme über die Reststreuung ($R^2_{\max}$ aus der Within-Session-Reliabilität), nicht auf beobachteten Post-Daten. Nach § 1.1 ist das als Modellrechnung zu kennzeichnen und nach Vorliegen der KG-Post-Werte an den Daten zu prüfen.

5.3 Der Grund, aus dem die Kovariate bleibt

Nicht Präzision, sondern Verzerrungsfreiheit. Die beiden Gruppen unterscheiden sich im Reifestatus um rund anderthalb Standardabweichungen ($d = 1,45$ bis $2,16$). Der Reifestatus hängt in allen sechs Zielgrößen gleichgerichtet mit der Leistung zusammen. Ohne Adjustierung steckt dieser Unterschied unerkannt im geschätzten Gruppeneffekt. Wir nehmen den Präzisionsverlust in Kauf, um diese Konfundierung zu verringern.

Und unabhängig davon: Die Aufnahme ist vorab festgelegt und prognostisch begründet (CONSORT Item 12b, § 11.2). Sie hängt ausdrücklich nicht davon ab, wie stark der Reifekoeffizient am Ende ausfällt. Eine Kovariate nach ihrem p-Wert auszuwählen, wäre derselbe Fehler wie der Baseline-Signifikanztest, den § 4 ablehnt.

6 Warum Ausgangswert und %PAH nicht dasselbe leisten

Eine naheliegende Rückfrage: Wenn reifere Spieler bereits im Prä-Test besser sind, steckt die Reife dann nicht schon im Ausgangswert? Teilweise ja — aber nur teilweise, und der Rest ist genau der Grund für die zweite Kovariate.

Der Ausgangswert erfasst, wo ein Spieler zu Beginn steht. %PAH erfasst, wie viel Entwicklung im Untersuchungszeitraum noch zu erwarten ist. Zwei Spieler können im Juli dieselbe 30-m-Zeit laufen und trotzdem verschieden weit in ihrer Reifung sein. Der weniger reife hat über neun Wochen mehr natürliches Wachstum vor sich und verändert sich deshalb anders als der weiter fortgeschrittene — unabhängig von

jeder Intervention. Der Ausgangswert kann das nicht abbilden, weil er nur einen Zustand misst, keine Entwicklungsrichtung.

Für unsere Konstellation ist das nicht nebensächlich: Die Kontrollgruppe ist einen Jahrgang jünger und im Mittel 4,6 Prozentpunkte weniger weit in ihrer Reifung. Über die Sommerpause hinweg ist bei ihr mehr reifungsbedingte Veränderung zu erwarten als bei der Interventionsgruppe. Ohne %PAH würde ein Teil dieser natürlichen Entwicklung als Gruppeneffekt erscheinen.

7 Ihr Fallschema — geprüft und korrigiert

Der Aufbau ist richtig, und er steht in ähnlicher Form bereits in § 11.9 der Projektanweisungen. Vier Präzisierungen machen ihn tragfähig.

1. Die Fallnummern waren vertauscht. Definiert war Fall 1 als „Überlappung vorhanden“, ausgeführt wurde Fall 1 dann als „keine Überlappung“. Nur eine Schreibsache, aber in einem Methodenteil entscheidet die Nummer über die Zuordnung.

2. Die Fallunterscheidung ändert nicht das Modell, sondern die Berichtsebene. Gerechnet wird in beiden Fällen dieselbe ANCOVA. Was sich unterscheidet, ist, ob aus ihr eine inferenzstatistische Aussage gezogen werden darf oder nur ein deskriptiver Bericht. Ein anderes Modell je nach Datenlage zu wählen, wäre genau das, was Vickers und Altman untersagen: „It is incorrect, however, to choose whichever analysis gives a more significant finding.“

3. Überlappung ist nicht dasselbe wie Gleichheit. Im Entwurf stand sinngemäß: Wenn die Ausgangswerte überlappen, bleibt nur noch %PAH als Problem. Das trifft nicht zu. Der Standweitsprung überlappt zu hundert Prozent und hat trotzdem einen Gruppenunterschied von $d = 0,60$ im Ausgangswert. Überlappung beschreibt den gemeinsamen Wertebereich, nicht die Lage der Mittelwerte. Der Ausgangswert bleibt deshalb in jedem Fall Kovariate.

4. Es sind zwei Prüfungen, nicht eine. Die Überlappung ist je Kovariate getrennt zu prüfen — einmal für den Ausgangswert je Zielgröße, einmal für %PAH. Beim 5-m-Sprint ist die Ausgangswert-Überlappung schlecht (33 %) und die %PAH-Überlappung dieselbe wie überall. Beim Standweitsprung ist die Ausgangswert-Überlappung vollständig. Ein einziges Urteil „überlappt / überlappt nicht“ je Zielgröße gibt es also nicht.

Tab. 6. So sieht das Schema mit unseren Zahlen aus

Zielgröße	Überlappung Ausgangswert	Überlappung %PAH	Folge
Standweitsprung	100 % — vollständig	IG 56 %	ANCOVA, inferenzstatistisch; primäre Zielgröße
505 rechts	94 %	IG 56 %	ANCOVA, inferenzstatistisch
505 links	82 %	IG 56 %	ANCOVA, inferenzstatistisch
Sprint 30 m	72 %	IG 56 %	ANCOVA, inferenzstatistisch
Sprint 10 m	83 %	IG 56 %	deskriptiv — aber wegen des Messausfalls ($n = 7$), nicht wegen der Überlappung
Sprint 5 m	33 % — schlecht	IG 56 %	deskriptiv — drei unabhängige Gründe: Überlappung, Fallzahl der KG, TE/SESOI

8 Nachtrag: die drei Argumente für die ANCOVA, sauber getrennt

Die frühere Formulierung „dort trägt allein die %PAH-Adjustierung“ war zu knapp. Hier vollständig. Vickers und Altman (2001) führen drei voneinander unabhängige Argumente an:

	Argument	Was es besagt	Gilt es bei uns?
a	Verzerrungsfreiheit	Die ANCOVA liefert dieselbe Schätzung, ob der Ausgangswert zwischen den Gruppen ungleich ist oder nicht	Nein. Hergeleitet für zufällige Ungleichheit bei Randomisierung. Unsere ist systematisch — das ist Lord's Paradox, und es steht dort nicht
b	Effizienz	Die ANCOVA braucht weniger Fälle als Post-Vergleich und Änderungswert (85 : 68 : 54 bei $r = 0,6$)	Nur teilweise. Die Quelle schränkt selbst ein: bei r über 0,8 ist der Vorteil gering. Das trifft auf 30 m ($r = 0,94$), 10 m (0,88) und Standweitsprung (0,86) zu. Beim 505 (0,39 und 0,49) greift er voll
c	Erweiterbarkeit	Die ANCOVA ist eine Regression und kann weitere prognostische Variablen aufnehmen	Ja, uneingeschränkt — und nur sie kann das

Daraus die klare Fassung: Bei 30 m und Standweitsprung — den beiden Zielgrößen, die die Arbeit tragen — bleibt von den drei Argumenten nur das dritte übrig. Die ANCOVA wird dort nicht gewählt, weil sie genauer wäre als eine Änderungswert-Rechnung; das ist sie nach der Quelle selbst nicht. Sie wird gewählt, weil sie als einziges der drei Verfahren den Reifestatus überhaupt ins Modell aufnehmen kann. Beim 505 kommt der Effizienzvorteil hinzu.

Und daraus folgt eine Auflage für 4.7: Wer die ANCOVA dort mit Effizienz begründet, begründet sie falsch — und zwar nachprüfbar falsch, weil die Einschränkung auf derselben Seite der zitierten Quelle steht.