

Statistik der Interventionsstudie

Von der Datenlage über die Verfahrenswahl bis zur Umsetzung — was jede Größe ist, warum genau diese Verfahren, und was dabei tatsächlich gerechnet wird

Bachelorarbeit U15-Plyometrie · DSHS Köln · Stand 09.09.2026 · Lehr- und Arbeitsdokument, keine Manuskriptfassung

Aufbau. Teil A klärt die Begriffe, weil ein großer Teil der Verwirrung in der Sportwissenschaft daher rührt, dass „Parameter“ vier verschiedene Dinge bezeichnet. Teil B löst die Zielgrößen einzeln auf. Teil C beschreibt, was für Daten überhaupt vorliegen. Teil D leitet daraus das Verfahren ab — mit den Gründen, warum die naheliegenden Alternativen ausscheiden. Teil E erklärt, was die ANCOVA rechnet, bis auf die Ebene, auf der man es von Hand nachvollziehen kann. Teil F bis H behandeln Voraussetzungen, Messgüte und die konkrete Umsetzung. Teil I enthält vier Rechnungen an den echten Prä-Daten, die die Argumente belegen statt sie zu behaupten — darunter eine Verzerrungsquelle, die bisher in keinem Projektdokument steht.

A Begriffe — die vier Bedeutungen von „Parameter“

Das Wort „Parameter“ wird in der Trainingswissenschaft für alles benutzt, was eine Zahl hat. In der Statistik hat es eine enge Bedeutung, und die Unterscheidung ist keine Pedanterie: Sie entscheidet, was geschätzt wird, was gemessen wird und was vorausgesetzt wird.

Tab. A1. Die Rollen sauber getrennt. Rechte Spalte: die Größen dieser Studie.

Rolle	Was es ist	Woher es kommt	In dieser Studie
Zielgröße (abhängige Variable)	Das Gemessene, dessen Unterschied erklärt werden soll	Aus der Messung	Post-Wert von Sprint 10 m, 30 m, 505 links, 505 rechts, Standweitsprung
Faktor (unabhängige Variable)	Die Bedingung, deren Wirkung geprüft wird	Aus dem Design	Gruppe: Intervention oder Kontrolle
Kovariate	Eine Störgröße, die man kennt und deshalb herausrechnen kann	Aus der Messung	Prä-Wert derselben Zielgröße; %PAH
Parameter im engeren Sinn	Unbekannte Größe der Grundgesamtheit, die geschätzt wird	Existiert nur im Modell	β_0 , β_1 , β_2 , β_3 und σ^2 der ANCOVA
Schätzer / Statistik	Der aus der Stichprobe berechnete Wert eines Parameters	Aus der Rechnung	b_1 (die adjustierte Differenz), s^2
Kennwert der Messgüte	Eigenschaft des Messverfahrens, nicht des Modells	Aus Wiederholungsmessungen	TE, CV, ICC, SESOI
Trainingsparameter	Steuergrößen der Intervention	Aus der Planung	Kontakte, Sätze, Frequenz, DVZ-Typ

Nur Zeile 4 sind „Parameter“ im statistischen Sinn. Die Zeilen 1 bis 3 sind Variablen, Zeile 5 sind Schätzer, Zeile 6 sind Eigenschaften des Messgeräts, Zeile 7 gehört ins Methodenskapitel 4.5.

Merksatz. Ein Parameter wird nie gemessen, sondern immer geschätzt. Was ihr im Feld messt, sind Variablenwerte; was am Ende im Ergebnisteil steht — die adjustierte Differenz mit Konfidenzintervall — ist eine Schätzung eines Parameters, den niemand je zu Gesicht bekommt.

Praktische Folge für die Formulierung: „Wir haben den Effekt gemessen“ ist falsch. Richtig ist „wir haben den Effekt geschätzt“ — und deshalb gehört zu jeder Schätzung ein Konfidenzintervall, das sagt, wie unscharf die Schätzung ist.

B Die Zielgrößen — eindeutige Auflösung

Fünf gemessene Zielgrößen, eine abgeleitete. Nicht alle haben denselben Status. Die Statusfrage ist wichtiger, als sie klingt: Sie entscheidet, ob ein Befund eine Aussage trägt oder nur ein Hinweis ist.

Tab. B1. Zielgrößen, Konstrukt, Status und Begründung.

Zielgröße	Konstrukt	Status	Warum sie drin ist — und warum mit diesem Status
Sprint 5 m	Antritt, erste Schrittfrequenz	nur deskriptiv	Kürzeste Strecke, größter relativer Messfehler ($TE/SESOI = 2,92$). In der KG fielen 5 von 13 Messungen aus, weil die Lichtschranke den Start bei 0,5 m nicht registrierte. Ein konfirmatorischer Test auf einer Größe mit halber Fallzahl und dreifachem Messfehler wäre Zahlenkosmetik.
Sprint 10 m	Beschleunigung	konfirmatorisch	Die Strecke, auf die sich die metaanalytische Erwartungsbasis für plyometrisches Training bezieht (Ramirez-Campillo 2020; Lloyd 2016). Direkte Vergleichbarkeit mit der Literatur.
Sprint 30 m	Beschleunigung plus obere Geschwindigkeit	konfirmatorisch	Beste Messgüte des gesamten Sets ($TE/SESOI = 1,24$, $R^2_{\max} = 0,88$) und damit die empfindlichste Zielgröße. Deckt den Anteil des Spiels ab, der oberhalb der Beschleunigungsphase liegt.
505 links / rechts	Richtungswechsel 180° mit Anlauf	konfirmatorisch, seitengetreunt	Das Anforderungsprofil weist Richtungswechsel als häufigste hochintensive Aktion aus. Seitengetreunt, weil die Beindominanz nicht erhoben wurde — die Mittelung beider Seiten hätte den seitenspezifischen Anteil vernichtet.
Standweitsprung	horizontale Sprungkraft, langsamer DVZ	konfirmatorisch	Die einzige Sprungzielgröße, die gerätefrei und feldtauglich ist. Horizontal — und damit näher an der trainierten Bewegungsrichtung als der sonst übliche CMJ.
COD-Defizit	Richtungswechsel ohne Sprintanteil	explorativ	Kein Endpunkt, sondern eine Kontrollrechnung: Die 505-Gesamtzeit enthält lineare Laufleistung. Das Defizit prüft, ob ein Gruppenunterschied im 505 in Wahrheit ein Sprintunterschied ist.

Der Status ist vor der Auswertung festgelegt und in 4.7 zu dokumentieren (CONSORT Item 6b).

B1 Was zwischen Messung und Zielgröße passiert

Ein Punkt, der oft übersehen wird: Die Zielgröße ist nicht das, was das Gerät anzeigt. Zwischen Anzeige und Analysewert liegen drei Entscheidungen, und jede davon ist eine methodische Festlegung.

- Gültigkeit.** Sechs 505-Versuche wurden verworfen, weil die Wendelinie nicht getroffen wurde. Diese Regel steht vor der Messung fest, sonst wäre sie eine Auswahl am Ergebnis.
- Aggregation.** Aus k gültigen Versuchen wird ein Wert je Spieler. Wir nehmen den Bestwert — bei Zeiten das Minimum, beim Standweitsprung das Maximum. Diese Wahl ist Konvention in der Leistungsdiagnostik, aber sie ist nicht folgenlos (Teil I, Demo 1).
- Vollständigkeit.** Wer keinen gültigen Versuch hat, fehlt in dieser Zielgröße — und wem %PAH fehlt, der fehlt in jeder Analyse mit dieser Kovariate. Deshalb sind die Fallzahlen je Zielgröße verschieden (Teil C).

C Die Datenlage — was tatsächlich vorliegt

C1 Skalenniveaus

Das Skalenniveau entscheidet, welche Rechenoperationen überhaupt zulässig sind.

- **Zielgrößen (Sekunden, Zentimeter):** verhältnisskaliert. Differenzen und Verhältnisse sind sinnvoll, es gibt einen absoluten Nullpunkt. Alle parametrischen Verfahren sind grundsätzlich zulässig.
- **Gruppe:** nominal, zweistufig. Im Modell wird sie als 0/1-Variable kodiert; ihr Koeffizient ist dann direkt die Gruppendifferenz.
- **%PAH:** metrisch, als Prozentsatz der erwarteten Endgröße. **Kontinuierlich verwendet, nicht in Reifebänder eingeteilt** — die kategoriale Umsetzung von Khamis-Roche hat eine sehr schwache Übereinstimmung mit dem Skelettalter ($\kappa = 0,12$), die kontinuierliche eine gute ($ICC = 0,93$). Wer bündert, wirft genau die Information weg, die trägt.
- **Chronologisches Alter:** metrisch, aber **als Kovariate unbrauchbar**, weil sich die Gruppen nicht überlappen (IG 14,57–15,49 J.; KG 13,71–14,49 J.). Eine Kovariate ohne gemeinsamen Wertebereich lässt sich nicht adjustieren, ohne über die Daten hinaus zu extrapolieren.

C2 Die Struktur — und warum sie ein Problem ist

Die Daten sind dreifach geschachtelt: Versuche liegen in Spielern, Spieler in Vereinen, Vereine in Gruppen. Die Zuteilung erfolgte auf Vereinsebene, die Messung auf Spielerebene.

Gruppe	▷	Verein	▷	Spieler	▷	Versuch
2		3		31		1 bis 3

Daraus folgt ein Problem, das benannt werden muss: Spieler desselben Vereins sind einander ähnlicher als Spieler verschiedener Vereine — gleicher Trainer, gleiches Sommerprogramm, gleiche Selektion. Statistisch heißt das, sie sind nicht unabhängig. Das übliche Gegenmittel wäre ein Mehrebenenmodell mit zufälligem Vereinseffekt.

Warum wir das trotzdem nicht rechnen. Ein zufälliger Effekt braucht genug Cluster, um seine Varianz zu schätzen — die Faustregeln liegen bei 20 bis 30. Wir haben drei. Mit drei Clustern ist die Varianzkomponente praktisch nicht schätzbar, und das Modell wäre schlechter als die einfache Rechnung. Die Konsequenz ist keine Rechnung, sondern eine ehrliche Limitation: Der Standardfehler der Gruppendifferenz ist vermutlich zu klein ausgewiesen, weil er die Vereinsähnlichkeit ignoriert. In 6.1 zu benennen.

Ein zweiter Punkt derselben Art: Beim 505 liefert jeder Spieler zwei Werte (links und rechts). Die dürfen nicht als zwei unabhängige Beobachtungen in dieselbe Analyse — das wäre eine Verdopplung der scheinbaren Fallzahl. Deshalb zwei getrennte Modelle, und das in 4.7 ausdrücklich sagen (CONSORT Item 12a nennt genau diesen Fehler; 63 Prozent der geprüften Studien machen ihn).

C3 Fallzahlen — drei verschiedene N

Tab. C1. Die Fallzahlen je Zielgröße, wie sie tatsächlich in die Analyse gehen.

Zielgröße	getestet	mit Bestwert	+ %PAH	IG / KG	warum die Differenz
Sprint 5 m	31	26	24	17 / 7	Lichtschranke registrierte Start bei 0,5 m oft nicht
Sprint 10 m	31	31	28	17 / 11	nur die drei fehlenden %PAH
Sprint 30 m	31	31	28	17 / 11	nur die drei fehlenden %PAH
Standweitsprung	31	31	28	17 / 11	nur die drei fehlenden %PAH
505 links	31	29	26	16 / 10	zwei Spieler ohne gültigen Versuch

Zielgröße	getestet	mit Bestwert	+ %PAH	IG / KG	warum die Differenz
505 rechts	31	29	27	16 / 11	zwei Spieler ohne gültigen Versuch

Die Spalte „+ %PAH“ ist die Analysefallzahl. Die drei fehlenden %PAH-Werte: HL-08 (Elterngroßen), VS-11 (Geburtsdatum), VS-18 (Alter außerhalb des Koeffizientenbereichs).

D Die Verfahrenswahl — und warum die Alternativen ausscheiden

Die Frage lautet: Unterscheiden sich die Gruppen nach der Intervention, wenn man berücksichtigt, dass sie schon vorher unterschiedlich waren? Das ist ein Gruppenvergleich einer metrischen Zielgröße bei zwei Gruppen und bekannten Störgrößen — also ein lineares Modell. Die Frage ist nur, welches.

Der Ausgangspunkt, der alles bestimmt: **Die Gruppen waren zu Beginn stark verschieden.** Die Interventionsgruppe war im 30-m-Sprint um $d = 1,68$ Standardabweichungen schneller. Das ist kein Rauschen, das ist ein Strukturunterschied. Jedes Verfahren muss sich daran messen lassen, wie es damit umgeht.

Tab. D1. Die fünf Kandidaten und ihre Ausschlussgründe.

Verfahren	Was es täte	Warum es hier ausscheidet
t-Test auf die Post-Werte	Vergleicht die Gruppenmittel nach der Intervention	Ignoriert den Baseline-Unterschied vollständig. Die IG wäre nach der Intervention schneller — weil sie es vorher war. Das Verfahren beantwortet die Frage nicht.
t-Test auf Differenzen (Post – Prä)	Vergleicht die Veränderung je Gruppe	Adressiert die Baseline, aber unvollständig: Es unterstellt, dass der Prä-Wert eins zu eins in den Post-Wert übergeht. Das tut er nicht — es gibt Regression zur Mitte (Teil I, Demo 2). Zusätzlich verdoppelt eine Differenz die Fehlervarianz.
Prozentuale Veränderung	Vergleicht relative Veränderungen	Alle Nachteile der Differenz, plus einen eigenen: Der Nenner ist je Spieler verschieden. Wer langsamer startet, bekommt für dieselbe absolute Verbesserung einen kleineren Prozentwert. Bei systematisch unterschiedlichen Ausgangsniveaus verzerrt das den Gruppenvergleich.
Mixed ANOVA 2×2 (Zeit $\times$ Gruppe)	Prüft die Interaktion Zeit $\times$ Gruppe	Der Interaktionsterm ist bei zwei Zeitpunkten algebraisch identisch mit dem t-Test auf Differenzen. Dieselbe Rechnung im aufwendigeren Gewand — und damit dasselbe Problem.
Mehrebenenmodell	Modelliert den Vereinseffekt als Zufallseffekt	Drei Cluster reichen nicht, um eine Varianzkomponente zu schätzen (siehe C2).

Alle fünf sind gängige Praxis im Feld. Vier davon würden hier zu einer verzerrten oder unnötig unscharfen Schätzung führen.

D1 Was die ANCOVA anders macht

Die Kovarianzanalyse behandelt den Prä-Wert nicht als etwas, das man abzieht, sondern als etwas, dessen Gewicht man *schätzt*. Sie fragt: Wie viel vom Post-Wert lässt sich aus dem Prä-Wert vorhersagen? Dieses Gewicht — nennen wir es b — ist fast immer kleiner als 1, weil Messfehler und Regression zur Mitte den Zusammenhang abschwächen.

Änderungswert-Analyse: $\text{Effekt} = (\text{Post_IG} - \text{Post_KG}) - 1,0 \cdot (\text{Prä_IG} - \text{Prä_KG})$
ANCOVA: $\text{Effekt} = (\text{Post_IG} - \text{Post_KG}) - b \cdot (\text{Prä_IG} - \text{Prä_KG})$

Differenz beider Schätzer = $(1 - b) \cdot (\text{Prä_IG} - \text{Prä_KG})$

Die Änderungswert-Analyse ist also der Sonderfall $b = 1$ — und der ist bei uns nachweislich falsch. Wie groß der Unterschied konkret ausfällt, steht in Teil I, Demo 4: Bei vier von sechs Zielgrößen verschiebt die Verfahrenswahl den geschätzten Effekt um **mehr als den SESOI**. Das heißt: Allein die Wahl zwischen den beiden Verfahren kann über eine praktisch bedeutsame Aussage entscheiden — noch bevor irgendein Trainingseffekt im Spiel ist.

Die Grenze der ANCOVA, ehrlich gesagt. Sie adjustiert für das, was gemessen wurde — Ausgangsleistung und Reifestatus. Sie adjustiert nicht für Trainingsalter, Vereinskultur, Trainerqualität oder Motivation, weil davon nichts erhoben ist. Bei einer randomisierten Studie wäre das egal, weil der Zufall auch das Unbeobachtete ausbalanciert. Bei uns ist es das nicht. Die ANCOVA reduziert die Konfundierung, sie beseitigt sie nicht. Genau dieser Satz gehört in 6.1 — nicht die Formulierung, die Baseline-Unterschiede seien „adressiert“.

E Was die ANCOVA rechnet

E1 Das Modell

$$Y_{\text{post},i} = \beta_0 + \beta_1 \cdot \text{Gruppe}_i + \beta_2 \cdot Y_{\text{prä},i} + \beta_3 \cdot \%PAH_i + \varepsilon_i$$

$\text{Gruppe}_i = 1$ für Intervention, 0 für Kontrolle

$\varepsilon_i \sim N(0, \sigma^2)$, unabhängig

Jeder Koeffizient hat eine Bedeutung, die man in einem Satz sagen kann:

- β_0 — erwarteter Post-Wert eines Kontrollgruppenspielers mit Prä-Wert 0 und %PAH 0. Rechnerisch nötig, inhaltlich bedeutungslos.
- β_1 — **die gesuchte Größe**. Erwarteter Unterschied im Post-Wert zwischen IG und KG bei gleichem Ausgangswert und gleichem Reifestatus. Das ist die adjustierte Differenz, die mit Konfidenzintervall berichtet wird.
- β_2 — um wie viel der Post-Wert steigt, wenn der Prä-Wert um eine Einheit steigt. Das ist das „b“ aus Teil D.
- β_3 — um wie viel der Post-Wert sich je Prozentpunkt %PAH ändert. Adjustiert für den Reifevorsprung der IG.

E2 Wie β_1 geschätzt wird — der Weg, den man von Hand gehen kann

Die Kleinste-Quadrate-Schätzung minimiert die Summe der quadrierten Abweichungen zwischen beobachteten und vorhergesagten Post-Werten. Für das Verständnis ist ein anderer, gleichwertiger Weg nützlicher — er heißt Frisch-Waugh-Lovell und läuft in drei Schritten:

1. Regressiere den Post-Wert auf die beiden Kovariaten. Behalte die Residuen: den Teil des Post-Werts, den Ausgangsleistung und Reife nicht erklären.
2. Regressiere die Gruppenvariable auf dieselben Kovariaten. Behalte auch hier die Residuen: den Teil der Gruppenzugehörigkeit, der *nicht* schon aus Ausgangsleistung und Reife hervorgeht.
3. Regressiere die Residuen aus Schritt 1 auf die Residuen aus Schritt 2. Die Steigung ist β_1 .

Schritt 2 ist der aufschlussreiche. Wenn die Gruppenzugehörigkeit stark mit den Kovariaten zusammenhängt — und bei uns tut sie das, die IG ist zugleich reifer und schneller —, dann bleibt nach Schritt 2 wenig übrig, aus dem der Effekt geschätzt werden kann. Wenig Variation heißt großer Standardfehler.

E3 Der Standardfehler und der Aufschlag Q

$$SE(\beta_1) = \sigma_{\text{res}} \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2} + Q}$$

$$\begin{aligned} \sigma_{\text{res}} &= SD \cdot \sqrt{(1 - R^2)} && \text{Reststreuung nach Adjustierung} \\ Q &= (d_1^2 - 2 \cdot r \cdot d_1 \cdot d_2 + d_2^2) / [(1 - r^2) \cdot (N - 2)] \end{aligned}$$

Bei einer randomisierten Studie wäre Q praktisch null, weil die Kovariaten im Mittel ausbalanciert sind: d_1 und d_2 wären nahe null. Bei uns sind sie es nicht (d_1 bis $-1,51$ im Ausgangswert, d_2 bis $+2,12$ im Reifestatus), und Q wird zu einem Term in derselben Größenordnung wie $1/n_1 + 1/n_2$.

Q ist damit **der Preis der nicht randomisierten Zuteilung, in einer Zahl**. Dass er genau dem entspricht, was man in der Regressionsdiagnostik Varianzinflation durch Multikollinearität nennt, zeigt Demo 3 in Teil I — dort stimmen zwei völlig verschiedene Rechenwege bis auf die dritte Nachkommastelle überein.

F Voraussetzungen — und was sie inhaltlich bedeuten

Tab. F1. Die fünf Voraussetzungen, ihre Bedeutung und wie sie geprüft werden.

Voraussetzung	Was sie inhaltlich heißt	Prüfung und Stand
Linearität	Der Zusammenhang Prä → Post ist eine Gerade, keine Kurve	Streudiagramm Post gegen Prä je Gruppe. Nach Dateneingabe.
Homogenität der Regressionssteigungen	Der Prä-Wert wirkt in beiden Gruppen gleich stark. Ist das verletzt, gibt es „den“ Gruppeneffekt nicht — er hinge davon ab, wo man auf der Prä-Skala schaut	F-Test der Interaktion Gruppe × Kovariate. Für %PAH an den Prä-Daten geprüft: nirgends signifikant, kleinstes $p = 0,110$. ⚠ Das ist keine Bestätigung — der Test ist bei $n = 28$ zu unempfindlich, um die tatsächlich beobachteten Steigungsunterschiede zu finden (Teil J4). Für Prä → Post nach Dateneingabe zu wiederholen.
Normalverteilung der Residuen	Die Abweichungen vom Modell streuen symmetrisch. Nicht die Rohdaten müssen normalverteilt sein — ein sehr häufiger Fehler	Q-Q-Plot der Residuen, Shapiro-Wilk als Ergänzung. Nach Dateneingabe.
Varianzhomogenität	Die Streuung um die Vorhersage ist in beiden Gruppen gleich groß	Levene-Test, Residuen gegen Vorhersagewerte. Nach Dateneingabe.
Kovariate nicht von der Intervention beeinflusst	Wird eine Kovariate durch die Behandlung mitverändert, rechnet man einen Teil des Effekts weg	Erfüllt per Design: Der Prä-Wert liegt vor der Intervention. %PAH beruht auf der Prä-Anthropometrie — genau deshalb wurde bewusst keine Post-Anthropometrie erhoben.

Die letzte Zeile ist die einzige, die man nicht nachträglich prüfen, sondern nur richtig planen kann. Das ist hier geschehen.

G Messgüte und Aussagekraft — drei Größen, die ständig verwechselt werden

Diese drei Zahlen sehen ähnlich aus, beantworten aber verschiedene Fragen. Wer sie vermischt, kommt zu Aussagen, die die Daten nicht tragen.

Tab. G1. TE, SESOI und MDES — Frage, Formel, Wert für den 10-m-Sprint.

Größe	Beantwortet die Frage	Formel	10 m
TE	Wie stark schwankt die Messung derselben Person, ohne dass sich etwas geändert hat?	gepoolte Intra-Personen-SD der Wiederholungsversuche	0,037 s

Größe	Beantwortet die Frage	Formel	10 m
SESOI	Ab welcher Größe ist ein Unterschied überhaupt praktisch bedeutsam?	$0,2 \times \text{SD}$ zwischen den Spielern — eine Konvention nach Cohen (1988), nicht eine Messgröße (Teil J)	0,021 s
TE / $\sqrt{n}$	Wie genau kennen wir den Gruppen-Mittelwert?	TE geteilt durch die Wurzel der Gruppengröße	$0,009 \text{ s} = 0,31 \times \text{SESOI}$
MDES	Wie groß müsste der wahre Effekt sein, damit wir ihn mit 80 % Wahrscheinlichkeit als signifikant erkennen?	$\text{ncp}(0,80; \text{df}) \cdot \sqrt{(1 - R^2) \cdot \sqrt{(1/n_1 + 1/n_2 + Q)}}$	$0,72 \rightarrow 3,6 \times \text{SESOI}$

Reliabilität: $\text{rel} = 1 - \text{TE}^2/\text{SD}^2$. Aus der klassischen Testtheorie — beobachtete Varianz ist wahre Varianz plus Fehlervarianz.

Der entscheidende Unterschied. TE/ $\sqrt{n}$ liegt bei $0,31 \times \text{SESOI}$, der MDES bei $3,6 \times \text{SESOI}$ — Faktor 11 zwischen zwei Zahlen, die beide „Genauigkeit“ heißen. Der Grund: In TE/ $\sqrt{n}$ steckt nur der Messfehler. Im MDES steckt zusätzlich die Streuung zwischen den Spielern, und die ist um ein Vielfaches größer. Übersetzt: Wir kennen den Gruppenmittelwert sehr genau. Wir können trotzdem keinen kleinen Gruppenunterschied nachweisen, weil die Spieler untereinander so verschieden sind. Beide Sätze sind wahr, und beide gehören nebeneinander in 4.7.

H Die Umsetzung — Schritt für Schritt mit eurem Datensatz

Die Reihenfolge ist nicht beliebig. Alles, was eine Festlegung ist, steht vor dem ersten Blick auf die Post-Werte.

Vor der Dateneingabe — jetzt

- Primäre Zielgröße festlegen** (Schwab). Nach der Poweranalyse kommt allein der Standweitsprung in Betracht. Die Festlegung entscheidet, ob überhaupt für Mehrfachtestung adjustiert werden muss.
- Mindestdosis für eine etwaige Per-Protokoll-Rechnung** schriftlich fixieren, mit Datum. Danach ist sie eine Auswahl am Ergebnis.
- Effektstärkemaß festlegen** — Empfehlung: partielles η^2 plus die adjustierte Differenz in Rohheiten mit KI.

Dateneingabe und Aufbereitung

- Post-Werte eintragen** in 02_Rohdaten, eine Zeile je Versuch, mit dem gilt-Flag. Die Spalten Familiarisierung und Status aus den Testtagsprotokollen nachtragen.
- Bestwerte bilden** nach derselben Regel wie prä. Die Versuchszahlen je Spieler dokumentieren — sie werden gebraucht (Teil I, Demo 1).
- Analysefallzahl je Zielgröße bestimmen** und die Ausschlussgründe protokollieren. Diese Zahlen gehen in das Flussdiagramm in 5.1.

Auswertung

- Deskriptive Statistik:** $M \pm \text{SD}$ je Gruppe und Zeitpunkt, ohne Signifikanztests auf Baseline-Unterschiede.
- Voraussetzungen prüfen** (Tab. F1) und die Befunde protokollieren — auch wenn alles in Ordnung ist.
- ANCOVA je Zielgröße:** $\text{Post} \sim \text{Gruppe} + \text{Prä} + \% \text{PAH}$. Ausgeben: adjustierte Mittelwerte mit KI, adjustierte Differenz mit KI, exakter p-Wert, Effektstärke mit KI. Zusätzlich die unadjustierte Differenz (CONSORT Item 18).
- Explorative Rechnungen:** COD-Defizit beide Seiten, 5 m deskriptiv, Sensitivitätsanalyse zur Familiarisierung — als explorativ gekennzeichnet.

11. **Fallzahlrechnung wiederholen** mit den endgültigen n. Das Skript aus Anhang G ist dafür parametrisiert.
12. **SPSS-Syntax und Versionsnummern sichern** — ohne sie ist die Auswertung nicht reproduzierbar, und § 11.4 verlangt beides.

I Vier Rechnungen an euren Prä-Daten

Die folgenden Rechnungen belegen die Argumente aus Teil D und E an den tatsächlichen Daten. Skript und vollständige Ausgabe: `Demonstrationen_Praedaten.py` und `Demonstrationen_Praedaten.txt`.

Demo 1 — Der Bestwert-Bias. Ein bisher unbenannter Befund

Der Bestwert aus k Versuchen ist ein Extremwert. Sein Erwartungswert hängt von k ab, auch wenn die wahre Leistung gleich bleibt: Wer öfter starten darf, hat mehr Gelegenheiten für einen guten Zufallsausschlag.

$$E[\text{Bestwert}] = \mu + TE \cdot E_k$$

E_k = Erwartungswert des Minimums von k standardnormalen Messfehlern

k	1	2	3	4	5
E_k	0,000	-0,564	-0,847	-1,030	-1,161

Die Interventionsgruppe hatte durchweg mehr gültige Versuche als die Kontrollgruppe. Daraus folgt ein systematischer Vorteil, der nichts mit Leistung zu tun hat:

Tab. 11. Erwarteter Bestwert-Vorteil der IG allein aus der höheren Versuchszahl.

Zielgröße	$\bar{k}$ IG	$\bar{k}$ KG	Bias (roh)	× SESOI	Einordnung
Sprint 5 m	2,22	1,62	-0,0127 s	0,80	erheblich
Sprint 10 m	2,56	1,62	-0,0138 s	0,64	erheblich
Sprint 30 m	2,61	2,38	-0,0050 s	0,08	vernachlässigbar
Standweitsprung	2,50	2,08	+0,73 cm	0,22	gering
505 links	1,94	1,83	-0,0054 s	0,24	gering
505 rechts	2,00	2,08	+0,0019 s	0,08	vernachlässigbar

Negatives Vorzeichen = IG erscheint schneller. Beim Standweitsprung ist der Bestwert das Maximum, das Vorzeichen dreht sich entsprechend.

Was das bedeutet. Beim 5-m- und 10-m-Sprint entsteht allein aus der ungleichen Versuchszahl ein scheinbarer IG-Vorsprung von rund zwei Dritteln bis vier Fünfteln des SESOI — im Prä-Test. Für die ANCOVA ist das teilweise unschädlich, weil der Prä-Wert als Kovariate eingeht und derselbe Mechanismus im Post-Test wieder wirkt. Unschädlich ist es aber nur, solange die Versuchszahlen prä und post gleich verteilt sind. Sind sie es nicht, entsteht ein echter differentieller Bias. Zwei Konsequenzen: erstens beim Eintragen der Post-Werte die Versuchszahlen je Gruppe vergleichen; zweitens den Sachverhalt in 4.4 nennen und in 6.1 einordnen. Er steht bisher in keinem Projektdokument.

Demo 2 — Regression zur Mitte, sichtbar in euren Daten

Die Begründung für die ANCOVA war, dass der Prä-Wert nicht mit Gewicht 1 in den Post-Wert übergeht. Das lässt sich an den Wiederholungsversuchen direkt zeigen: Regression des zweiten Versuchs auf den ersten. Wäre der Zusammenhang perfekt, wäre die Steigung 1.

Tab. 12. Steigung b der Regression Versuch 2 auf Versuch 1 (Prä-Testung).

Zielgröße	Paare	r	b	Lesart
Sprint 5 m	21	0,845	0,726	deutlicher Rückfall zur Mitte

Zielgröße	Paare	r	b	Lesart
Sprint 10 m	26	0,879	0,968	schwacher Rückfall
Sprint 30 m	30	0,957	0,913	schwacher Rückfall
Standweitsprung	29	0,854	0,782	deutlicher Rückfall
505 links	22	0,533	0,617	starker Rückfall
505 rechts	26	0,647	0,605	starker Rückfall

Alle sechs Steigungen liegen unter 1. Je unzuverlässiger die Messung, desto stärker der Rückfall — 505 und 5 m sind die unzuverlässigsten Tests des Sets.

Das ist derselbe Mechanismus, der zwischen Prä und Post wirkt, nur über Minuten statt über Wochen. Er ist der Grund, warum eine Änderungswert-Analyse bei ungleichen Ausgangsniveaus systematisch danebenliegt — und der Grund, warum die ANCOVA das Gewicht schätzt statt es auf 1 zu setzen.

Demo 3 — Warum die Adjustierung Präzision kostet

Nach Frisch-Waugh-Lovell wird β_1 aus dem Teil der Gruppenvariable geschätzt, der nicht durch die Kovariaten erklärt ist. Wie groß dieser Teil ist, lässt sich direkt messen: durch eine Hilfsregression der Gruppenvariable auf die Kovariaten.

Tab. 13. Varianzinflation — zwei unabhängige Rechenwege, ein Ergebnis.

Zielgröße	R ² (G ~ Kov.)	VIF	√VIF	Faktor SE aus Q
Sprint 5 m	0,5131	2,05	1,433	1,433
Sprint 10 m	0,4441	1,80	1,341	1,341
Sprint 30 m	0,4805	1,92	1,387	1,387
Standweitsprung	0,3895	1,64	1,280	1,280
505 links	0,3443	1,52	1,235	1,235
505 rechts	0,4345	1,77	1,330	1,330

$VIF = 1 / (1 - R^2)$. Die letzte Spalte stammt aus der Q-Formel des CONSORT-Dokuments, die vierte aus einer Hilfsregression. Sie stimmen exakt überein.

Beim 5-m-Sprint sind 51 Prozent der Gruppenzugehörigkeit bereits durch Ausgangsleistung und Reifestatus erklärt. Nur die restlichen 49 Prozent stehen für die Schätzung des Effekts zur Verfügung — daher der Standardfehler-Aufschlag von 43 Prozent. Dass zwei völlig verschiedene Rechenwege dieselbe Zahl liefern, ist zugleich die wechselseitige Kontrolle beider Rechnungen.

Demo 4 — Wie weit ANCOVA und Änderungswerte auseinanderliegen

Nach der Formel aus Teil D beträgt die Differenz beider Schätzer $(1 - b) \times \text{Prä-Differenz}$. Da b noch nicht bekannt ist, wird es über die plausible Spanne variiert.

Tab. 14. Verschiebung des geschätzten Effekts, wenn statt der ANCOVA Änderungswerte gerechnet würden.

Zielgröße	Prä-Diff	b = 0,60	b = 0,70	b = 0,80	b = 0,90	SESOI
Sprint 5 m	-0,0718	-0,0287	-0,0215	-0,0144	-0,0072	0,0158
Sprint 10 m	-0,1116	-0,0446	-0,0335	-0,0223	-0,0112	0,0215
Sprint 30 m	-0,3818	-0,1527	-0,1145	-0,0764	-0,0382	0,0627
Standweitsprung	9,27	3,71	2,78	1,85	0,93	3,32
505 links	-0,0497	-0,0199	-0,0149	-0,0099	-0,0050	0,0228

Zielgröße	Prä-Diff	b = 0,60	b = 0,70	b = 0,80	b = 0,90	SESOI
505 rechts	-0,0074	-0,0030	-0,0022	-0,0015	-0,0007	0,0233

Werte in Sekunden bzw. Zentimetern. Prä-Differenz = IG minus KG, aus den analysierbaren Fällen.

Das ist das stärkste Argument für die ANCOVA. Beim 30-m-Sprint verschiebt die Verfahrenswahl den geschätzten Effekt um das 0,6- bis 2,4-Fache des SESOI, beim 10-m-Sprint um das 0,5- bis 2,1-Fache. Die Änderungswert-Analyse würde die Interventionsgruppe systematisch begünstigen — weil sie den Baseline-Vorsprung mit einem zu großen Gewicht abzieht und dadurch überkorrigiert. Wer bei dieser Datenlage Änderungswerte oder Prozentwerte rechnet, produziert einen Effekt, der überwiegend aus der Verfahrenswahl stammt. Beim 505 rechts, wo die Gruppen praktisch gleich starteten, spielt es dagegen keine Rolle — das ist kein Zufall, sondern genau die Vorhersage der Formel.

J Vertiefung: Woher der SESOI kommt — und ob die Homogenitätsannahme trägt

Nachtrag vom 09.09.2026 auf zwei Rückfragen. Grundlage ist der am selben Tag geprüfte Volltext von Hopkins (2000), Sports Medicine 30(1), 1–15, im Ordner als 2000 Hopkins, Measures of.pdf.

J1 Was Hopkins auf S. 8 tatsächlich schreibt

Die Passage steht auf **Seite 8** im Abschnitt 2.2 „Estimation of Sample Size“ — nicht auf S. 9, wie § 11.3 der Projektanweisungen angibt. Im Original:

"When interest centres on experiments involving the average person in a population, Cohen[13] argued that clinical judgement should be guided by the spread of raw scores (not change scores) in the population, and suggested that the smallest worthwhile value of d is 0.2 of the between-subject standard deviation."

Hopkins (2000), S. 8

Drei Dinge stehen in diesem einen Satz, die für die Arbeit wichtig sind.

- 1. Die Regel ist Cohens, nicht Hopkins'.** Referenz [13] bei Hopkins ist Cohen, J. (1988), *Statistical power analysis for the behavioral sciences* (2. Aufl.), Lawrence Erlbaum. Hopkins referiert sie. Wer „SESOI = $0,2 \times \text{SD}$ (Hopkins, 2000)“ schreibt, schreibt ihm eine Setzung zu, die er selbst als fremde kennzeichnet.
- 2. Sie gilt für die Durchschnittsperson einer Population.** Hopkins nennt zwei Zeilen darüber einen ganz anderen Maßstab für den Leistungssport: „In research on factors affecting athletic performance, d is about half the typical error of an athlete's performance between races“ (Referenz [2] = Hopkins, Hawley & Burke, 1999). Für Wettkampfleistung gilt $0,5 \times \text{TE}$ zwischen Wettkämpfen, nicht $0,2 \times \text{SD}$. Für Feldtests wie unsere ist der Populationsmaßstab der passende — aber die Wahl ist eine, und sie ist zu begründen.
- 3. Der Bezugspunkt ist die Streuung der Rohwerte,** ausdrücklich nicht die der Veränderungswerte („the spread of raw scores (not change scores)“). Das haben wir richtig gemacht: Unser SESOI beruht auf der Zwischen-Athleten-SD der Prä-Werte.

Was der SESOI damit ist — und was nicht. Er ist eine normative Setzung, keine gemessene Größe. Er sagt nicht, was Trainer oder Spieler für bedeutsam halten, sondern was Cohen 1988 in der Psychologie als „kleinen Effekt“ definierte, übertragen auf die Streuung unserer Stichprobe. Das ist eine vertretbare, in der Sportwissenschaft übliche Konvention — aber sie ist eine Konvention und im Text als solche zu kennzeichnen. Ferguson et al. (2024) lehnen sie für Nachwuchsspieler ausdrücklich ab; dieser Gegenbefund gehört in 6.1.

Zur Einordnung: Es gäbe vier Wege, einen SESOI zu bestimmen. (a) Die Cohen-Konvention $0,2 \times \text{SD}$ — unser Weg. (b) Anker-basiert, also durch Befragung von Trainern oder Spielern, was sie für bedeutsam halten — bei uns nicht erhoben. (c) Messfehler-basiert, etwa über den kleinsten Wert, der den Messfehler übersteigt. (d) Hopkins' Athletenmaßstab über die Wettkampfstreuung — mangels Wettkampfmaß nicht

anwendbar. Weg (a) ist gewählt, weil er der einzige ist, für den die Daten vorliegen. Das ist ein Argument aus der Verfügbarkeit, nicht aus der Sache — und genau so zu schreiben.

J2 Hopkins' eigene Präzisierung — und was sie bei uns ändern würde

Zwei Absätze weiter, auf derselben Seite, schränkt Hopkins die eben referierte Regel ein. Das ist sein eigener Beitrag, und er betrifft uns unmittelbar:

"In the above estimate of sample size, the between-subject standard deviation, S , is made up of true between-subject variation (ST) and an independent concurrent error of measurement (e), such that $S^2 = ST^2 + e^2$. Ideally, we should consider the smallest worthwhile effect as a fraction of ST rather than of S , so the smallest worthwhile effect should be written as $0.2ST = 0.2\sqrt{S^2 - e^2}$."

Hopkins (2000), S. 8

Der Gedanke ist einfach: Die beobachtete Streuung zwischen den Spielern enthält bereits Messfehler. Wer den SESOI an ihr festmacht, macht ihn künstlich groß — und zwar umso mehr, je unzuverlässiger der Test ist. Hopkins' Korrektur zieht den Messfehler heraus. Was das bei unseren Daten bedeutet:

Tab. J1. SESOI nach der Konvention ($0,2 \cdot S$) gegenüber Hopkins' Präzisierung ($0,2 \cdot S_T$).

Zielgröße	S	e (TE)	S_T	$0,2 \cdot S$	$0,2 \cdot S_T$	Δ
Sprint 5 m	0,0792	0,0462	0,0643	0,0158	0,0129	-18,7 %
Sprint 10 m	0,1073	0,0369	0,1007	0,0215	0,0201	-6,1 %
Sprint 30 m	0,3133	0,0775	0,3035	0,0627	0,0607	-3,1 %
Standweitsprung	16,595	6,148	15,414	3,319	3,083	-7,1 %
505 links	0,1140	0,0888	0,0715	0,0228	0,0143	-37,3 %
505 rechts	0,1166	0,0829	0,0821	0,0233	0,0164	-29,6 %

$S_T = \sqrt{S^2 - e^2}$. e ist bei Hopkins der „concurrent error“ — der kurzfristige Messfehler, also genau unser Within-Session-TE.

Bei den Sprints und beim Standweitsprung ist die Korrektur klein (3 bis 7 Prozent). Beim 505 ist sie groß, weil dort der Messfehler fast so groß ist wie die Streuung zwischen den Spielern. Die Folge für das Verhältnis TE zu SESOI: 505 links steigt von 3,89 auf 6,21, 505 rechts von 3,55 auf 5,05, der 5-m-Sprint von 2,92 auf 3,59.

Empfehlung — und der Ehrlichkeitspunkt dabei. Bei $0,2 \cdot S$ bleiben, weil die gesamte Vergleichsliteratur so rechnet und ein Wechsel die Einordnung gegen fremde Befunde unmöglich machte. Aber: Diese Wahl ist die für uns günstigere. Sie lässt den MDES in einem besseren Verhältnis zum SESOI erscheinen, als Hopkins' eigene Empfehlung es täte. Wer die günstigere Variante wählt, muss die andere nennen — ein Satz in 4.7 und die Zahlen aus Tab. J1 als Sensitivitätsangabe in 6.1. Andernfalls steht im Text eine Konvention, die als Hopkins' Empfehlung ausgegeben wird, obwohl er ausdrücklich etwas anderes empfiehlt.

J3 Fünf Zitierfallen in einer einzigen Quelle

Hopkins (2000) trägt in der Arbeit den SESOI, den TE und den CV — also drei zentrale Kennwerte. Umso wichtiger, dass die Zitation stimmt. Für T4 einzutragen:

- **Fundstelle S. 8, nicht S. 9.** Beide Kernstellen stehen auf Zeitschriftenseite 8 (Kopfzeile „8 / Hopkins“ verifiziert). § 11.3 der Projektanweisungen ist zu korrigieren.
- **Die 0,2-Regel ist ein Sekundärzitat.** Original ist Cohen (1988). Entweder „Cohen, 1988, zitiert nach Hopkins, 2000“ oder Cohen direkt beschaffen und zitieren.
- **Hopkins verwendet weder „SESOI“ noch „SWC“.** Beide Begriffe kommen im Volltext nicht vor; er schreibt „smallest worthwhile effect“. „SESOI“ stammt aus der Äquivalenztest-Literatur (Lakens), „SWC“ aus späteren Hopkins-Arbeiten. Wer den Begriff verwendet und diese Quelle anhängt, überträgt eine Terminologie, die dort nicht steht.

- **Hopkins' eigene Empfehlung ist $0,2 \cdot S_T$** , nicht $0,2 \cdot S$ (siehe J2).
- **Für Athleten nennt Hopkins einen anderen Maßstab** ($0,5 \times TE$ zwischen Wettkämpfen, Referenz [2] = Hopkins, Hawley & Burke, 1999). Die Wahl des Populationsmaßstabs ist zu begründen, nicht stillschweigend zu treffen.

J4 Ist die Homogenitätsannahme für unsere Daten relevant?

Kurz: ja, und schärfer als die bisherige Formulierung nahelegte. Zwei getrennte Gründe.

Grund 1 — Die Gruppen überlappen sich im Ausgangswert nur teilweise

Die ANCOVA adjustiert entlang der Kovariate. Wo sich die Gruppen im Wertebereich der Kovariate nicht überlappen, adjustiert sie, ohne dass Daten beider Gruppen vorliegen — sie extrapoliert. Und genau dort trägt die Homogenitätsannahme die ganze Last: Ist die Steigung in beiden Gruppen gleich, ist die Extrapolation harmlos; ist sie es nicht, ist die adjustierte Differenz ein Artefakt.

Tab. J2. Überlappung der Prä-Bestwerte zwischen den Gruppen (analysierbare Fälle).

Zielgröße	IG Spanne	KG Spanne	gemeinsamer Bereich	IG darin	KG darin
Sprint 5 m	0,870–1,180	1,090–1,190	1,090–1,180	6 / 17	6 / 7
Sprint 10 m	1,650–2,060	1,780–2,090	1,780–2,060	14 / 17	10 / 11
Sprint 30 m	4,090–5,000	4,450–5,440	4,450–5,000	12 / 17	8 / 11
Standweitsprung	207–255	202–259	207–255	17 / 17	8 / 11
505 links	2,240–2,700	2,350–2,650	2,350–2,650	13 / 16	10 / 10
505 rechts	2,150–2,670	2,290–2,740	2,290–2,670	15 / 16	10 / 11

Werte in Sekunden bzw. Zentimetern. „IG darin“ = Zahl der IG-Spieler im gemeinsamen Wertebereich.

Der 5-m-Sprint ist der kritische Fall. Nur 6 von 17 Spielern der Interventionsgruppe liegen im gemeinsamen Wertebereich; elf sind schneller als der schnellste Spieler der Kontrollgruppe. Eine ANCOVA müsste dort für zwei Drittel der IG über den Datenbereich der KG hinaus extrapolieren. Das ist ein zweites, unabhängiges Argument dafür, den 5 m nur deskriptiv zu führen — es kommt zu Messfehler und Ausfallquote hinzu und ist von beiden unabhängig. Beim 30-m-Sprint ist die Lage entspannter, aber nicht unproblematisch (12 von 17 und 8 von 11). Beim 10 m, Standweitsprung und beiden 505-Richtungen ist die Überlappung ausreichend.

Grund 2 — Der Homogenitätstest kann nicht finden, was er finden müsste

Ein nicht signifikanter Test wird oft als Bestätigung der Annahme gelesen. Das ist nur dann zulässig, wenn der Test überhaupt die Kraft hätte, eine relevante Verletzung zu entdecken. Für unsere Daten ist genau das nicht der Fall:

Tab. J3. Beobachteter Steigungsunterschied gegenüber dem kleinsten, den der Test bei Power 0,80 fände.

Zielgröße (~ %PAH)	df	b IG	b KG	beobachtete Δb	nachweisbar ab
Sprint 5 m	20	–0,00722	–0,01002	0,0028	0,0322
Sprint 10 m	24	–0,01001	–0,00512	0,0049	0,0385
Sprint 30 m	24	–0,02502	–0,03353	0,0085	0,1054
Standweitsprung	24	1,191	4,384	3,193	5,794
505 links	22	–0,01855	–0,01073	0,0078	0,0421
505 rechts	23	–0,02387	–0,00622	0,0177	0,0492

Nachweisbar ab = $ncp(0,80; df) \times \text{Standardfehler der Steigungsdifferenz}$. $\alpha = 0,05$ zweiseitig.

Der beobachtete Steigungsunterschied liegt bei allen sechs Zielgrößen *unter* der Nachweisgrenze — beim 30-m-Sprint um den Faktor 12, beim Standweitsprung um den Faktor 1,8. Der Standweitsprung ist der aufschlussreichste Fall: Die Steigung ist in der Kontrollgruppe fast viermal so groß wie in der Interventionsgruppe (4,38 gegenüber 1,19 cm je Prozentpunkt %PAH). Das ist ein erheblicher Unterschied — und der Test findet ihn nicht, weil er ihn bei elf Spielern in der KG nicht finden kann.

Die richtige Formulierung. Nicht „die Voraussetzung ist erfüllt“, sondern: Die Annahme wurde geprüft und nicht verworfen; der Test hat bei dieser Fallzahl allerdings nur die Kraft, sehr große Steigungsunterschiede zu entdecken, sodass eine moderate Verletzung nicht ausgeschlossen werden kann. Beim Standweitsprung liegt ein Steigungsunterschied vor, der den Test nicht erreicht, aber nicht ignoriert werden sollte. Genau so gehört es in 4.7 und in 6.1 — alles andere wäre ein Beweis aus der Abwesenheit von Evidenz.

J5 Was daraus folgt

1. § 11.3 der Projektanweisungen korrigieren: Fundstelle S. 8 statt S. 9; die 0,2-Regel als Cohen-Konvention kennzeichnen; Hopkins' Präzisierung $0,2 \cdot S_T$ erwähnen.
2. Fünf Zitierfallen in T4 eintragen (J3).
3. In 4.7 einen Halbsatz ergänzen, dass der SESOI eine Konvention ist und auf der beobachteten, nicht der wahren Zwischen-Athleten-Streuung beruht; die Werte nach Hopkins' Präzisierung als Sensitivitätsangabe in 6.1.
4. Die Formulierung zur Homogenität der Regressionssteigungen in Baustein 6 des Gerüsts abschwächen: „geprüft und nicht verworfen, bei begrenzter Testempfindlichkeit“ statt „erfüllt“.
5. Die Überlappungsanalyse der Ausgangswerte (Tab. J2) in 4.7 oder 5.1 aufnehmen — analog zur bereits vorhandenen Überlappungsanalyse für %PAH in Blatt 06. Für den 5-m-Sprint ist sie ein eigenständiges Argument.
6. Nach Eintragung der Post-Werte dieselben beiden Prüfungen für die Prä-Kovariate wiederholen — die Steigung Post ~ Prä je Gruppe ist die eigentliche ANCOVA-Voraussetzung und bisher gar nicht prüfbar.

Alle Rechnungen dieses Dokuments stammen aus Statistik\Studiendaten_U15_gesamt.xlsx (Blätter 01_Personen, 02_Rohdaten, 04_Kennwerte). Keine Größe ist geschätzt; wo eine Eingangsgröße noch nicht vorliegt (b in Demo 4), ist sie als Gitter variiert. Skripte: Demonstrationen_Praedaten.py, AnhangG_Kovariatenkorrelation.py und sesoi_homog.py. Teil J ergänzt am 09.09.2026; Hopkins (2000) am Volltext geprüft.