

Statistische Verfahren — Literaturbefund

Systematische Durchsicht von 30 Volltexten aus dem Ordner · 11.09.2026

Bachelorarbeit U15-Plyometrie · DSHS Köln · Arbeitsdokument, kein Manuskripttext

Korrekturvermerk 11.09.2026, abends (Phase A „RCT-Auswertungspraxis“): Drei Aussagen dieses Befunds waren zu eng — nicht eine, sondern drei Korpusstudien rechnen eine ANCOVA mit Ausgangswert (Beato 2018, Sammoud 2024; Negra 2020 post hoc); nicht keine, sondern vier haben eine A-priori-Fallzahlbegründung (Aloui, Liu, Sammoud, Bouafif — alle mit Einzelstudien-Effektstärken); „kein TE aus eigenen Daten“ bleibt richtig, vier Studien berichten aber einen CV. Korrigiert in § 1, Tab. 1 (Rang 3), Rang-17-Absatz, § 5 und § 7. Belege: Claudel RCT_Auswertungspraxis_2026-09-11 § 6.2.

Vorgehen. 30 Volltexte aus „Ideen und Studien“ extrahiert und je Quelle in der Reihenfolge Titel → Abstract → Methodenteil „Statistical Analysis“ → Diskussion, Limitationen und Ausblick geprüft. Jedes Zitat dieses Dokuments wurde nach der Auswertung einzeln per Volltextsuche gegen die Quelldatei verifiziert. Seitenangaben sind PDF-Seiten, sofern die Zeitschriftenpaginierung nicht im Text steht.

Ehrlichkeitsvorbehalt. Empfohlen wird nur, was in diesem Korpus belegt ist. Verfahren, die naheliegen, aber in keiner der 30 Quellen vorkommen, stehen in Abschnitt 7 als ausdrücklich unbelegt — nicht als Empfehlung.

Kurzfassung — die beiden Antworten

Zu 5 m und 10 m: drei benannte Verfahren, die ohne Inferenzstatistik auskommen

Die Literatur hält für genau diesen Fall ein etabliertes Instrumentarium bereit. Es beurteilt eine Veränderung am Messfehler statt an einem α -Niveau und verlässt damit den Bereich der schließenden Statistik nicht nur formal, sondern der Sache nach.

- Sensitivitätseinstufung TEM gegen SWC (Sammoud et al., 2021): dreistufig good / OK / marginal. Unsere vorhandenen TE/SESOI-Werte erhalten damit ein publiziertes Etikett — alle sechs Zielgrößen sind „marginal“.
- Minimal detectable change, MDC (Taylor et al., 2018): $MDC = TE \times 1,96 \times \sqrt{2}$. Für uns neu und sofort rechenbar. Taylor liefert zugleich die Satzform, die wir brauchen: Gruppenunterschiede werden gegen den MDC gestellt, nicht gegen einen p-Wert.
- Schwelle 1,5 bis $2,0 \times TE$ (Hopkins, 2000): die weniger strenge Alternative zum 95%-Kriterium, mit einer Chance von 6:1 bis 12:1 auf eine echte Veränderung. Das ist die einzige Schwelle, die eine unserer beobachteten Veränderungen überhaupt überschreitet.

⚠ **Gegenbefund, der in dieselbe Passage gehört:** Ferguson et al. (2024) raten von genau der standardisierten SWC-Schwelle ab, auf der Sammoud aufbaut. Der Evidenzkörper ist an dieser Stelle uneinheitlich (§ 6.4).

Zu 30 m, 505 und Standweitsprung: die ANCOVA-Begründung ist jetzt belegbar — mit zwei Grenzen

★ **Vickers & Altman (2001) liegt im Ordner.** Der höchstpriorisierte Beschaffungsposten aus § 6.5 ist damit erledigt. Die Quelle trägt die Modellgleichung, die Kovariaterweiterung und die Effizienzrechnung. Zwei Einschränkungen ihres eigenen Textes betreffen uns jedoch unmittelbar und sind in 4.7 zu berücksichtigen — Abschnitt 5.

- Ergänzend als vorab festgelegte Sensitivitätsanalyse: die Änderungswert-Rechnung, von Vickers & Altman für hohe Prä-Post-Korrelationen ausdrücklich zugelassen — bei uns trifft das auf 30 m, 10 m und den Standweitsprung zu.
- Logarithmische Transformation der Zeitgrößen: von drei unabhängigen Quellen empfohlen (Vickers & Altman, Hopkins, Taylor). Liefert prozentuale Effekte und behandelt ungleiche Fehlerstreuung.

- Konfidenzgrenzen für den typischen Messfehler selbst: von Hopkins ausdrücklich verlangt, bei uns bisher nicht berichtet.
- Hopkins' eigene Fallzahlformel als unabhängige Gegenprobe zur Sensitivitäts-Poweranalyse — sie liefert greifbarere Zahlen als die Angabe „Vielfaches des SESOI“.

⚠ Befund aus dem Korpusvergleich: Von den geprüften Interventionsstudien verwenden drei eine ANCOVA mit dem Ausgangswert als Kovariate — Beato et al. (2018) und Sammoud et al. (2024) a priori, Negra et al. (2020) post hoc für den 12-Wochen-Vergleich (Korrektur 11.09. abends nach Phase A). Keine verwendet den Reifestatus als Kovariate; im Detraining-Korpus kommt keine Kovariate vor. Für die Reifeadjustierung hat unsere Verfahrenswahl kein Vorbild — das ist kein Mangel, sondern in 6.2 als Stärke zu formulieren.

2 Relevanzrangfolge des Korpus

Sortiert nach Überschneidung mit unserer Verfahrensfrage, nicht nach inhaltlicher Nähe zum Thema. Maßgeblich waren: verwendet die Quelle ein Verfahren, das wir übernehmen könnten, und ist es an unserer Datenlage anwendbar.

Tab. 1. Rang 1 bis 5 — Verfahren direkt übertragbar

#	Quelle	Überschneidung	Verfahren, das uns betrifft
1	Vickers & Altman (2001), BMJ	Methodennorm; kontinuierliche Prä- und Post-Messung	ANCOVA gegen Änderungswert gegen Post-Vergleich; Kovariaterweiterung; Effizienz
2	Hopkins (2000), Sports Med	Methodennorm; TE, CV, kleinster lohnender Effekt	Schwelle $1,5-2,0 \times TE$; ANCOVA mit Personenmerkmalen; Fallzahlformeln; KI für den TE
3	Beato et al. (2018), JSCR	Plyometrie, U18-Akademie; 10/30 m, 505, Standweitsprung	ANCOVA mit Ausgangswert als Kovariate (ebenso Sammoud 2024 a priori, Negra 2020 post hoc); $SWC = 0,2 \times SD$; 90%-KI
4	Taylor et al. (2018), Sci Med Football	Modifizierter 505 seitengetrent, U12–U18, Reifegruppen	MDC-Verfahren; Abgleich von Gruppenunterschieden gegen den MDC
5	Sammoud et al. (2021), JFMK	505 nach Draper & Lancaster, 5/10/20 m, Microgate	Sensitivitätsregel TEM gegen SWC, dreistufig

Tab. 2. Rang 6 bis 10 — teilweise übertragbar oder Gegenbefund

#	Quelle	Überschneidung	Verfahren / Rolle
6	Ferguson et al. (2024), JSCR	5/10/30 m, 14,7 J., Akademie	⚠ Gegenbefund: lehnt standardisierte Schwellen ab; gemischte lineare Modelle für systematische Verschiebung
7	Dugdale et al. (2019), EJSS	U15-Teilstichprobe; Standweitsprung, 505, 10/20 m	Drei-Kriterien-Regel ICC und CV und Effektstärke gemeinsam
8	Lloyd et al. (2016), JSCR	Dosisnächste Studie, 6 Wo./12 Einheiten	Reife als Faktor im Modell, nicht als Kovariate → Moderatorfrage
9	Negra et al. (2019), IJSP	Dosisnächste Studie: 50 → 120 Kontakte, 90 s Satzpause	Nur Effektstärken mit 90%-Grenzen, keine Modellrechnung
10	Bouafif et al. (2026), PLOS ONE	Plyometrie nach Reifestatus	Stratifizierung nach Reife; Moore statt Mirwald mit Begründung

Tab. 3. Rang 11 bis 16 — Berichtsnormen und Metaanalysen: Forderungen an Primärstudien

#	Quelle	Was sie für künftige Studien verlangt
1 1	Moran et al. (2016/17), JSCR	Kontrollgruppe zwingend; Reifemaß erheben — nennt Khamis-Roche ausdrücklich als geeignete Alternative
1 2	Ramirez-Campillo et al. (2020), Sports Med	Kritik an Dichotomisierung stetiger Variablen; Reifestatus als Moderator berichten
1 3	Oliver et al. (2024), Sports Med	Randomisierung mit vergleichbarem Ausgangsniveau; Reifestatus und Trainingshistorie berichten
1 4	Ramirez-Campillo et al. (2023), Sports Med Open	Reifestatus systematisch berichten; robustere Analysen
1 5	Moher et al. (2010), BMJ — CONSORT	Analysepopulation, Nenner je Analyse, Effektschätzung mit Präzision
1 6	Smart et al. (2015), IJEBH — TESTEX	Berichtsvollständigkeit von Trainingsstudien

Rang 17 und darunter (Hammami 2016 · Aloui 2022 · Sammoud 2024 · Bedoya 2015 · Liu 2024 · Padrón-Cabo 2025 · Asimakidis 2022 · Dambel 2025 · Silva 2016 · Moran 2024 · Behm 2017 · Nimphius 2016 · Marín-Jiménez 2024 · Clark 2020): für die Verfahrensfrage überwiegend als **Negativbeispiel** verwertbar. Sie arbeiten überwiegend mit **Zeit-x-Gruppe-Varianzanalysen ohne Kovariate**, prüfen **Baseline-Unterschiede per Signifikanztest** — genau das, was § 4 ablehnt — oder berichten gar keine Inferenzstatistik. Ausnahme: Sammoud et al. (2024) rechnen eine ANCOVA mit Ausgangswert; ihre Tab. 3 ist die Schablone für unsere Ergebnistabelle 5.2 (Phase A, 11.09.).

3 Frage 1: Verfahren für 5 m und 10 m ohne schließende Statistik

§ 11.9 definiert den deskriptiven Bericht als Einzelwerte, Mittelwert und Streuung, ohne p-Wert und ohne Effektstärke. Die drei folgenden Verfahren fügen sich darin ein: Sie sind Aussagen über die Messgüte des Tests, nicht über die Grundgesamtheit. Genau deshalb sind sie hier zulässig.

3.1 Sensitivitätseinstufung: typischer Messfehler gegen kleinsten lohnenden Unterschied

Sammoud et al. (2021) formulieren die Regel ausdrücklich aus:

“In the case of $TEM < SWC$, the test’s capacity to detect small performance changes is considered “good”; when $TEM = SWC$, it is considered “OK”; when $TEM > SWC$, it is rated as “marginal”.”

Sammoud et al. (2021), PDF-S. 4

Die Quelle wendet sie auf denselben Test an, den wir verwenden — den 505 nach Draper & Lancaster, gemessen mit Microgate-Lichtschranken:

“Regarding the sensitivity analysis, the TEM (0.07 s) was higher than the $SWC_{0.2}$ (0.04 s), indicating a “marginal” ability of the 505 CoD speed test to detect small performance changes.”

Sammoud et al. (2021), PDF-S. 5

Für uns bedeutet das: Die Spalte TE/SESOI in Blatt 04_Kennwerte ist genau diese Kennzahl. Alle sechs Zielgrößen liegen über 1 und sind damit nach Sammouds Skala „marginal“ — die günstigste ist der 30-m-Sprint mit 1,24, die ungünstigste der 505 links mit 3,89. Das ist keine neue Rechnung, sondern ein publizierter Namen für einen Befund, der bereits vorliegt, und er ist dadurch in 4.4 und 6.1 belegbar statt nur behauptet.

3.2 Minimal detectable change — für uns neu

Taylor et al. (2018) definieren die Schwelle, ab der eine Veränderung mit 95 % Sicherheit keine Messschwankung mehr ist:

“The typical error can also be used to calculate the MDC, which provides information on the change in performance required for a practitioner to have confidence (95%) that a real change has occurred”

Taylor et al. (2018), PDF-S. 2

“Subsequently, the MDC was calculated as a percentage for each variable [...] as: $\text{typical error} \times 1.96 \times \sqrt{2}$ ”

Taylor et al. (2018), PDF-S. 3 f.

Entscheidend ist, wie Taylor die Größe verwendet — als Maßstab für Gruppenunterschiede, ohne p-Wert:

“All reported between groups effects were smaller than the group specific MDC.”

Taylor et al. (2018), PDF-S. 4

“Changes in performance that are smaller than the MDC should be considered with caution, as it cannot be stated with 95% confidence that these changes are substantial.”

Taylor et al. (2018), PDF-S. 6

Tab. 4. Die Verfahren an unseren Kennwerten gerechnet · Werte aus Blatt 04_Kennwerte

Zielgröße	TE	SESOI	TE/ SESOI	Einstufung	MDC	MDC in %	1,5 × TE	2 × TE
Sprint 5 m (s)	0,046	0,016	2,92	marginal	0,128	11,9	0,069	0,092
Sprint 10 m (s)	0,037	0,022	1,72	marginal	0,102	5,4	0,055	0,074
Sprint 30 m (s)	0,078	0,063	1,24	marginal	0,215	4,6	0,116	0,155
Standweitsprung (cm)	6,15	3,32	1,85	marginal	17,0	7,3	9,22	12,30
505 links (s)	0,089	0,023	3,89	marginal	0,246	9,9	0,133	0,178
505 rechts (s)	0,083	0,023	3,56	marginal	0,230	9,2	0,124	0,166

3.3 Die weniger strenge Schwelle nach Hopkins

Hopkins hält das 95-%-Kriterium für die Beurteilung einzelner Personen für zu streng und schlägt eine andere Schwelle vor:

“A more realistic threshold appears to be about 1.5 to 2.0 times the typical error (or a little more than half the limits of agreement), because the corresponding odds of a real change are between 6 and 12 to 1.”

Hopkins (2000), S. 7

Tab. 5. Welche beobachtete Veränderung erreicht welche Schwelle · IG paarweise, nach Korrektur HL-08

Zielgröße	IG Δ	n	MDC	2·TE	1,5·TE	A Δ	MDC	2·TE	1,5·TE
Sprint 5 m	0,031	16	nein	nein	nein	0,080	nein	nein	JA
Sprint 10 m	0,097	7	nein	JA	JA	0,097	nein	JA	JA
Sprint 30 m	0,056	16	nein	nein	nein	0,111	nein	nein	nein
Standweitsprung	4,44	16	nein	nein	nein	6,86	nein	nein	nein
505 links	0,000	15	nein	nein	nein	0,033	nein	nein	nein
505 rechts	0,011	14	nein	nein	nein	0,017	nein	nein	nein

Lesart. Keine einzige beobachtete Veränderung erreicht den MDC. Die 10-m-Veränderung überschreitet als einzige die Hopkins-Schwelle von $2 \times \text{TE}$ — und sie beruht ausschließlich auf Verein A, ist also kein Gruppenwert. Beim 5-m-Sprint überschreitet nur Verein A die schwächere Schwelle von $1,5 \times \text{TE}$. Das ist eine sachlich tragfähige, vollständig deskriptive Aussage und genau die Form, in der 5 m und 10 m in Kapitel 5 berichtet werden können.

⚠ Einschränkung, die mitgeteilt werden muss: Unser TE stammt aus Wiederholungsversuchen innerhalb einer Sitzung. Hopkins verlangt für Experimente ausdrücklich einen TE aus einer Reliabilitätsstudie derselben Dauer wie das Experiment — „Any estimate of sample size based on typical error in a reliability study must therefore be regarded as a minimum“ (S. 9). Unsere MDC-Werte sind damit Untergrenzen; der wahre MDC über neun bis elf Wochen liegt höher. Das verschärft die Aussage, es schwächt sie nicht.

3.4 Darstellung: Einzelwerte statt Kennzahlen

Ferguson et al. (2024) zeigen je Messtermin Rohdaten, Verteilungsdichte und Boxplot gemeinsam. Das erfüllt die Forderung aus § 11.9 nach Einzelwerten und vermeidet zugleich den in § 11.6 ausgeschlossenen Responder-Schluss, weil nichts klassifiziert wird:

“Raw data, probability density, and boxplots of Test 1, Test 2, and Test 3 for all outcome measures are visualized through Raincloud plots (1).”

Ferguson et al. (2024), PDF-S. 3

3.5 ⚠ Der Gegenbefund — Pflicht nach § 6.4

Ferguson et al. (2024) verwerfen genau die standardisierte Schwelle, auf der die Abschnitte 3.1 und 3.2 beruhen. Die Passage ist lang, aber sie muss vollständig zur Kenntnis genommen werden, weil sie unsere SESOI-Konvention direkt trifft.

“Despite its widespread popularity, researchers and practitioners are discouraged from this approach, however, as standardization produces unrealistic values when compared values deemed realistic by expert practitioners (11).”

Ferguson et al. (2024), PDF-S. 6

“Further disadvantages of standardization are that they can be challenging to interpret and misleading depending on whether the population is homogenous or heterogeneous (18), and there is no solid basis to use a certain value for a minimally important change in standardized units as this process produces highly variable estimates (42).”

Ferguson et al. (2024), PDF-S. 6 f.

“Once established, to evidence test sensitivity, measurement error should be interpreted against meaningful change and not against absolute reliability or standardized thresholds.”

Ferguson et al. (2024), PDF-S. 7

Konsequenz. § 12 führt bereits „SESOI als Konvention (Ferguson et al. lehnen sie ab)“ als Vormerkung. Der Volltext bestätigt das und verschärft es: Ferguson lehnt nicht nur den Wert 0,2 ab, sondern das Standardisieren als solches. Damit ist der Evidenzkörper an dieser Stelle uneinheitlich, und nach § 6.4 sind beide Seiten zu nennen. Die tragfähige Formulierung lautet: Die Einstufung folgt einer verbreiteten Konvention (Hopkins 2000 nach Cohen 1988; angewandt u. a. von Sammoud et al. 2021 und Beato et al. 2018), für die ein alternativer, praxisbezogener Maßstab vorgeschlagen wird, den wir mangels einer eigenen Wirksamkeitsverankerung nicht bilden können.

4 Frage 2: Verfahren für 30 m, Richtungswechsel und Standweitsprung

Die drei Zielgrößen erhalten zusätzlich zu allem aus Abschnitt 3 eine schließende Auswertung. Die Verfahrenswahl ANCOVA ist jetzt erstmals am Volltext belegbar.

4.1 Vickers & Altman (2001) — der Beschaffungsposten ist erledigt

“A better approach is to use analysis of covariance (ANCOVA), which, despite its name, is a regression method.”

Vickers & Altman (2001), S. 1123

“follow up score = constant + a×baseline score + b×group”

Vickers & Altman (2001), S. 1123

Die Aufnahme von %PAH als zweiter Kovariate ist durch dieselbe Quelle gedeckt:

“Lastly, analysis of covariance is a type of multiple regression and can be seen as a special type of adjusted analysis. The analysis can thus be expanded to include additional prognostic variables (not necessarily continuous), such as age and diagnostic group.”

Vickers & Altman (2001), S. 1124

Die Absage an den Änderungswert als Mittel gegen Baseline-Ungleichheit:

“However, analysing change does not control for baseline imbalance because of regression to the mean: baseline values are negatively correlated with change because patients with low scores at baseline generally improve more than those with high scores.”

Vickers & Altman (2001), S. 1123

Und die Regel, die unsere Prozessdisziplin stützt:

| *"It is incorrect, however, to choose whichever analysis gives a more significant finding."*

Vickers & Altman (2001), S. 1123

4.2 ⚠ Zwei Grenzen dieser Quelle, die uns unmittelbar betreffen

Erstens: Der Effizienzvorteil gilt bei uns nicht überall. Vickers & Altman beziffern ihn für eine Prä-Post-Korrelation von 0,6 — 85 Fälle beim Post-Vergleich, 68 beim Änderungswert, 54 bei der ANCOVA. Auf derselben Seite schränken sie selbst ein:

| *"The efficiency gains of analysis of covariance compared with a change score are low when there is a high correlation (say $r > 0.8$) between baseline and follow up measurements."*

Vickers & Altman (2001), S. 1124

Tab. 6. Wo die Einschränkung greift · r aus dem $R^2_{\max}$ der Sensitivitäts-Poweranalyse

Zielgröße	$R^2_{\max}$	r	Gilt die Einschränkung $r > 0,8$?
Sprint 30 m	0,881	0,94	ja — Effizienzvorteil gering
Sprint 10 m	0,777	0,88	ja — Effizienzvorteil gering
Standweitsprung	0,744	0,86	ja — Effizienzvorteil gering
Sprint 5 m	0,435	0,66	nein — Vorteil greift
505 rechts	0,245	0,49	nein — Vorteil greift
505 links	0,155	0,39	nein — Vorteil greift

Das heißt: Ausgerechnet bei den beiden Zielgrößen, die die Arbeit tragen — 30 m und Standweitsprung —, darf die ANCOVA nicht mit einem Effizienzgewinn begründet werden. Dort trägt allein das Argument aus § 11.2, dass sie zusätzlich die %PAH-Adjustierung erlaubt. Beim 505 greift der Effizienzvorteil dagegen voll. Wer Vickers & Altman pauschal als Effizienzbeleg zitiert, zitiert an der eigenen Datenlage vorbei.

Zweitens: Die Quelle setzt Randomisierung voraus. Der Text handelt durchgängig von randomisierten Studien und begründet Baseline-Ungleichgewicht mit Zufall („by chance“). Die Eigenschaft, dass die ANCOVA dieselbe Antwort gibt, ob ein Baseline-Unterschied vorliegt oder nicht, ist damit für zufällige Ungleichgewichte hergeleitet. Unsere Unterschiede sind nachweislich nicht zufällig (§ 4). Diese Eigenschaft ist deshalb aus Vickers & Altman nicht auf uns übertragbar — das ist genau Lord's Paradox, und es steht dort nicht. Die bereits in § 11.2 festgelegte Zurückhaltung („die ANCOVA adressiert die Baseline-Unterschiede“ ist zu stark) ist damit am Volltext bestätigt.

4.3 Zusätzliche Verfahren, die der Korpus stützt

a) Änderungswert-Rechnung als vorab festgelegte Sensitivitätsanalyse. Vickers & Altman lassen sie bei hoher Korrelation ausdrücklich zu: „analysis of change scores can be a reasonable alternative“ (S. 1124). Genau diese Bedingung ist bei 30 m, 10 m und Standweitsprung erfüllt. Beide Rechnungen nebeneinander zu berichten, macht die Verfahrenswahl überprüfbar. Zwingende Auflage: vorab festlegen und beide Ergebnisse berichten, unabhängig vom Ausgang — sonst greift das Verbot aus demselben Text, sich das signifikantere Verfahren auszusuchen.

b) Logarithmische Transformation der Zeitgrößen. Drei unabhängige Quellen: Vickers & Altman („data transformation, such as taking logarithms, may be indicated“, S. 1124) · Hopkins („analysis after logarithmic transformation addresses the problem of heteroscedasticity and provides an estimate of the typical percentage error“, S. 12) · Taylor et al. („All data were log-transformed to reduce the effect of non-uniformity of error“, PDF-S. 3). Nutzen für uns: prozentuale statt absolute Effekte, dadurch Vergleichbarkeit mit dem Korpus, der durchgängig in Prozent berichtet.

c) Konfidenzgrenzen für den typischen Messfehler. Hopkins verlangt sie ausdrücklich: „All estimates of reliability should be accompanied by confidence limits for the true value“ (S. 13). Wir berichten den TE bisher als Punktschätzer. Nach Hopkins' Tabelle II liegt der Faktor für unsere Konstellation (26 bis 31 Personen,

zwei bis drei Versuche) bei rund 1,20 bis 1,30 — der wahre TE kann also 20 bis 30 Prozent über oder unter dem berichteten liegen. Diese Angabe gehört in 4.4 und relativiert zugleich die MDC-Werte aus Abschnitt 3.2.

d) Hopkins' Fallzahlformel als unabhängige Gegenprobe. Für eine Studie mit Kontrollgruppe gibt Hopkins $4n = 32 s^2/d^2$ an (S. 8), mit s als typischem Messfehler und d als kleinstem lohnenden Effekt. Auf unsere Messgüte angewandt ergibt das erforderliche Gesamtfallzahlen von 49 (30 m), 94 (10 m), 110 (Standweitsprung), 274 (5 m), 405 (505 rechts) und 485 (505 links) — gegenüber tatsächlich 24 bis 28. Das bestätigt die Sensitivitäts-Poweranalyse aus einer zweiten, unabhängigen Quelle und ist für Kapitel 7.2 erheblich griffiger als die Angabe eines Vielfachen des SESOI.

e) Prüfung auf systematische Verschiebung zwischen Messterminen. Ferguson et al. (2024) verwenden dafür gemischte lineare Modelle mit dem Termin als festem und dem Spieler als zufälligem Effekt (PDF-S. 3). Für die in der Datendurchsicht offene Frage zu Verein A ist das das einschlägige Verfahren. ⚠ Nicht zu verwechseln mit dem in § 11.6 ausgeschlossenen Mehrebenenmodell mit Vereinseffekt — dort scheitert es an drei Clustern, hier geht es um die Prä-Post-Verschiebung innerhalb eines Vereins.

4.4 Reifestatus: als Kovariate belassen, nicht als Moderator prüfen

Der Korpus behandelt den Reifestatus auf vier verschiedene Weisen, und die Befunde widersprechen einander.

Quelle	Behandlung des Reifestatus	Befund
Lloyd et al. (2016)	dritter Faktor im $2 \times 4 \times 2$ Modell	signifikante Zeit $\times$ Training $\times$ Reife-Interaktion; prä-PHV profitierten stärker
Bouafif et al. (2026)	Stratifizierung vor der Zuteilung, dann Faktor	post-PHV profitierten stärker — gegenläufig zu Lloyd
Ramirez-Campillo et al. (2023)	Metaanalytischer Moderator	kein Moderatoreffekt außer beim Richtungswechsel
Negra 2019 · Sammoud 2024 · Asimakidis 2022	erhoben, rein deskriptiv	keine Adjustierung
Beato 2018 · Aloui 2022 · Liu 2024 · Padrón-Cabo 2025	gar nicht erhoben	—

Empfehlung: bei der Kovariate bleiben. Eine Moderatorprüfung wäre der Test auf Homogenität der Regressionssteigungen, und § 11.9 hält bereits fest, dass er bei $n = 28$ nur sehr große Steigungsunterschiede findet. Die Literatur stützt die Zurückhaltung zusätzlich: Ramirez-Campillo et al. (2020) warnen ausdrücklich davor, stetige Variablen für Subgruppen zu zerschneiden — „the dichotomisation of continuous data [...] could result in residual confounding and reduced statistical power“ (PDF-S. 14). Unsere kontinuierliche Führung von %PAH ist damit literaturgestützt die bessere Wahl, und die widersprüchliche Befundlage zur Moderation gehört als offene Frage nach 6.1, nicht in eine eigene Rechnung.

★ **Ein Beleg, der die Methodenwahl unmittelbar stützt:** Moran et al. (2016/17) fordern nicht nur die Erhebung der Reife, sondern nennen unser Verfahren beim Namen — „alternatives such as the Khamis-Roche method (37) offer a similarly convenient and non-invasive way of predicting adult stature“ (PDF-S. 15). Das ist im gesamten Korpus die einzige namentliche Empfehlung von Khamis-Roche und gehört nach 4.2.

5 Was die Forschenden selbst vermissen

Ausbeute der Diskussions- und Ausblicksteile: Verfahren, die als nützlich bezeichnet, aber nicht verwendet wurden. Das ist zugleich der Katalog dessen, was unsere Arbeit bereits leistet.

Quelle	Was gefordert, aber nicht selbst getan wird
Oliver et al. (2024)	„Future research should implement randomisation procedures, ensuring a similar baseline level of key dependent variables.“ — und: Reifestatus und Trainingshistorie berichten, weil deren uneinheitliche Berichterstattung jede Moderatoranalyse verhinderte
Ramirez-Campillo et al. (2023)	„Future studies are encouraged to report participants' maturity status“ · „Future studies must incorporate more robust analyses“
Ramirez-Campillo et al. (2020)	Reife als Moderator aufnehmen; Selbstkritik an der Dichotomisierung stetiger Variablen
Moran et al. (2016/17)	Kontrollgruppe zwingend; Reifemaß erheben, Khamis-Roche ausdrücklich genannt
Taylor et al. (2018)	mehr Versuche je Termin — „if each player had completed four tests, the ‚noise‘ of the test would be halved“; ausgiebigere Familiarisierung gegen systematischen Bias
Ferguson et al. (2024)	hauseigene Reliabilitätsstudie; Messfehler gegen einen extern begründeten „meaningful change“ statt gegen Schwellenwerte
Beato et al. (2018)	größere Stichprobe; Kontrollgruppe (die Studie hat keine)
Negra et al. (2019)	aktive Kontrollgruppe; physiologische und biomechanische Messgrößen

Bemerkenswert ist, was in diesem Katalog fehlt. Keine der geprüften Interventionsstudien fordert eine Fallzahlbegründung; vier haben eine a priori (Aloui 2022, Liu 2024, Sammoud 2024, Bouafif 2026), alle mit Effektstärken aus Einzelstudien als Eingangsgröße — die Form, die § 11.1 ausschließt (Korrektur 11.09. abends). Keine fordert Konfidenzintervalle für Effektstärken, obwohl Hammami und Aloui keine berichten. Taylor et al. (2018) ist die einzige Quelle des Korpus, die einen Wunsch nach mehr Versuchen je Termin formuliert — genau der Punkt, den § 11.8 für künftige Testtermine festlegt.

6 Was ich nicht empfehle — und warum nicht

Äquivalenz- oder Nichtunterlegenheitsprüfung. Naheliegend, weil ein Nullbefund erwartet wird und ein nicht signifikanter Test kein Wirksamkeitsausschluss ist. ⚠ Keine der 30 geprüften Quellen verwendet oder erwähnt ein solches Verfahren. Nach § 7.1 ist es damit hier nicht zitierfähig. Wenn es verwendet werden soll, braucht es eine eigene Methodenquelle — Lakens (2022) steht bereits in der Referenzbasis nach § 15, liegt aber nicht im Ordner. Als Beschaffungsposten vermerken, nicht als Empfehlung führen.

Bootstrap-Konfidenzintervalle, Permutationstests, Bayes-Schätzung. Im gesamten Korpus kein einziger Treffer. Gleiche Konsequenz.

Magnitude-based inferences. Im Korpus vorhanden — Beato (2018), Negra (2019) und Taylor (2018) verwenden sie. Ich rate dennoch ab. Beato verzichtet dafür vollständig auf Nullhypothesentests („A traditional approach based on the null hypothesis and P-value was not reported in this study“, PDF-S. 10), und Negra etikettiert jede einzelne Zeile als „Likely beneficial“, auch dort, wo die 90-%-Grenzen die Null überschreiten — also entgegen dem eigenen Kriterium. Das Verfahren ist seit 2018 methodisch umstritten und würde bei unserer Fallzahl dieselbe Schwäche zeigen. Brauchbar ist daraus nur der Punktschätzer mit Intervall, nicht die Wahrscheinlichkeitsetiketten.

Prädiktionsintervalle. Oliver et al. (2024) berichten sie — es ist aber ein metaanalytisches Instrument für die Übertragbarkeit auf künftige Populationen und auf eine Einzelstudie nicht anwendbar.

7 Empfehlung

	Maßnahme	Beleg	Wohin
1	MDC je Zielgröße berechnen und berichten; beobachtete Differenzen gegen MDC und gegen $1,5-2,0 \times TE$ stellen	Taylor 2018 · Hopkins 2000	4.4 und 5
2	Sensitivitätseinstufung „marginal“ für alle sechs Zielgrößen benennen, mit Ferguson-Gegenbefund in derselben Passage	Sammoud 2021 · Ferguson 2024	4.4 und 6.1
3	Konfidenzgrenzen für den TE ergänzen (Faktor rund 1,20–1,30)	Hopkins 2000, Tab. II	4.4
4	ANCOVA-Begründung auf Vickers & Altman stützen — ohne Effizienzargument bei 30 m und Standweitsprung, und ohne die Randomisierungsprämisse zu übernehmen	Vickers & Altman 2001	4.7
5	Änderungswert-Rechnung vorab als Sensitivitätsanalyse festlegen, beide Ergebnisse berichten	Vickers & Altman 2001	4.7 und 5
6	Logarithmische Transformation der Zeitgrößen prüfen und entscheiden	V&A · Hopkins · Taylor	4.7
7	Hopkins-Fallzahlformel als zweite Begründung der Fallzahlempfehlung aufnehmen	Hopkins 2000, S. 8	7.2 und Anhang G
8	%PAH kontinuierlich belassen, keine Moderatorprüfung; widersprüchliche Befundlage in 6.1 benennen	RC 2020 · Lloyd 2016 · Bouafif 2026 · RC 2023	4.7 und 6.1
9	Khamis-Roche-Wahl mit Moran et al. belegen	Moran 2016/17, PDF-S. 15	4.2
1 0	T1 und T4 um die geprüften Quellen und die neuen Zitierfallen ergänzen	dieses Dokument	ev3_datan

Zum Abschluss ein Befund für 6.2. Von den geprüften Interventions- und Detraining-Studien haben vier eine A-priori-Fallzahlbegründung mit Einzelstudien-Effektstärken, keine berichtet den typischen Messfehler, SEM oder MDC aus eigenen Daten (vier berichten einen CV), und drei verwenden eine ANCOVA mit dem Ausgangswert als Kovariate — keine mit dem Reifestatus. Im gesamten Detraining-Korpus kommt keine Kovariate vor — auch nicht bei Padrón-Cabo et al. (2025), die mit U15 gegen U17 dasselbe Reifeproblem haben wie wir und es unbehandelt lassen. Unsere Messgütetabelle, die Sensitivitäts-Poweranalyse und die %PAH-Adjustierung liegen damit über dem Standard des Vergleichsfelds. Das gehört als Stärke formuliert, nicht als Pflichtübung.