

Voraussetzungsprüfungen der ANCOVA

Erklärung, Literaturabgleich und Folgerungen · Stand 24.09.2026, 13:45 MESZ

Grundlage: Spezifikation der Rechenschritte vom 24.09.2026 (S14, S19, O7, O8, K18 bis K21, P5), Auswertungsplan vom 12.09.2026, Projektanweisungen F12 § 11.2 und § 11.9. **Vergleichskorpus:** Schreiben\ev3_daten\T6_auswertungspraxis.csv (elf Interventionsstudien) und 02_Befunde\RCT_Auswertungspraxis_2026-09-11. **Methodenquellen im Ordner:** Fröhlich et al. (2020), Cohen (1988), Vickers und Altman (2001), Moher et al. (2010). **Externe Quellen:** am 24.09.2026 recherchiert, Volltextstatus je Quelle in Abschnitt 6.

⚠ **Nicht an die blinde Instanz weitergeben.** Das Dokument verweist an drei Stellen auf die erste Rechnung vom 15.09., ohne deren Zahlen zu nennen.

Kurzfassung

Eine Voraussetzungsprüfung fragt, ob die Daten einer Modellannahme deutlich widersprechen. Bestätigen kann sie eine Annahme nie. Bei 23 bis 26 Spielern je Modell entdeckt sie nur grobe Verletzungen. Deshalb lautet das Ergebnis „geprüft und nicht verworfen“ und nicht „erfüllt“ (PA § 11.9).

Prüfung in S14	prüft die Annahme	Präzedenz im Vergleichskorpus	Stützung außerhalb des Korpus	Urteil
1 Shapiro-Wilk der Residuen	normalverteilte Fehler	Test in 6 von 11 Studien, aber an Messwerten, nicht an Residuen	gut: Ernst und Albers (2017), Razali und Wah (2011), Vickers und Altman (2001)	gestützt, Q-Q-Diagramm ergänzen (N1)
2 Brown-Forsythe	gleiche Fehlervarianz beider Gruppen	Levene in 3 von 11, Brown-Forsythe in keiner	gut: NIST (2020), Cohen (1988), Delacre et al. (2017)	gestützt, Residuen-SD je Gruppe ergänzen (N2)
3 Steigungshomogenität	parallele Regressionsgeraden	in keiner der drei ANCOVA-Studien	Lehrbuchstandard: Leppink (2018), Schneider et al. (2015)	gestützt, geringe Trennschärfe benennen
4 Linearität grafisch	gerader Zusammenhang Kovariate zu Post	keine	gut: Ernst und Albers (2017), Stuart (2010)	gestützt
5 Überlappung	gemeinsamer Wertebereich der Kovariaten	keine	gut: Stuart (2010), Pokorny und Mittal (2026)	gestützt, hier die wichtigste Prüfung
6 Vorab-Prüfung an Prä-Werten	Vorinformation, keine ANCOVA-Annahme	keine	nur mittelbar	nachvollziehbar, gering gewichten
Regel O7	verworfen Prüfung ändert nichts	Aloui et al. (2022) faktisch, ohne Regel	gut: Rochon et al. (2012), Sullivan und D'Agostino (2003), Gegenposition Leppink (2018)	gestützt, Bootstrap auf alle drei Zielgrößen ausweiten (N3)

Zwei Annahmen prüft keine Rechnung: die Unabhängigkeit der Spieler innerhalb eines Vereins und die Messfehlerfreiheit der Kovariaten. Beide gehören als Grenzen in 6.1 (Abschnitt 4). Die Literatur ergibt drei kleine Nachträge zur Spezifikation (Abschnitt 5.1). Keiner ändert ein festgelegtes Verfahren.

1 Das Modell und seine Annahmen

Die Hauptanalyse schätzt je Zielgröße das Modell $\text{Post} = b_0 + b_1 \cdot G + b_2 \cdot \text{Prä} + b_3 \cdot \text{PAH} + e$. G ist 1 für die IG und 0 für die KG. b_1 ist die adjustierte Gruppendifferenz. Das Residuum e ist der Teil des Post-Werts, den Gruppe, Ausgangswert und Reifestatus nicht erklären.

Die Annahmen wirken an zwei verschiedenen Stellen. Normalverteilung und gleiche Varianz der Residuen betreffen nur den Standardfehler von b_1 und damit Konfidenzintervall und p-Wert. Linearität, parallele Steigungen und Überlappung betreffen schon den Punktschätzer b_1 selbst. Sind sie verletzt, misst b_1 nicht die Größe, die er messen soll.

Leppink (2018, Abschn. 1.1) zählt sechs Annahmen der ANCOVA auf. Zwei weitere Punkte kommen hinzu, weil die Gruppen nicht randomisiert sind.

Nr.	Annahme	Inhalt	Prüfung in S14
1	unabhängige Residuen	Die Abweichung eines Spielers verrät nichts über die eines anderen	keine, Frage des Designs (Abschnitt 4.1)
2	Residuenmittel null bei jedem Wert von Gruppe und Kovariate	Das Modell liegt nirgends systematisch daneben, praktisch die Linearität	Regel 4, grafisch
3	normalverteilte Residuen	Grundlage für p-Wert und Konfidenzintervall bei kleinem n	Regel 1, Shapiro-Wilk
4	gleiche Residuenvarianz über Gruppen und Kovariate	Die Vorhersage ist in beiden Gruppen gleich genau	Regel 2, Brown-Forsythe
5	Gruppenvariable und Kovariate fest und ohne Messfehler	Prä-Wert und %PAH sind exakt bekannt	keine, nicht prüfbar (Abschnitt 4.2)
6	gleiche Steigung in allen Gruppen	Der Zusammenhang Kovariate zu Post ist in IG und KG gleich stark	Regel 3, Modelle SLPRE und SLPAH
+	gemeinsamer Wertebereich der Kovariaten	Beide Gruppen haben Spieler mit ähnlichen Ausgangswerten	Regel 5, Überlappung
+	Vorab-Prüfung laut Plan	Blick auf die Prä-Werte, bevor Post-Werte vorlagen	Regel 6

2 Die Prüfungen im Einzelnen

2.1 Normalverteilung der Residuen: Shapiro-Wilk (Regel 1, K18)

Was geprüft wird. Die Nullhypothese lautet: Die Residuen stammen aus einer Normalverteilung. Die Prüfgröße W beruht auf der Korrelation zwischen den der Größe nach geordneten Residuen und den Werten, die eine Normalverteilung an diesen Rangplätzen erwarten ließe (Ghasemi & Zahediasl, 2012, Abschn. 3). W nahe 1 heißt gute Übereinstimmung. Bei $p < 0,05$ gilt die Annahme als verworfen.

Warum die ANCOVA das braucht. Konfidenzintervall und p-Wert von b_1 stammen aus der t-Verteilung. Das ist nur bei normalverteilten Fehlern exakt. In großen Stichproben gleicht der zentrale Grenzwertsatz Abweichungen aus, in kleinen nicht. Williams et al. (2013, S. 1) fassen zusammen, dass Regressionsmodelle „require the assumption of normally distributed errors in order for trustworthy inferences, at least in small samples, but not the assumption of normally distributed response or predictor variables“. Der Punktschätzer bleibt unberührt. Probleme entstehen „primarily ... for inferential problems (such as confidence intervals and testing) with small samples“ (Ernst & Albers, 2017, Abschn. „Consequences of violations of assumptions“).

Warum an den Residuen und nicht an den Messwerten. Die Annahme betrifft die Fehler. Ernst und Albers (2017) nennen die Prüfung der Rohwerte den häufigsten Irrtum: „researchers incorrectly assume that X_i , or both X_i and Y , should be normally distributed, rather than the errors of the model“. Die Rohwerte zu prüfen, unterstellt zudem, alle Spieler hätten denselben Erwartungswert (Ernst & Albers, 2017). Das trifft bei zwei Gruppen mit verschiedenen Ausgangswerten gerade nicht zu. Rochon et al. (2012, Abschn. „Strategy II“) prüfen deshalb die Residuen: „the normality assumption can be examined through residuals instead of raw data“.

Warum gemeinsam über beide Gruppen. Das Modell unterstellt eine einzige Fehlerverteilung. Gemeinsam stehen 23 bis 26 Residuen zur Verfügung statt 10 bis 16 je Gruppe. Das erhöht die ohnehin geringe Trennschärfe.

Warum Shapiro-Wilk und warum Royston. Unter den gängigen Tests hat Shapiro-Wilk die größte Trennschärfe, vor Anderson-Darling, Lilliefors und Kolmogorov-Smirnov (Razali & Wah, 2011, S. 21). Ghasemi und Zahediasl (2012, Abschn. 3) bestätigen den Vorsprung vor dem Kolmogorov-Smirnov-Test. Beide Quellen schränken ein: „the power of all four tests is still low for small sample size“ (Razali & Wah, 2011, S. 21). Bei kleinen Stichproben bestehen die meisten Daten den Test (Ghasemi & Zahediasl, 2012, Abschn. 3). Royston (1995) ist die Rechenvorschrift, nach der R den Test rechnet (R-Dokumentation zu `shapiro.test`). Referenztest R09 und Implementierung sind damit vergleichbar.

Präzedenz im Ordner. Shapiro-Wilk nennen 6 der 11 Korpusstudien: Beato et al. (2018), Negra et al. (2020), Aloui et al. (2022), Sammoud et al. (2024), Bouafif et al. (2026) und Padrón-Cabo et al. (2025). Den Kolmogorov-Smirnov-Test nennen Hammami et al. (2016) und Liu et al. (2024). Keine Studie gibt an, Residuen geprüft zu haben. Wo der Gegenstand erkennbar ist, sind es die Messwerte selbst: Aloui et al. (2022, S. 4) melden „24% (9/37) of the other parameters are not normally distributed“, Padrón-Cabo et al. (2025, S. 3) „All analyzed variables showed a normal distribution“. Die Methodenquellen im Ordner verlangen die Prüfung, ohne ein Verfahren festzulegen. Fröhlich et al. (2020, S. 59) halten fest, dass die Anwendungsvoraussetzungen von t-, z- und F-Tests „hinsichtlich Varianzhomogenität und Normalverteilung ... stets zu prüfen sind“, und nennen Schiefe und Kurtosis oder den Kolmogorov-Smirnov-Test als Beispiele. Vickers und Altman (2001, S. 1124) schreiben zur ANCOVA: „the use of analysis of covariance depends on some assumptions that need to be tested“. Der Statistik-Lehrgang vom 09.09. (Tab. F1) sah bereits die Residuen vor, mit Q-Q-Diagramm und Shapiro-Wilk als Ergänzung.

Urteil. Verfahren und Gegenstand sind gut gestützt. Das Korpus liefert eine Präzedenz für den Test, nicht für seinen Gegenstand. Zwei Punkte folgen aus der Literatur. Ein nicht verworfener Test ist bei dieser Fallzahl kein Nachweis. Und die Grafik gehört neben den Test. Ernst und Albers (2017, Abschn. „Best practices for checking of assumptions“): „Applying graphical methods is therefore a preferred approach.“ Ghasemi und Zahediasl (2012, Abschn. 5): „It is preferable that normality be assessed both visually and through normality tests“. S14 enthält kein Q-Q-Diagramm der Residuen (Vorschlag N1).

2.2 Gleiche Fehlervarianz: Brown-Forsythe (Regel 2, K19)

Was geprüft wird. Für jeden Spieler wird der Betrag des Abstands seines Residuums vom Median der Residuen seiner Gruppe gebildet. Streut eine Gruppe stärker, sind ihre Abstände im Mittel größer. Eine einfaktorielle Varianzanalyse vergleicht die mittleren Abstände beider Gruppen. Bei $p < 0,05$ gilt die Annahme gleicher Varianz als verworfen.

Warum die ANCOVA das braucht. Das Modell schätzt eine gemeinsame Residuenvarianz für beide Gruppen und aus ihr den Standardfehler von b_1 . Streuen die Gruppen verschieden, ist dieser Standardfehler falsch. Bei etwa gleich großen Gruppen schadet das wenig, bei ungleich großen erheblich. Cohen (1988, S. 43) nennt den t-Test robust „despite moderate failure of this assumption provided that sample sizes are about equal“. Bei ungleichen Varianzen und ungleichen Gruppengrößen zugleich „the nominal values for t and power at a given significance criterion ... may differ greatly from the true values“ (Cohen, 1988, S. 44). Die Richtung beschreiben Delacre et al. (2017): „When the larger variance is associated with the smaller sample size, the Type 1 error rate is inflated“. Liegt die größere Varianz in der größeren Gruppe, sinkt der Fehler erster Art. In allen drei Analysesets ist die KG die kleinere Gruppe (16 zu 10, 13 zu 10, 16 zu 10). Streut die KG stärker, fallen die p-Werte zu klein aus. Die Quellen sprechen vom t-Test. Die Übertragung auf den Gruppenkoeffizienten der ANCOVA ist eigene Ableitung [EXTRAPOLATION]: Der t-Test ist ein Spezialfall des linearen Modells (Rochon et al., 2012, Abschn. „Strategy II“), und b_1 wird wie dort mit einer gepoolten Residuenvarianz getestet.

Warum der Median statt des Mittelwerts. Levene (1960) bildete die Abstände vom Gruppenmittelwert. Brown und Forsythe (1974) setzten den Median ein. Das NIST/SEMATECH e-Handbook (NIST, 2020, Abschn. 1.3.5.10) empfiehlt die Median-Variante „as the choice that provides good robustness against many types of non-normal data while retaining good power“. Der Mittelwert hat bei symmetrischen Verteilungen die größte Trennschärfe, der Median ist bei schiefen Verteilungen überlegen. Weil die Normalverteilung der Residuen bei dieser Fallzahl selbst unsicher ist (2.1), ist die robuste Variante folgerichtig.

Warum an den Residuen und nach Gruppe. Die Annahme betrifft die Streuung um die Vorhersage. Die Streuung der Post-Werte enthält zusätzlich den Einfluss von Ausgangswert und Reife. Geprüft wird nach Gruppe, weil die Gruppenvarianz zusammen mit den ungleichen Gruppengrößen die Verzerrung bestimmt. Ob die Varianz mit dem Wert der Kovariate wächst, zeigt die Grafik der Residuen gegen die Vorhersage (Regel 4) als Trichterform.

Präzedenz im Ordner. Den Levene-Test nennen 3 der 11 Korpusstudien: Hammami et al. (2016), Aloui et al. (2022) und Liu et al. (2024). Den Brown-Forsythe-Test nennt keine. Ein Ergebnis berichten nur Aloui et al. (2022, S. 4: 6 von 16 Prüfungen verworfen, ohne Konsequenz) und Liu et al. (2024, S. 4: „confirmed“, ohne Kennwerte). Fröhlich et al. (2020, S. 59) verlangen die Prüfung der Varianzhomogenität. Cohen (1988, S. 43–44) liefert im Ordner die Begründung, warum sie bei ungleichen Gruppen zählt.

Gegenposition. Zimmerman (2004, nur Abstract) und Delacre et al. (2017) raten davon ab, die Varianzen erst zu testen und danach das Verfahren zu wählen. Zimmerman: „Optimum protection is assured by using a separate-variances test unconditionally whenever sample sizes are unequal.“ Delacre et al.: Der Levene-Test „can have very low power, which leads to Type 2 errors when sample sizes are small and unequal“. Die Regel O7 vermeidet den Wechsel nach Vortest (Abschnitt 3). Ein von vornherein robustes Verfahren enthält die Spezifikation nur in S19.

Urteil. Die Verfahrenswahl ist gut gestützt. Präzedenz gibt es für den Levene-Test, nicht für die Median-Variante. Der p-Wert allein sagt nicht, in welche Richtung eine Ungleichheit wirkt. Dafür braucht der Bericht die Residuen-SD je Gruppe (Vorschlag N2).

2.3 Parallele Steigungen: zwei Interaktionsmodelle (Regel 3, K20)

Was geprüft wird. Modell SLPRE ergänzt das Hauptmodell um den Term G·Prä. Sein Koeffizient ist der Unterschied der Prä-Steigung zwischen IG und KG. Ein t-Test prüft, ob er von null abweicht. Modell SLPAH macht dasselbe für %PAH mit dem Term G·PAH.

Warum die ANCOVA das braucht. Die ANCOVA legt zwei parallele Geraden durch die Daten, eine je Gruppe. b_1 ist ihr senkrechter Abstand, und der ist nur bei parallelen Geraden überall gleich. Laufen die Geraden auseinander, gibt es „den“ Gruppenunterschied nicht. Er hängt dann vom Ausgangswert ab. Leppink (2018, Abstract) hält fest, dass das Modell mit Wechselwirkung in diesem Fall zeigt, „that the magnitude of a group difference depends on the level of the covariate“, während die ANCOVA einen einzigen Gruppenunterschied ausweist. Besonders schwer wiegt das, wo sich die Gruppen im Wertebereich der Kovariate wenig überlappen. Dort beruht der Vergleich ganz auf der Parallelität (2.5).

Warum zwei getrennte Modelle. Der Auswertungsplan nennt beide Wechselwirkungen (§ 2 B6 und Tab. 1: „Gruppe × Prä, Gruppe × %PAH“). Getrennt geschätzt hat jeder Test $df = n - 5$ statt $n - 6$. Jeder Interaktionskoeffizient ist nur für die Kovariaten des Hauptmodells adjustiert, nicht für die zweite Wechselwirkung. So lässt sich ein Befund genau einer Kovariate zuordnen. Eine Literaturvorgabe für die getrennte Form gibt es nicht. Sie ist Festlegung K20 des Verfassers.

t statt F. Die erste Rechnung vom 15.09. gab F aus, die Spezifikation gibt t aus. Bei einem Zählerfreiheitsgrad gilt $F = t^2$ bei identischem p. Im Abgleich ist das umzurechnen, nicht als Abweichung zu werten.

Präzedenz im Ordner. Keine. Keine der drei ANCOVA-Studien des Korpus berichtet die Prüfung: Beato et al. (2018), Negra et al. (2020) und Sammoud et al. (2024). Die Auswertungspraxis vom 11.09. wertet das als Lücke des Korpus: „prüfen und berichten“. Die geringe Trennschärfe ist im Projekt belegt. Beim Standweitsprung war die %PAH-Steigung an den Prä-Werten in der KG fast viermal so steil wie in der IG, und der Test fand das nicht (PA § 11.9, Lehrgang 09.09., Teil J).

Außerhalb des Ordners. Die Prüfung ist Lehrbuchstandard. Schneider et al. (2015, Einleitung): „statistical textbooks recommend that the homogeneity of slope assumption be tested before conducting an ANCOVA“. Leppink (2018, Abschn. 1.1) führt sie als sechste Annahme. Kim (2018) zeigt die Prüfung über den Interaktionsterm. Miller und Chapman (2001, S. 41–42) geben Rogosa wieder: „with small sample sizes, functionally important differences in slopes might not be ‚significant‘“.

Gegenposition. Leppink (2018) empfiehlt, auf Grund der Prüfung nach Informationskriterien zwischen ANCOVA und Modell mit Wechselwirkung zu wählen. Dagegen stehen Sullivan und D'Agostino (2003, nur Abstract): Das Vorgehen, erst die Steigungen zu testen und bei Verwerfung getrennte Steigungen zu schätzen, „produced significance levels that exceeded the nominal levels especially when the sample sizes were small“. Der Ethikantrag legt zudem das Modell fest.

Urteil. Gut gestützt, im Korpus ohne Präzedenz. Die Lücke liegt beim Korpus. Wegen der geringen Trennschärfe gehört neben den p-Wert die Größe des Steigungsunterschieds, also Koeffizient und Standardfehler. Beide gibt S14 bereits aus. Den Modellwechsel nach Vortest schließt O7 aus, in Übereinstimmung mit Sullivan und D'Agostino (2003) und dem Antrag.

2.4 Linearität: Grafik statt Test (Regel 4, K21)

Was geprüft wird. Drei Streudiagramme je Zielgröße: Residuen gegen die Vorhersage, gegen Prä und gegen %PAH, die Gruppen unterscheidbar markiert. Stimmt das Modell, liegen die Punkte als waagrechtes Band um null. Ein Bogen zeigt einen gekrümmten Zusammenhang, ein Trichter eine mit dem Wert wachsende Streuung.

Warum die ANCOVA das braucht. Die Adjustierung folgt einer Geraden. Ist der wahre Zusammenhang gekrümmt, wird gerade dort falsch adjustiert, wo sich die Gruppen am stärksten unterscheiden. Stuart (2010, Abschn. 1.2) warnt, lineare Adjustierung könne die Verzerrung sogar vergrößern, „when the true relationship between the covariate and outcome is even moderately non-linear, especially when there are large differences in the means and variances of the covariates in the treated and control groups“. Das ist die Lage dieser Studie (2.5).

Warum nur grafisch. Ein Test auf Krümmung, etwa über einen quadrierten Prä-Term, hat bei 23 bis 26 Spielern dieselbe geringe Trennschärfe wie die übrigen Prüfungen. Die Grafik zeigt dagegen, ob, wo und in welcher Form das Modell danebenliegt. Ernst und Albers (2017) ziehen grafische Verfahren vor. Kozak und Piepho (2018, nur Abstract) halten Residuengrafiken für aussagekräftiger als Tests. Die Schwäche: Das Urteil ist subjektiv. Im Bericht gehört das beobachtete Muster in einen Satz, die Grafiken gehören in den Anhang.

Abweichung von der ersten Rechnung. Die Python-Kette vom 15.09. und das SPSS-Vorgehen vom 24.09. prüfen die Linearität mit einem quadrierten Prä-Term und F-Test. Die Spezifikation tut das nicht (K21). Im Abgleich hat dieser Wert kein Gegenstück und ist als erwartete Abweichung zu vermerken.

Präzedenz im Ordner. Keine im Korpus. Im Projekt sah der Lehrgang vom 09.09. (Tab. F1) ein Streudiagramm Post gegen Prä je Gruppe vor.

Außerhalb des Ordners. Linearität ist die erste der vier Regressionsannahmen bei Ernst und Albers (2017) und eine „widely-known“ Voraussetzung bei Schneider et al. (2015, Einleitung). Bei Leppink (2018) steckt sie in der zweiten Annahme, dem Residuenmittel null bei jedem Wert der Kovariate.

Urteil. Gut gestützt. Das Q-Q-Diagramm aus N1 gehört in dieselbe Grafikausgabe.

2.5 Überlappung der Kovariaten (Regel 5)

Was geprüft wird. Für Prä und für %PAH im Analyseset der gemeinsame Wertebereich, von der größeren der beiden Gruppenuntergrenzen bis zur kleineren der beiden Obergrenzen, und je Gruppe die Zahl der Spieler darin. Das ist eine Beschreibung, kein Test.

Warum die ANCOVA das braucht. Die ANCOVA vergleicht beide Gruppen bei einem gemeinsamen Wert der Kovariaten. Wo nur eine Gruppe Spieler hat, fehlt der Vergleich in den Daten. Das Modell ergänzt ihn, indem es die Geraden über die Daten hinaus verlängert. Pokorny und Mittal (2026): „Lack of overlap, on the other hand, occurs when certain ranges of the covariate are only occupied by units from one of the groups.“ Die Prüfungen 1 bis 4 zeigen das nicht. Stuart (2010, Abschn. 6.2): „Standard regression diagnostics will not warn researchers when there is insufficient overlap to reliably estimate causal effects“.

Warum in dieser Studie besonders. Stuart (2010, Abschn. 4.1) nennt als Faustregel: „For regression adjustment to be trustworthy, the absolute standardized differences of means should be less than 0.25 and the variance ratios should be between 0.5 and 2“. Die Ausgangsunterschiede der drei konfirmatorischen Zielgrößen lagen im Planungsstand zwischen $|d| = 0,56$ und $1,70$ (PA § 3), beim %PAH bei rund $1,6$ Standardabweichungen (eigene Rechnung aus PA § 3). Die Faustregel ist bei allen drei Zielgrößen verfehlt. Das Ergebnis hängt damit stärker als in einer randomisierten Studie an Linearität und parallelen Steigungen. Die Zahl der Spieler im gemeinsamen Bereich zeigt, auf wie vielen Spielern der Vergleich tatsächlich ruht.

Präzedenz im Ordner. Keine im Korpus. Im Projekt: Lehrgang „Überlappung und Kovariate“ (11.09.) und PA § 11.9.

Außerhalb des Ordners. Stuart (2010) und Pokorny und Mittal (2026) stützen die Prüfung ausdrücklich. Pokorny und Mittal halten es für wichtig, „to inspect the comparability of groups on key covariates“.

Urteil. Gut gestützt, ohne Korpuspräzedenz, in dieser Studie die inhaltlich wichtigste Prüfung. Die Varianzverhältnisse nach Stuart lassen sich aus den SD je Gruppe in S12 bilden. Eine neue Rechnung braucht es dafür nicht.

2.6 Vorab-Prüfung an den Prä-Werten (Regel 6, P5)

Was geprüft wird. Erstens das Modell $\text{Prä} = c_0 + c_1 \cdot G + c_2 \cdot \text{PAH} + c_3 \cdot G \cdot \text{PAH}$: Hängt die Ausgangsleistung in beiden Gruppen gleich stark mit dem Reifestatus zusammen? Zweitens Shapiro-Wilk der Prä-Bestwerte je Gruppe. Beides in der Menge der Spieler mit Prä-Wert und %PAH (P5).

Warum. Der Auswertungsplan (§ 2 B6) legte diese Prüfung fest, als es noch keine Post-Werte gab. Der erste Teil gibt einen frühen Hinweis auf die Frage, die SLP AH später am Post-Wert beantwortet. Der zweite Teil prüft Rohwerte und ist damit keine ANCOVA-Voraussetzung (2.1). Er beschreibt die Form der Ausgangsverteilung. Bei deutlicher Schiefe beschreiben Mittelwert und SD die Gruppe schlecht. Moher et al. (2010, Item 15) schlagen für asymmetrische Verteilungen Median und Perzentilbereich vor.

Präzedenz im Ordner. Keine.

Urteil. Als Vorinformation nachvollziehbar und planmäßig. Im Bericht nicht als Prüfung einer ANCOVA-Voraussetzung darstellen, sondern als Beschreibung der Ausgangslage, in höchstens einem Satz.

3 Die Entscheidungsregel O7

Inhalt. Eine verworfene Prüfung ($p < 0,05$) ändert das Verfahren nicht. Sie wird mit Prüfgröße und p-Wert berichtet (S14, Merkmal VERW).

Warum. Drei Gründe tragen die Regel.

1. Der Ethikantrag legt die ANCOVA fest. Ein Modellwechsel nach Sichtung der Daten wäre eine nicht vorab festgelegte Abweichung (PA § 1.5).
2. Die Literatur zu zweistufigen Verfahren rät ab. Rochon et al. (2012, Abschn. „Conclusions“): „From a formal perspective, preliminary testing for normality is incorrect and should therefore be avoided.“ Als Grund nennen sie, dass Vortest und Haupttest auf denselben Daten laufen, „which may result in uncontrolled error rates“ (Abschn. „Background“). Sie schränken selbst ein, dass der Vortest praktisch wenig Schaden anrichte: „From a practical perspective, however, preliminary testing does not seem to cause much harm“. Ihr Einwand ist also formal, nicht praktisch. Zimmerman (2004, nur Abstract) fand, dass das zweistufige Vorgehen bei Varianzen „fails to protect the significance level and usually makes the situation worse“. Für die Steigungen gilt dasselbe (Sullivan & D'Agostino, 2003, siehe 2.3).
3. Die Trennschärfe ist gering. Bei 23 bis 26 Spielern ist ein nicht verworfener Test kein Nachweis, und ein verworfener markiert nur grobe Abweichungen. Keines von beidem trägt einen Verfahrenswechsel.

Gegenpositionen. Leppink (2018) will die Steigungsprüfung zur Modellwahl nutzen (2.3). Im Ordner selbst schreiben Vickers und Altman (2001, S. 1124) nach dem Satz über die Prüfpflicht: „In particular, data transformation, such as taking logarithms, may be indicated.“ Die Transformation wäre eine Konsequenz aus der Prüfung. O7 folgt dem aus zwei Gründen nicht. Eine Log-Transformation verlegt den Effekt auf eine Verhältnisskala, und der Vergleich mit SESOI und TE in Sekunden und Zentimetern ginge verloren. Eine Transformation nur bei verworfenem Test wäre zudem wieder ein zweistufiges Verfahren.

Präzedenz im Ordner. Aloui et al. (2022) berichten Verletzungen und rechnen unverändert parametrisch weiter, ohne die Konsequenz zu begründen. Das ist die Praxis von O7, aber ohne Regel. Liu et al. (2024, S. 4) tun das Gegenteil: „Once both normality and homogeneity assumptions were confirmed, a mixed ANOVA test (time*group) was conducted“. Das ist genau das zweistufige Vorgehen, von dem Rochon et al. (2012) abraten.

Was O7 nicht leistet. Die Regel verhindert den Wechsel nach Vortest. Einen Ausgleich für eine echte Verletzung bietet sie nicht. Diesen Ausgleich liefert in der Spezifikation nur S19, das Bootstrap-Konfidenzintervall. Fröhlich et al. (2020, S. 78) stützen es im Ordner: Bootstrapping „ermöglicht die Durchführung von Signifikanztests ohne die Annahme der theoretischen Normalverteilung und eignet sich daher insbesondere für Situationen mit nichtnormalverteilten Daten“. S19 zieht ganze Spieler, getrennt nach Gruppe, und schätzt das Modell jedes Mal neu. Die tatsächliche Streuung jeder Gruppe geht so unverändert in das Intervall ein. Eine gleiche Varianz der Gruppen setzt S19 deshalb nicht voraus [EXTRAPOLATION, in dieser Prüfung ohne Literaturbeleg].

Die Auswahl in S19. Das Bootstrap-Intervall ist nur für 30 m festgelegt, und zwar nachdem die erste Rechnung vom 15.09. dort die Normalverteilung der Residuen verworfen hatte (Sitzungsnotizen Teil 0, Rev. 81). Die Zusatzanalyse hängt damit an einem Vortest mit geringer Trennschärfe. Dass die beiden anderen Zielgrößen nicht verworfen wurden, belegt keine Normalverteilung. Als Sensitivität ersetzt S19 das Hauptergebnis nicht, der

Schaden bleibt begrenzt. Folgerichtig nach Rochon et al. (2012) wäre dennoch die Anwendung auf alle drei konfirmatorischen Zielgrößen, unabhängig vom Vortest (Vorschlag N3).

Die Robustheitsaussage vom 15.09. Das Analyseprotokoll vom 15.09. (§ 5) nennt die ANCOVA „bei $n = 26$ gegenüber moderater Abweichung von der Normalverteilung robust“. Cohen (1988, S. 273–274) stützt Robustheit allgemein: „moderate violations of these assumptions have generally negligible effects on the validity of null hypothesis tests and power analyses“. Die neueren Quellen binden sie an die Stichprobengröße. Schmidt und Finan (2018, Abstract) nennen mehr als zehn Beobachtungen je Variable, Ghasemi und Zahediasl (2012, Abschn. 1) mehr als 30 bis 40 Beobachtungen. Williams et al. (2013, S. 3) halten Inferenz bei kleinen Stichproben mit nicht normalverteilten Fehlern für nicht vertrauenswürdig. Hier kommen im Hauptmodell $23/3 \approx 7,7$ bis $26/3 \approx 8,7$ Spieler auf eine erklärende Variable, in den Steigungsmodellen $23/4 \approx 5,8$ bis $26/4 = 6,5$ (eigene Rechnung). Die Robustheitsaussage ist für diese Fallzahl nicht gedeckt und so nicht ins Manuskript zu übernehmen.

4 Was keine Prüfung abdeckt

4.1 Unabhängigkeit der Spieler

Leppink (2018, Abschn. 1.1) nennt sie als erste Annahme: „the residuals are assumed to be independent“. Moher et al. (2010, Item 12a) übersetzen das für kontrollierte Studien: „this usually means that there is one observation per participant“. Auf Spielerebene erfüllt die Spezifikation das mit einem Bestwert je Spieler und beim 505 mit einem Seitenmittel. Auf Vereinsebene nicht. Spieler eines Vereins teilen Trainer, Platz, Testtag, Wetter und Prä-Post-Intervall. Ihre Residuen können deshalb einander ähnlicher sein als die von Spielern verschiedener Vereine. Die KG besteht aus einem Verein, die IG aus zweien. Keine Rechnung in S14 prüft das, und mit drei Vereinen lässt es sich nicht modellieren (PA § 11.6). Folge: Der Standardfehler von b_1 fällt vermutlich zu klein aus (PA § 12). Im Ordner berücksichtigen Hilska et al. (2021, S. 4) die Korrelation der Spieler eines Vereins mit cluster-robusten Standardfehlern, in einer cluster-randomisierten Studie mit 20 Vereinen. Auf drei Vereine ist das nicht übertragbar [EXTRAPOLATION].

4.2 Messfehlerfreie Kovariaten

Nach Leppinks fünfter Annahme sind Gruppenvariable und Kovariate „fixed and measured without error“. Für die Gruppe gilt das, für die Kovariaten nicht. Der Prä-Wert trägt den typischen Messfehler aus S10, %PAH den Vorhersagefehler der Formel nach Khamis und Roche. Pokorny und Mittal (2026): „when the covariate is measured with error, the estimate of the treatment effect will be biased ... The only exception to this is when the independent variable (IV) and covariate (Cov) are uncorrelated.“ Gruppe und Kovariaten hängen hier stark zusammen (2.5). Eine Verzerrung ist also zu erwarten, ihre Größe ist unbekannt. Zur Richtung bei einer einzelnen Kovariate [EXTRAPOLATION]: Der Messfehler flacht die geschätzte Steigung ab, die Adjustierung fällt zu klein aus, und b_1 behält einen Teil des Ausgangsunterschieds. Bei allen drei konfirmatorischen Zielgrößen lag der Ausgangsvorsprung bei der IG (PA § 3). Die Verzerrung würde dort zugunsten der IG wirken.

4.3 Nicht randomisierte Gruppen

Schneider et al. (2015, Einleitung) nennen eine weitere Voraussetzung, die bei randomisierter Zuteilung per Konstruktion gilt, bei vorgefundenen Gruppen aber nicht: „the expected value of the covariate is the same for all of the participants in the experiment“. Die Vereine sind solche vorgefundenen Gruppen. Miller und Chapman (2001, S. 40) folgern, echte Gruppenunterschiede in einer Kovariate ließen sich oft nicht „korrigieren“ oder „kontrollieren“. Pokorny und Mittal (2026) widersprechen: Gleichheit der Gruppen in der Kovariate sei keine Voraussetzung. Entscheidend sei, ob die Kovariate vor der Intervention gemessen wurde. Das trifft auf Prä-Wert und %PAH zu. Übrig bleiben nach Pokorny und Mittal genau die Punkte aus 2.5 und 4.2, fehlende Überlappung und Messfehler. Die Formulierung der Projektanweisungen trägt damit: Die ANCOVA „reduziert die Konfundierung, sie beseitigt sie nicht“ (PA § 11.2).

5 Folgerungen

5.1 Nachträge zur Spezifikation, zur Entscheidung vor dem Blindlauf

F1 ist gegeben. Die drei Nachträge ergänzen Ausgaben und ändern kein festgelegtes Verfahren. Sie wären als datierter Nachtrag nach F1 zu führen, mit neuen Kennungen in _Kennungen.csv.

Nr.	Nachtrag	Grund	Empfehlung
N1	Normal-Q-Q-Diagramm der Residuen je Zielgröße in S14 Regel 4, Datei S14_QQ_<ZIEL>, Gruppen markiert	Grafik neben dem Test (Ernst & Albers, 2017, Ghasemi & Zahediasl, 2012), im Lehrgang 09.09. schon vorgesehen	ja
N2	SD der Residuen je Gruppe und ihr Verhältnis KG zu IG in S14 Regel 2	Richtung der Verzerrung bei ungleich großen Gruppen (Cohen, 1988, S. 44, Delacre et al., 2017)	ja
N3	S19 für 30 m, 505-Seitenmittel und Standweitsprung. Startwert 20260924 vor jeder Zielgröße neu gesetzt, damit 30 m unverändert bleibt	Auswahl nach Vortest vermeiden (Rochon et al., 2012), gleiche Toleranzregel	ja

Erwogen und nicht empfohlen: heteroskedastizitätsrobuste Standardfehler, Transformationen, eine Rang-ANCOVA und Modelle mit getrennten Steigungen. Jedes davon wäre eine weitere nachträgliche Analyse ohne Grundlage im Antrag. N3 deckt die Normalverteilung ab und nach eigener Ableitung auch ungleiche Varianzen (Abschnitt 3).

5.2 Für den Abgleich (Phase 6)

- Linearität: Der F-Test des quadrierten Prä-Terms aus der ersten Rechnung hat in der Spezifikation kein Gegenstück. Als erwartete Abweichung vermerken.
- Steigungen: F aus der ersten Rechnung gegen t^2 aus S14 vergleichen, p direkt.
- Shapiro-Wilk und Brown-Forsythe tragen in beiden Rechnungen denselben Namen. Ob die erste Rechnung ebenfalls die Residuen nach Gruppe verwendet, ist im Abgleich am Code zu bestätigen.
- N1 und N2 haben kein Gegenstück in der ersten Rechnung.

5.3 Für das Manuskript

4.7 Statistische Auswertung. Die Prüfungen in zwei Sätzen nennen, dazu die Regel O7 mit Grund und die Formulierung „geprüft und nicht verworfen“. Das Bootstrap-Intervall als nachträgliche Zusatzsensitivität kennzeichnen. Baustein, kein Textvorschlag: „Die Voraussetzungen wurden an den Modellresiduen geprüft: Normalverteilung mit dem Shapiro-Wilk-Test, Varianzgleichheit zwischen den Gruppen mit dem Brown-Forsythe-Test, parallele Regressionssteigungen über je einen Interaktionsterm Gruppe $\times$ Kovariate, Linearität grafisch. Beschrieben wurde zudem die Überlappung der Gruppen im Wertebereich der Kovariaten. Eine verworfene Prüfung wurde berichtet, ohne das vorab festgelegte Modell zu ändern.“ Belege dafür: Leppink (2018) für die Annahmen, Shapiro und Wilk (1965) und Brown und Forsythe (1974) als Verfahrensquellen, Rochon et al. (2012) für die Regel.

6.1 Methodendiskussion. Sechs Punkte aus diesem Befund:

1. Geringe Trennschärfe aller Prüfungen bei dieser Fallzahl (Razali & Wah, 2011, Delacre et al., 2017).
2. Robustheit gegenüber nicht normalverteilten Residuen ist bei 23 bis 26 Spielern nicht gesichert (Schmidt & Finan, 2018). Die Aussage aus dem Analyseprotokoll vom 15.09. § 5 nicht übernehmen.
3. Ungleiche Gruppengrößen mit Richtung der Streuung aus N2 (Cohen, 1988, Delacre et al., 2017).
4. Ausgangsunterschiede weit über der Faustregel von Stuart (2010). Das Ergebnis hängt an Linearität und parallelen Steigungen, die Zahl der Spieler im gemeinsamen Bereich zeigt die tragende Basis.
5. Unabhängigkeit auf Vereinsebene nicht gegeben und nicht modellierbar (Moher et al., 2010, Item 12a, PA § 12).
6. Messfehler der Kovariaten, Verzerrung zu erwarten, vermutlich zugunsten der IG (Pokorny & Mittal, 2026, Leppink, 2018, Richtung als EXTRAPOLATION).

5.4 Zitierfähigkeit und Beschaffung

Nach PA § 7.1 wird nur zitiert, was als Volltext im Ordner liegt und gelesen wurde. Die online gelesenen Quellen (Status V in Abschnitt 6) sind vor einer Zitation in Ideen und Studien abzulegen und selbst zu lesen. Die Seitenangaben aus online gelesenen PDFs sind dabei zu prüfen. Nur als Abstract gelesen und damit nicht zitierfähig: Zimmerman (2004), Sullivan und D'Agostino (2003), Kozak und Piepho (2018). Die Verfahrensquellen

Shapiro und Wilk (1965), Brown und Forsythe (1974) und Royston (1995) sind über die Bibliothek zu beschaffen (PA § 6.2: Originalquelle zwingend). Miller und Chapman (2001) lag nur als Lehrkopie vor, Razali und Wah (2011) nur als Scan mit Lesefehlern. Für beide ist die Verlagsfassung zu beschaffen oder auf die Zitation zu verzichten.

6 Quellen und Volltextstatus

Status: **O** Volltext im Ordner · **V** Volltext am 24.09. online gelesen, nicht im Ordner · **A** nur Abstract · **M** nur Metadaten geprüft. Die Korpusstudien sind in T1 mit vollständigen Angaben geführt.

- **M** Brown, M. B., & Forsythe, A. B. (1974). Robust tests for the equality of variances. *Journal of the American Statistical Association*, 69(346), 364–367. <https://doi.org/10.1080/01621459.1974.10482955>
- **O** Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2. Aufl.). Lawrence Erlbaum.
- **V** Delacre, M., Lakens, D., & Leys, C. (2017). Why psychologists should by default use Welch's t-test instead of Student's t-test. *International Review of Social Psychology*, 30(1), 92–101. <https://doi.org/10.5334/irsp.82>
- **V** Ernst, A. F., & Albers, C. J. (2017). Regression assumptions in clinical psychology research practice: A systematic review of common misconceptions. *PeerJ*, 5, e3323. <https://doi.org/10.7717/peerj.3323>
- **O** Fröhlich, M., Mayerl, J., Pieter, A., & Kemmler, W. (2020). *Einführung in die Methoden, Methodologie und Statistik im Sport*. Springer Spektrum.
- **V** Ghasemi, A., & Zahediasl, S. (2012). Normality tests for statistical analysis: A guide for non-statisticians. *International Journal of Endocrinology and Metabolism*, 10(2), 486–489. <https://doi.org/10.5812/ijem.3505>
- **V** Kim, H.-Y. (2018). Statistical notes for clinical researchers: Analysis of covariance (ANCOVA). *Restorative Dentistry & Endodontics*, 43(4), e43. <https://doi.org/10.5395/rde.2018.43.e43>
- **A** Kozak, M., & Piepho, H.-P. (2018). What's normal anyway? Residual plots are more telling than significance tests when checking ANOVA assumptions. *Journal of Agronomy and Crop Science*, 204(1), 86–98. <https://doi.org/10.1111/jac.12220>
- **V** Leppink, J. (2018). Analysis of covariance (ANCOVA) vs. moderated regression (MODREG): Why the interaction matters. *Health Professions Education*, 4(3), 225–232. <https://doi.org/10.1016/j.hpe.2018.04.001>
- **M** Levene, H. (1960). Robust tests for equality of variances. In I. Olkin et al. (Hrsg.), *Contributions to probability and statistics: Essays in honor of Harold Hotelling* (S. 278–292). Stanford University Press.
- **V** Miller, G. A., & Chapman, J. P. (2001). Misunderstanding analysis of covariance. *Journal of Abnormal Psychology*, 110(1), 40–48. <https://doi.org/10.1037/0021-843X.110.1.40> (gelesen als Lehrkopie)
- **O** Moher, D., Hopewell, S., Schulz, K. F., Montori, V., Gøtzsche, P. C., Devereaux, P. J., Elbourne, D., Egger, M., & Altman, D. G. (2010). CONSORT 2010 explanation and elaboration: Updated guidelines for reporting parallel group randomised trials. *BMJ*, 340, c869. <https://doi.org/10.1136/bmj.c869>
- **V** National Institute of Standards and Technology. (2020). *NIST/SEMATECH e-Handbook of statistical methods* (Abschn. 1.3.5.10: Levene test for equality of variances). <https://doi.org/10.18434/M32189>
- **V** Pokorny, V., & Mittal, V. A. (2026). Misunderstanding of analysis of covariance revisited: Commentary on Miller and Chapman (2001). *Journal of Psychopathology and Clinical Science*, 135(3), 345–348. <https://doi.org/10.1037/abn0001062> (online 2025, gelesen über PubMed-Text ohne kursive Wörter)
- **V** R Core Team. Dokumentation der Funktion `shapiro.test`, Paket stats.
- **V** Razali, N. M., & Wah, Y. B. (2011). Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, 2(1), 21–33. (gelesen als Scan, nicht Verlagsfassung)
- **V** Rochon, J., Gondan, M., & Kieser, M. (2012). To test or not to test: Preliminary assessment of normality when comparing two independent samples. *BMC Medical Research Methodology*, 12, 81. <https://doi.org/10.1186/1471-2288-12-81>
- **M** Royston, P. (1995). Remark AS R94: A remark on algorithm AS 181: The W-test for normality. *Applied Statistics*, 44(4), 547–551. <https://doi.org/10.2307/2986146> (Endseite nach der R-Dokumentation, Verlagsseite nicht geprüft)
- **V** Schmidt, A. F., & Finan, C. (2018). Linear regression and the normality assumption. *Journal of Clinical Epidemiology*, 98, 146–151. <https://doi.org/10.1016/j.jclinepi.2017.12.006> (gelesen als Autorenfassung)

- V Schneider, B. A., Avivi-Reich, M., & Mozuraitis, M. (2015). A cautionary note on the use of the analysis of covariance (ANCOVA) in classification designs with and without within-subject factors. *Frontiers in Psychology*, 6, 474. <https://doi.org/10.3389/fpsyg.2015.00474>
- M Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4), 591–611. <https://doi.org/10.1093/biomet/52.3-4.591>
- V Stuart, E. A. (2010). Matching methods for causal inference: A review and a look forward. *Statistical Science*, 25(1), 1–21. <https://doi.org/10.1214/09-STS313>
- A Sullivan, L. M., & D'Agostino, R. B. (2003). Robustness and power of analysis of covariance applied to ordinal scaled data as arising in randomized controlled trials. *Statistics in Medicine*, 22(8), 1317–1334. <https://doi.org/10.1002/sim.1433>
- O Vickers, A. J., & Altman, D. G. (2001). Statistics notes: Analysing controlled trials with baseline and follow up measurements. *BMJ*, 323(7321), 1123–1124. <https://doi.org/10.1136/bmj.323.7321.1123>
- V Williams, M. N., Gómez Grajales, C. A., & Kurkiewicz, D. (2013). Assumptions of multiple regression: Correcting two misconceptions. *Practical Assessment, Research & Evaluation*, 18(11). (ERIC EJ1015680, keine DOI)
- A Zimmerman, D. W. (2004). A note on preliminary tests of equality of variances. *British Journal of Mathematical and Statistical Psychology*, 57(1), 173–181. <https://doi.org/10.1348/000711004849222>

Projektdokumente: Spezifikation der Rechenschritte 24.09.2026 · Auswertungsplan 12.09.2026 · Projektanweisungen F12 · Statistik-Lehrgang 09.09. (Zielgrößen und Verfahren) und 11.09. (Überlappung und Kovariate) · RCT_Auswertungspraxis 11.09. · T6_auswertungspraxis.csv · Analyseprotokoll 15.09. · SPSS_Auswertung_Vorgehen 24.09.